分类号 _____ 密 级 _____

U D C _____ 编 号 _____

成都理工大学

专业学位硕士学位论文

题名和副题名 基于站内多关系图与机制诊断的充电节点短期负荷预测研究

作 者 姓 名 胥舒元

指导教师姓名及职称 杨小峰 (副教授)

申请学位级别 专业学位硕士 类别 (领域) 电气工程

论文提交日期 _____ 论文答辩日期 _____

学位授予单位和日期 成 都 理 工 大 学 (年 月)

答辩委员会主席 _____

分类号_____ 学校代码：10616

U D C _____ 密级_____ 学号：2024050524

专业学位硕士学位论文

基于站内多关系图与机制诊断的充电节点短期负荷预测研究

胥舒元

指导教师姓名及职称 杨小峰（副教授）

申请学位级别 专业学位硕士 类别（领域） 电气工程

论文提交日期 _____ 论文答辩日期 _____

学位授予单位和日期 成 都 理 工 大 学（ 年 月）

答辩委员会主席 _____

独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。据我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得成都理工大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的人员对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

学位论文作者签名：

年　　月　　日

学位论文版权使用授权书

本学位论文作者完全了解成都理工大学有关保留、使用学位论文的规定，有权保留并向国家有关部门或机构送交论文的复印件和磁盘，允许论文被查阅和借阅。本人授权成都理工大学可以将学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

（保密的学位论文在解密后适用本授权书）

学位论文作者签名：

学位论文作者导师签名：

年　　月　　日

基于站内多关系图与机制诊断的充电节点短期负荷预测研究

摘 要

场站内充电节点负荷稀疏且异质，全局误差未必反映活跃片段表现。本文以公开会话记录重构的 15 min 节点代理负荷为对象，检验站内关系与节点级门控的预测增量，并据此讨论模型选择与误差报告。主要比较采用 Caltech 事件时刻协议与 JPL 另一场站重新拟合协议，均假定行为计数在时间片末可见。

本文构建负荷耦合、行为共现和轮廓相似关系图，以多关系门控图卷积网络（MRG-GCN）融合时间表示与节点关系；并以三层机制诊断协议（MDP）分别检验冻结参数敏感度、受检时序学生的替代表现和事件—规则四格误差构成。主要贡献是对站内关系增量及其解释范围进行受控检验，不主张基础图卷积、门控或时序网络组合为算法首创。

Caltech 事件时刻协议下，MRG-GCN 整体 MAE 为 0.03890 kWh/15 min，较容量近似 TCN 低 16.1%，但完整 AGCRN 更低，且 MRG-GCN 在非零目标和标签事件组均未优于 TCN。JPL 中 MRG-GCN 整体 MAE 较三项预登记基线低 2.64%—3.36%，但 TCN 的 RMSE、标签事件及非零目标误差更低。节点级门控在两场站相对同参数节点共享门控的整体 MAE 分别低 2.69%和 2.71%；节点共享门控各有一个种子触及 60 轮上限，结论限于该预算。

JPL 关系替换重训支持负荷耦合和轮廓相似关系相对自环的条件性整体 MAE 增量（1.82%和 1.52%），行为共现关系仍不确定。负荷关系相对自环的非零组正向差异属于未校正事后分层；完整 MRG-GCN 非零组仍未胜过 TCN。完成时刻截断后，MRG-GCN 相对容量近似 TCN 的整体 MAE 排序保持，但非零组 MAE 仍较高。以上补充分析复用已查看测试期。

MDP 分别解释参数敏感度、受检学生的替代表现和误差构成，修正了关系取舍、替代性判断与分层报告重点。现有结果可支持节点代理负荷模型筛选和后续采数安排；实测功率效度、输入到达时延和运行收益仍需同步量测及现场评价。

关键词：充电节点短期负荷预测；LRE；MRG-GCN；MDP；节点代理负荷

Short-Term Load Forecasting of Charging Nodes Based on Within-Station Multi-Relation Graphs and Mechanism Diagnosis

Abstract

Charging-node proxy energy is sparse and heterogeneous, so aggregate error can conceal performance on active intervals. This thesis studies 15-minute node proxy energy reconstructed from public charging sessions. It tests whether within-station relations and node-specific gates add predictive value, and what model-selection and error-reporting decisions those comparisons support. Main analyses use Caltech's event-time protocol and a separately refitted JPL site, assuming behavioral counts are available at interval end.

MRG-GCN combines temporal representations with load-coupling, behavioral co-occurrence, and profile-similarity relations. The contribution is a controlled test of within-station relation gains and their interpretive scope, not a claim of novelty for the underlying graph convolution, gating, or temporal-network components. At Caltech, its overall MAE is 0.03890 kWh/15 min, 16.1% below a capacity-near TCN, but full AGCRN performs better and MRG-GCN does not lead on nonzero or labeled-event targets. At JPL, its overall MAE is 2.64%–3.36% below three preregistered baselines, while TCN has lower RMSE and lower nonzero- and labeled-event-target errors. Node-specific gates reduce overall MAE by 2.69% and 2.71% relative to parameter-matched shared gates at Caltech and JPL, respectively; one shared-gate seed per site reaches the 60-epoch limit, so this result is budget-bound.

JPL relation-replacement retraining supports conditional overall-MAE gains over self-loop replacements for load coupling (1.82%) and profile similarity (1.52%); the behavioral relation remains uncertain. An uncorrected post-hoc nonzero-target difference for load coupling is exploratory and does not imply that the complete model beats TCN on nonzero targets. With the completion-time-truncated target, MRG-GCN retains its overall-MAE ranking relative to the capacity-near TCN, while its nonzero-target MAE remains higher. These supplements reuse inspected test periods.

MDP separates parameter sensitivity, a tested student's replacement performance, and error composition. The distinctions refine relation choice, model replacement claims, and subgroup reporting, but do not show that diagnosis-guided model changes improve prediction. The findings can guide node-proxy-load model screening and data collection; meter validity, reporting delays, and operational benefits require synchronized measurements and field evaluation.

Keywords: short-term charging-node load forecasting; LRE; MRG-GCN; MDP; node proxy load

目 录

第 1 章 绪论 1
1.1 研究背景与意义 1
1.1.1 电动汽车充电负荷增长与节点级预测需求 1
1.1.2 离散会话记录与节点代理负荷预测问题 1
1.1.3 站内节点关系建模与事件窗口预测意义 2
1.2 国内外研究现状 2
1.2.1 电动汽车充电负荷时间序列预测 2
1.2.2 多节点负荷与时空图预测 3
1.2.3 充电行为特征与事件建模 5
1.2.4 模型可解释性与机制诊断 5
1.3 现有研究不足 6
1.4 研究目标与主要内容 7
1.5 技术路线 8
1.6 论文组织结构 8
1.7 本章小结 9
第 2 章 充电行为数据与特征分析 10
2.1 数据来源与重构口径 10
2.1.1 三套评估协议的任务边界 12
2.1.2 分摊支持范围与实测形态核查 13
2.1.3 JPL 另一场站数据与验证口径 14
2.2 节点可用性筛选与质量门禁 15
2.3 节点负荷统计特征 17
2.4 事件分数构成与事件窗口统计 19
2.5 特征构成与协议输入 23
2.6 数据特征对建模的启示 25
2.7 本章小结 26
第 3 章 基于多关系门控图卷积的节点短期负荷预测 27
3.1 引言 27
3.2 预测任务形式化定义 29
3.3 场景驱动的 LRE 三关系图构建 30
3.3.1 负荷耦合关系图 31
3.3.2 行为共现关系图 31

3.3.3 轮廓相似关系图 31
3.3.4 top-k 稀疏化与对称归一化 31
3.4 时间基线：TCN 32
3.5 双层多关系门控图卷积网络（MRG-GCN） 32
3.5.1 总体架构 32
3.5.2 单关系消息传递 33
3.5.3 关系级门控 33
3.5.4 节点级门控 33
3.5.5 关系随机失活 34
3.5.6 逐层关系选择与跨层融合 34
3.5.7 目标函数与训练策略 34
3.5.8 与现有方法的区别 34
3.5.9 节点门控与残差更新的分工 34
3.5.10 跨层表示的使用原则 35
3.6 主要预测结果与回溯补充 36
3.6.1 评价协议与指标 36
3.6.2 Caltech 事件时刻协议的预测结果 37
3.6.3 JPL 重拟合协议：另一场站的点预测比较 38
3.6.4 回溯补充：完整配置与复算状态 41
3.6.5 回溯补充：分层与节点误差 45
3.6.6 回溯补充：模型规模与训练记录 47
3.7 组件增量与协议敏感性 48
3.7.1 同参数节点级门控配对对照 48
3.7.2 关系路径、关系子集与敏感性 49
3.7.3 关系级参数干预 51
3.7.4 组合配置消融与事件残差探索 51
3.7.5 四格评价的加权还原检查 52
3.8 证据综合与适用范围 52
3.8.1 方法组件与目标敏感性证据综合 53
3.8.2 三套协议的回答范围与比较边界 54
3.8.3 输入、容量与训练选模预算 54
3.8.4 完成时刻截断目标敏感性（SG-EXP-032） 55
3.9 本章小结 56
第 4 章　三层机制诊断协议（MDP）与模型可解释性分析 57
4.1 引言：MDP 协议的定义与设计原则 57

4.2 L1 干预归因层（IA）：关系分配的功能依赖 58
4.2.1 观察操作 58
4.2.2 干预操作 58
4.2.3 观察证据 58
4.2.4 干预证据 59
4.2.5 L1 判定结论 60
4.2.6 分层敏感度：关系分配干预的样本响应 61
4.3 L2 蒸馏验证层（DV）：受检时序学生的替代性分析 62
4.3.1 协议操作 62
4.3.2 诊断实验 63
4.3.3 L2 判定结论 63
4.4 L3 四格溯源层（FET）：全局误差构成 64
4.4.1 协议操作 64
4.4.2 诊断实验 64
4.4.3 还原校验 66
4.4.4 L3 判定结论 66
4.5 MDP 诊断结果与适用边界 67
4.6 JPL 的 L1/L3 复核与适用范围 67
4.6.1 复核材料与计算口径 67
4.6.2 L1：整体配置敏感度及样本层面差异 68
4.6.3 L3：困难样本与总误差组成 69
4.6.4 复核结论与剩余验证范围 69
第 5 章 模型结构与可靠性边界分析 70
5.1 引言 70
5.2 方向性统计候选与结构对照 70
5.2.1 问题与动机 70
5.2.2 传递熵方向性检验 71
5.2.3 传递熵名义候选与双向读数不对称 71
5.2.4 有向候选边与统计关系图的互补性 72
5.2.5 PCMCI+条件独立检验与版本敏感性 74
5.2.6 方向性证据的解释边界与复核路径 75
5.3 事件感知的区间预测：分层共形预测 76
5.3.1 问题与动机 76
5.3.2 分层共形方法 76
5.3.3 事件时刻输入协议下的独立校准补充 77

5.3.4 成熟标签约束下的滚动校准回放 78
5.3.5 JPL 既有预测的独立校准补充 78
5.3.6 回溯补充：覆盖与路由错位 79
5.3.7 回溯补充：残差失配诊断 81
5.4 节点负荷预测的决策接口与验证条件 82
5.4.1 预测量与运行量的对应 82
5.4.2 从预测曲线到运行核查 83
5.4.3 固定发布时刻的四目标片算例 83
5.4.4 有限时域充电分配与合成决策算例 84
5.4.5 证据边界与应用验证要求 85
5.5 本章小结 85
结 论 86
研究工作总结 86
主要研究结论 86
研究判断与使用条件 87
研究局限与后续工作 87
参考文献 88
附录 A Caltech 事件时刻协议完整组件结果 93

第 1 章　绪论

1.1 研究背景与意义

1.1.1 电动汽车充电负荷增长与节点级预测需求

我国电动汽车保有量及配套充电设施持续增长。截至 2024 年底，全国公共充电桩保有量达到 357.9 万台[1]。用户到达时刻、停留时长和充电需求的不确定性，使充电负荷呈现随机性、间歇性与空间不均衡性[2-4]。充电负荷预测因而成为配电容量配置、场站运行管理和有序充电调度的基础。

现有研究多以区域、站群或单个充电站的聚合负荷为预测对象，其结果能够支持电网侧调度和站级容量规划，但难以直接回答场站内部各充电节点在未来时段的负荷分配问题[2-3]。对于站内运行而言，不同充电节点的活跃水平、峰值时段和负荷波动并不一致。以节点为粒度的短期预测可为多桩负荷均衡、局部容量约束识别、设备利用率分析以及有序充放电优化提供更细粒度的信息[5-6]，其空间分辨率更接近场站实际控制与运维对象。

节点级预测也比聚合负荷预测面临更突出的数据困难。多个用户行为在聚合后能够相互平滑，而单个节点通常包含大量零负荷时段和少量突变时段，负荷序列的稀疏性、非平稳性与节点异质性更加明显。若仅依赖单节点历史序列进行外推，模型可能难以利用同一场站内其他节点的同步变化和互补信息。因此，本文首先要解决的问题是：在明确数据物理口径的前提下刻画站内节点关系，并建立适合稀疏负荷的短期预测方法。

1.1.2 离散会话记录与节点代理负荷预测问题

充电运营平台的数据通常以离散会话记录形式保存，每条记录包含充电节点标识、接入时刻、离站时刻和充电电量等字段，而不是连续采样的电表功率序列。利用这类运营数据预测时，需先将会话在统一时间网格上展开或聚合，形成可供时序模型处理的等间隔负荷序列[7-9]。本文以 15 min 为时间粒度，将原始充电会话重构为“时间步—节点”二维序列，并将每个时间片内由会话记录分配得到的能量定义为节点代理负荷。

节点代理负荷是按会话起止时间和总电量重构的时间片能量，电表功率则来自实际充电过程的计量。能量分配假设会改变时间形态，因此本文结论限定于节点代理负荷；二者的对应关系须经同步量测验证。

会话重构既解决了模型输入的时间对齐问题，也限定了后续分析的统计边界。节点在无充电会话时对应大量零值，常用百分比误差指标可能因分母接近零而失

真；不同节点的会话数量、活跃月份和负荷水平也存在差异。因此，数据重构、节点筛选、评价指标选择与模型设计需要在统一数据口径下协同确定。

1.1.3 站内节点关系建模与事件窗口预测意义

同一场站内的充电节点共享用户到达过程和运行环境，其负荷变化并非完全独立，可能呈现长期负荷同步、充电行为共同出现及日内轮廓相似等统计联系[10-11]。图神经网络将节点表示与关系结构结合，通过邻居信息传播补充单节点时序缺失的横向信息，已用于充电站群和多节点负荷预测[10,12-13]。本文的图边由训练期数据统计得到，表示站内节点间的统计交互，而非配电网电气连接或充电设施物理拓扑。

多类关系的预测作用需分别检验。本文为负荷耦合、行为共现和轮廓相似关系设置独立变换，以逐层关系权重和节点级门控融合消息，并通过重训练对照与冻结参数干预评价其作用；由于权重与变换共同决定消息，学习权重能否优于等权设置仍须实验判断。

除周期性变化外，充电节点还会出现接入、离站、活跃会话变化或负荷跳变构成的稀疏变化窗口，本文统称事件窗口，并在第 2 章区分目标侧标签事件与冻结规则触发。此类窗口不同于可提前获知的节假日或特殊日[14-17]：其发生可事后标记，预测时行为字段的可获取时点仍须核验。少量高误差样本易被大量稳定样本稀释，仅报告全局平均误差难以揭示其误差水平和总量贡献。因此，本文依次检验站内关系的预测增量、解释诊断证据，并界定区间与运行使用条件。

1.2 国内外研究现状

1.2.1 电动汽车充电负荷时间序列预测

电动汽车充电负荷预测已形成从统计方法、机器学习到深度学习和组合预测的方法谱系。相关综述总结了数据来源、影响因素、预测尺度和模型类型[2-4,18-19]。经典统计方法以 ARIMA 及其扩展模型为代表，具有结构清晰、参数含义明确等优点，适用于趋势和周期相对稳定的序列，但其线性与平稳性假设难以充分描述用户行为驱动的非线性波动。以 LightGBM[20]和 XGBoost[21]为代表的集成学习方法能够利用多维人工特征刻画非线性映射，在中小规模数据上具有训练效率优势，但对长时间依赖的利用通常依赖显式滞后特征和特征工程。

随着深度学习在时序预测中的应用，LSTM[22]、GRU[23]、时间卷积网络[24]和 Transformer[25]成为充电负荷建模的重要基础。相关研究通过双向循环网络、卷积—循环组合、注意力机制和 Transformer 结构增强时序特征提取能力[7,26-30]；另一些工作将分时电价、气象条件、用户意愿和多源交互信息纳入模型输入，以

提高对外部扰动的响应能力[5,11,29,31]。针对负荷序列的非平稳性，分解—预测—重构和误差修正也被广泛用于降低不同频段或不同状态下的预测误差[32-35]。此外，区间预测开始用于表达点预测之外的不确定性[36]，表明评价目标正由单一平均误差逐步扩展至风险和可靠性刻画。

近年来，相关研究还从多时间尺度深度学习、规模化行为建模、半监督学习、场景聚类和在线辨识等路径细化充电负荷预测[37-41]。从行为变量的利用看，已有工作将实时出行需求、引导策略、排队与 SOC、路网拥堵和用户决策更新纳入区域或站群预测[42-46]。这些工作扩展了不同时间尺度与运行状态下的预测思路，但其图节点多数并非同一场站内部的充电节点；相关行为信息的可见性、时效性也与本文站内规则触发并不相同。

总体而言，现有时间序列方法为充电负荷预测提供了较成熟的建模工具，但研究对象仍以站级或区域聚合序列为主。对站内单个充电节点而言，负荷零值比例更高、节点间差异更强，单序列模型难以直接利用其他节点提供的横向信息。同时，许多工作主要报告全局预测指标，对模型收益来源及高误差窗口的表现讨论有限。这些特点促使研究进一步从单序列预测转向多节点关系建模与分层评价。

1.2.2 多节点负荷与时空图预测

图神经网络为多节点时序预测提供了统一的关系建模框架。GCN[47]通过邻接矩阵上的特征传播聚合邻居信息，GAT[48]进一步以注意力机制学习邻居贡献，RGCN[49]则将消息传递扩展至多关系场景。在时空预测领域，STGCN[50]将图卷积与时间卷积结合，Graph WaveNet[51]通过自适应邻接和扩张卷积联合学习空间与时间依赖，AGCRN[52]使用节点自适应参数和可学习图结构刻画节点异质性。这些方法最初主要用于交通流预测[53-55]，随后被引入居民负荷、区域负荷和多节点短期负荷预测[56-63]。

EV 充电负荷预测中亦可见站群多图、区域负荷与概率建模等研究[6,8,64-70]。表 1-1 比较直接 EV 近邻[12,13,67,70,76]及站间图[10]、住宅图方法[71]，并标明证据来源和字段核验边界。

表 1-1　充电负荷预测及方法近邻研究比较

文献	节点粒度与关系来源	模型路径	已报告的验证范围及本文比较边界
黄健等[13]	以城市充电站为节点，按地域分布描述站间关系	原文摘要: GCN 提取站点及邻站空间依赖，将各时刻表征输入 LSTM 作时间预测	官方期刊摘要及已核查的第 59—64 页索引正文片段；对象是城市场站负荷，非单场站内节点。本文未从该文可核实数据划分、预测时输入到达时刻及参数共享细节，故不作跨文数值比较

文献	节点粒度与关系来源	模型路径	已报告的验证范围及本文比较边界
张延宇等[12]	可读摘要确认充电站负荷时空相关与自适应关联图；摘要未说明节点粒度及建边字段	多头注意力与自适应关联图提取表征，再以 Chebyshev 图卷积和多尺度时间卷积建模时空耦合	国家科技期刊平台可读摘要报告两个真实数据集及 Palo Alto 四种波动条件的结果；未据摘要外推输入可见性、数据划分或门控细节
黄南天等[10]	13 座公共充电站为节点；Rapid-MIC 特征与自适应动态图	AST-GCN 差异化空间聚合、节点自适应参数学习与 GRU	公开正文报告 13 站小时负荷和随机抽取 32 天, 并含动态图及节点参数模块消融；研究对象为站间负荷，模块删除消融不等同于冻结β参数干预
Xie 等[70]	城市充电站群；距离、交通网络与交通密度图	出版社全文索引说明采用 MGAT-MIC-LSTM, 融合多图、ResNet/GAT/LSTM 及天气、典型日、价格等因素	出版社页面的图构建与数据处理段报告西安 10 站、30 min 采样、2021 年 7—9 月；其节点是站群站点。全文可读范围未明确精确切分和预测时外生变量到达权限
Liang[76]	主要实验使用加工后的配电负荷代理；Boulder 扩展以公开交易记录重构 EV 负荷序列	PARC 以持续性预测为锚，使用预测时可用的滞后、滚动、爬坡和周期特征学习残差；在相同特征边界下比较直接预测与残差校正	出版社全文报告滚动起点、日块重采样及配对检验；Boulder 序列上持续性/季节混合在 sMAPE、正负荷 MAPE 较优, HistGBR 在 MAE、加权绝对百分比误差（WAPE）较优, PARC-ExtraTrees 在 RMSE、R^2较优。该文覆盖会话重构 EV 负荷预测，但未报告本文式站内关系替换重训或 MDP；两者不作数值排名
Feng 等[71]	住宅个体及聚合负荷为预测对象；自适应邻居与时间相似邻居构图	STGNet 以节点特定 GCN 提取空间表示, 经自适应图门控融合后接 BiGRU	原文§4.1.1、§4.1.3 及§5.5（表 3—5）报告节点特定参数化、图分支消融；含三套真实数据及 15 户设置。该研究可证明图门控和节点特异参数化已有先例，不能作为 EV 充电任务的同键对照
Huang 等[67]	Palo Alto、Boulder、韩国等站群数据；构造站间因果感知关系与关键站动态关系	作者稿§III（PDF 第 4—6 页）描述 CAGLM、CRGLM 及时间表示融合	作者稿§IV（第 7—8 页、表 II 起）报告 27/40/14 站、逐小时数据、72 h 输入、3/6/12 h 预测、7∶1∶2 切分及 5 次随机初始化；数据说明将会话起止与总电量按分钟分配后聚合为小时负荷，表明会话重构代理已有先例。其“因果感知”是模型构造术语，不等于外部因果识别；节点仍是站点

文献	节点粒度与关系来源	模型路径	已报告的验证范围及本文比较边界
Wang 等[72]	住宅用户为节点；Pearson 同步图与传递熵方向信息图	RLF-MGNN 逐时刻以多图 GCN 提取关系表征，再送入 LSTM 学习时间特征	出版社摘要可读，未据此核实完整建图细节、切分、容量或消融；住宅用户节点不同于场站内充电节点，传递熵图不等同物理因果拓扑
Zhang 等[73]	住宅用户为节点；构造时空融合图	STFAG-GCN 报告自适应门控图卷积（AFG-Conv）、门控 TCN 及多层 STFGCN 组合	PubMed 收录的原文摘要可读，未取得全文核实图构造、参数共享、切分和消融细节；因此仅作为方法结构先例，不作数值比较

表 1-1 显示，已有研究覆盖站间图预测、住宅用户图门控，也包括会话交易重构 EV 负荷后的直接与残差预测[12-13,67,70-73,76]。因此，本文不把一般 EV 代理负荷预测、图卷积、多关系融合或门控时序模型组合视为研究空白或算法首创。与近邻[76]相比，本文关注的问题更窄：在单场站会话重构代理任务中，站内统计关系相对自环替换是否具有条件增量，以及参数干预、受检学生和误差分层分别能改变哪些研究判断。当前结果支持两类关系的条件性整体增量，第三类仍不确定；尚未证明诊断指导改模可提升预测。节点粒度、目标和评价协议不同，不作跨文数值排名。

1.2.3 充电行为特征与事件建模

用户接入、离站、停留和充电需求是充电负荷波动的直接行为来源，现有研究通常将其与历史负荷、日期、气象和价格等变量一并送入时序模型[5,7,9,11,26,31]。针对可提前获知的特殊日期，已有研究通过节假日增长率修正、春节影响期划分、日期映射和特殊事件组合模型改善预测[14-17]。这类方法利用已知日历信息，其对象仍不同于运行中临时出现的接入、离站与负荷跳变。

在非日历事件方面，已有研究关注事件数据与极端误差[74]，并提出风险时段识别及选择性残差修正[75-76]。近邻[76]的会话代理重构与残差预测比较见表 1-1。本节关注事件定义、信息可见时点和阈值确定：须避免测试期信息进入判定，并分别评价事件与常态样本。

本文据此区分目标侧标签事件与冻结规则触发：前者用于事后分层评价，后者用于回溯规则路由和诊断。冻结阈值不等于输入实时可见，旧规则中的代理负荷差分仍依赖会话最终字段。事件窗口兼作评价与误差溯源单元；本文不预设事件机制必然改善点预测，而是检验双口径分层的差异及事件窗口的区间表现。

1.2.4 模型可解释性与机制诊断

负荷预测模型的解释研究主要包括外部归因和内部信号分析两类路径。外部

归因通常利用 SHAP[77]等方法衡量输入特征对预测结果的贡献；内部分析则通过注意力权重、门控值或隐状态可视化理解模型的表示过程[62,78]。这类方法能够提供直观线索，但观察到较大的权重并不必然意味着对应组件具有决定性功能。注意力权重与模型实际决策路径之间可能存在偏离[79]，能源预测领域的可解释性综述也指出，解释结果仍需要进一步的稳定性和有效性验证[80]。

误差价值分析提供了另一条相关路径。Guastavino 等[81]针对二分类事件预测提出价值加权技能评分，按误报、漏报与事件时序赋予不同价值；本文处理的是连续代理负荷的预测误差，不设置运营代价权重，而用事件标签与规则触发的四格统计还原误差构成。该分解描述样本数和绝对误差分布，不代表错误的实际经济或运行价值。

本文围绕单场站节点代理负荷，将受控预测比较与机制诊断结合：同参数重训练检验节点门控和关系邻接增量，MDP 分别检验联合配置敏感度、受检学生替代表现和误差构成。其贡献由这些任务内证据支撑，相关工具的既有来源见前述文献。

1.3 现有研究不足

现有研究已覆盖会话重构 EV 负荷的残差预测[76]、站间关系建模和住宅用户图门控。本文因此将研究缺口限定为：在会话重构的站内节点代理负荷任务中，哪些统计关系相对自环具有可复核的条件增量，以及参数干预、替代学生和误差分层能够支持何种机制判断。围绕这一范围，本文回答三个相互关联的问题。

（1）如何表示并检验站内节点差异。多类统计关系可刻画负荷同步、行为共现和轮廓相似，但关系图本身不保证预测增益，关系融合与节点差异门控的作用须在明确协议下比较。

（2）如何区分观察信号、功能依赖和性能增量。门控权重描述参数分配，冻结替换检验既有配置的敏感度，蒸馏检验特定学生设置的替代尝试；三者回答的问题不同，均不能单独确立因果机制。整体误差还须拆至事件与稳定窗口，以说明改进发生于哪些样本。

（3）如何界定行为信息和可靠性结论。目标侧事件标签、回溯规则与预测时可见行为输入的信息条件不同。代理负荷中的零值和稀有高误差窗口要求分别报告总体误差与事件表现，否则事后分层或全局均值都可能掩盖模型的适用边界。

上述三项研究问题及其与相关研究方向的对应关系见图 1-1。

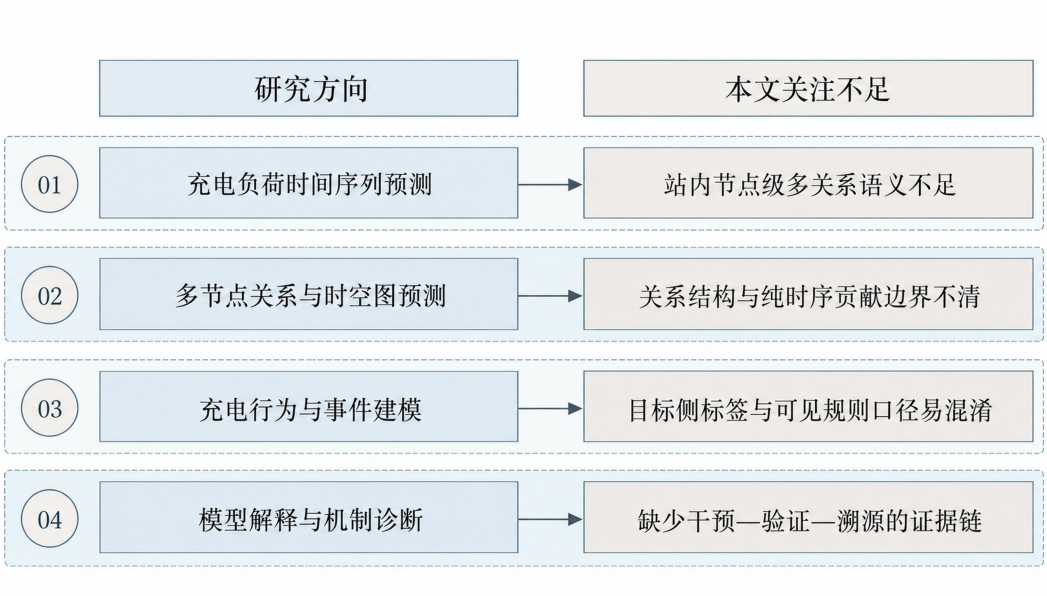


图 1-1 研究方向与本文关注不足的对应关系

注：从时间序列预测、多节点关系建模、行为事件建模和机制解释四个方向，归纳本文所关注的站内节点关系语义、结构贡献边界、双事件口径和诊断证据链问题。

1.4 研究目标与主要内容

本文以 MRG-GCN 为验证载体，检验站内关系与节点差异门控的预测增量，并以 MDP 区分模型依赖和误差构成。主要发现是：在 JPL 所检设置下，负荷耦合与轮廓相似关系相对自环具有条件性整体增量，行为共现关系仍不确定；完整模型的整体优势未延伸至非零目标组。本文据此区分组件价值、模型排序与诊断判断，主要研究内容如下。

（1）数据与协议。审计会话字段和节点标识，重构 15 min 节点代理负荷，明确输入可见时点、标签成熟条件和时间切分；分析稀疏性与节点异质性，为关系构建和分层评价提供依据。

（2）预测与受控增量。构建负荷—行为—轮廓关系编码（LRE）三关系图，由 MRG-GCN 融合时间表示与关系消息；在 Caltech 事件时刻和 JPL 重拟合协议中比较节点级与共享门控，在 JPL 逐一以自环替换关系邻接，在 Caltech 改用完成时刻截断目标重训。分别检验整体表现、组件增量和目标敏感性，并以非零组和事件组约束总体结论。

（3）机制诊断。以 L1 的冻结β替换及重参数化分析、L2 的受检时序学生蒸馏和 L3 的事件—规则四格分解，区分联合配置依赖、特定替代尝试与误差来源，并在 JPL 既有检查点上事后复核 L1/L3；据此修订关系解释、学生替代结论和分层报告重点。诊断指导改模的收益尚待检验。

（4）可靠性与使用条件。开展方向性候选筛查、独立校准与成熟标签滚动

回放，并用固定预测轨迹和合成约束例检查运行接口。结果按代理目标、固定测试期和计量材料边界解释；场站间比较限于 ACN 同源、时期重叠的重新拟合任务。

1.5 技术路线

图 1-2 概括本文主线与补充验证。

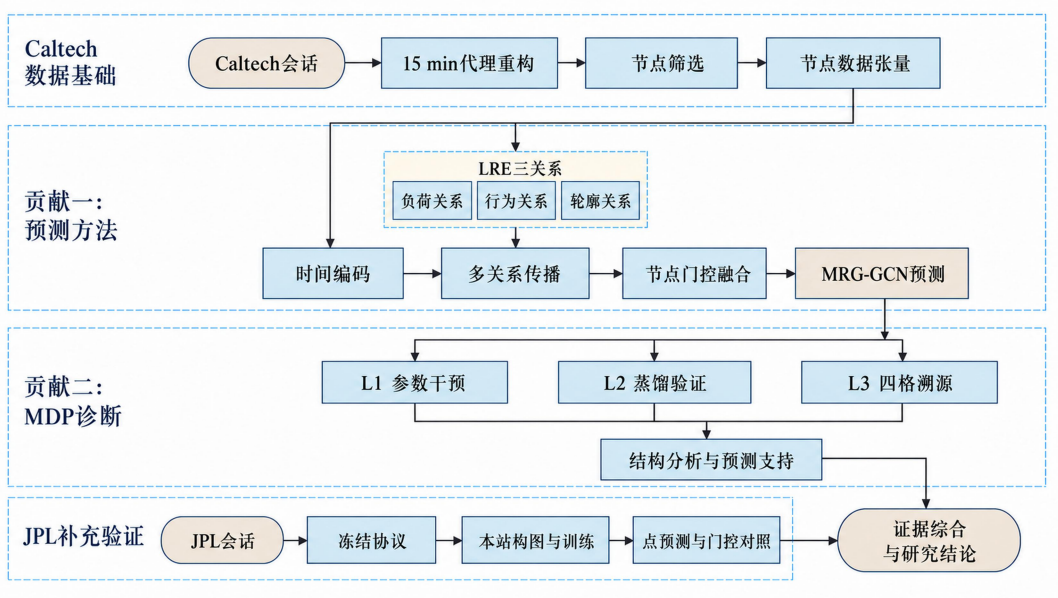


图 1-2 本文总体技术路线与双贡献主线

注：Caltech 主线完成代理序列重构、LRE 构图、MRG-GCN 预测及 MDP 诊断；JPL 重新筛选节点、构图和训练，补充点预测与门控比较。固定测试期的关系替换、目标敏感性及 JPL 既有检查点复核分别见 3.7.2、3.8.4 和 4.6 节。

第一阶段审计会话字段、时间和节点标识，重构 15 min 节点代理负荷，依训练集和验证集筛选 10 个节点，为构图和分层评价提供数据。

第二阶段以训练期统计量构建并稀疏化三类 LRE 关系图，经 TCN 和双层多关系门控图卷积预测未来 1 h 的四个目标片；以统一预测键和指标比较已登记基线及组件变体。部分文献方法仅用于定位，未重跑。

第三阶段以 MDP 检查冻结β替换、当前 TCN 学生蒸馏和事件—规则四格误差，分别形成参数敏感度、受检替代性及误差构成判断。

第四阶段筛查方向性统计候选，评价分层区间覆盖，并通过固定预测轨迹和合成线性规划定义运行核查接口，界定后续验证条件。

1.6 论文组织结构

本文正文由五章组成，正文之后为结论和参考文献。各章按“界定任务—检

验预测—解释证据—分析适用条件”展开。

第 1 章界定研究对象, 梳理相关工作, 提出研究问题、主要贡献和技术路线。

第 2 章说明 Caltech 和 JPL 数据、代理目标重构、节点筛选及时间划分，归纳数据特征对建模与评价的约束。

第 3 章介绍 LRE 关系图与 MRG-GCN, 报告 Caltech 和 JPL 的协议内模型比较、组件对照及目标敏感性。

第 4 章通过 MDP 分析参数敏感度、受检学生替代表现和四格误差构成，并以 JPL 既有产物事后复核 L1 与 L3。

第 5 章分析方向性候选、Caltech 与 JPL 区间可靠性和预测支持接口，界定应用验证条件。

结论归纳受控增量证据和 MDP 引起的研究判断, 汇总适用条件与后续工作。事件残差修正与预警比较属于已终止探索，不列为贡献。

1.7 本章小结

本章将研究问题归纳为站内关系预测、组件增量辨识和分层诊断。后续章节依次完成数据与时点定义、受控预测比较、诊断判断及可靠性分析，重点考察总体收益是否延伸至非零目标与事件样本。

第 2 章　充电行为数据与特征分析

本章回答两个问题：充电会话记录如何转化为可建模的节点序列，以及该序列的统计特征如何约束模型与评价。研究对象不是在线电表连续功率，而是由离散会话重构的节点代理负荷。下文依次说明数据来源与重构口径、节点筛选和质量门禁，再分析负荷稀疏性、节点异质性、周期性、事件窗口及特征相关性，并据此确定多关系图建模和分层评价要求。

2.1 数据来源与重构口径

本文采用公开的 ACN-Data 电动汽车充电数据集。该数据集由加州理工学院发布，记录会话接入、断开、充电完成时间和总交付电量等信息[82]。本文下载使用 siteID=2 的单场站会话归档，含 31,424 条记录和 11 个字段，不包含连续电流量测；这不意味着 ACN-Data 接口本身不提供电流序列。接入时间从 2018 年 4 月 25 日 11:08:04 延续至 2021 年 9 月 14 日 1:52:37，最晚断开时间为 2021 年 9 月 14 日 3:05:10，覆盖约 3.39 年。接入与断开时间全部可解析，充电完成时间可解析 29,369 条；完成时间不是式（2-1）主目标重构所需字段，其缺失不影响该主目标的时间片能量分配。

原始数据只给出会话总交付电量, 不包含可直接用于节点级短期预测的连续功率序列。本文以 15 min 为固定时间间隔，将每条会话的总交付电量均匀分配至该会话从接入时刻到断开时刻所覆盖的全部时间片。设第s条会话的总交付电量为E_s，所属节点为i_s，覆盖的 15 min 时间片集合为$\mathcal{B}_s$，则节点i在时间片t上的节点代理负荷定义为

$$y_{t,i} = \sum_{s:i_s=i,t\in\mathcal{B}_s} \frac{E_s}{|\mathcal{B}_s|}. \tag{2-1}$$

式中，$|\mathcal{B}_s|$为会话覆盖的时间片数。同一节点同一时间片若有多条会话，则对其分摊电量求和。由此形成 2018 年 4 月 25 日 11:00 至 2021 年 9 月 14 日 3:15 的规则时间网格，共 118,818 个时间步；相邻时间戳间隔均为 15 min，无缺步。本文将$y_{t,i}$记作“节点代理负荷”，单位写作 kWh/15 min，表示每个 15 min 离散时间片内由会话总电量分摊得到的电能量。该量不是瞬时功率或电表实测功率，也不用于还原时间片内部的真实充电曲线。

分摊的数值一致性与实际充电过程的真实性需要分别核查。10 个主分析节点 11,085 条会话的交付电量合计 92,650.017 kWh，与全部节点代理时间片的电量之和一致，逐节点守恒差均小于10^{-8} kWh。这说明电量分配没有造成总量丢失，但不能证明分配时刻正确。若车辆完成充电后继续保持连接，当前方法仍向这一停留区间分配电量；每条会话的实际功率起伏也被均匀分摊所替代，可能平

滑尖峰或改变峰值时刻。2.1.2 节通过完成时刻和有限电流样本进一步核查这种时间形态差异；预测误差仍只相对于式（2-1）的代理目标定义。

节点标识审计显示，原始数据的场站字段 siteID 只有 1 个取值（2），该场站内包含 55 个候选充电节点。设备字段 stationID、EVSEID 与 spaceID 均有 55 个唯一值且不存在缺失, 其中 stationID 与 EVSEID 逐行一致, stationID 到 spaceID 为一对一映射。由此可知，stationID 在该数据接口中是设备标识而非场站数量字段。本文统一使用 spaceID 作为节点标识，并以 CA-303 等编号表示站内空间充电单元；该标识不被解释为独立的配电网母线或物理拓扑节点。后续关系图的边仅描述节点负荷与充电行为的统计联系，而非站内配电线路的电气连接。

如图 2-1 所示, 原始会话记录依次转换为模型输入张量。旧协议的节点选择、目标与特征 z-score 统计以及规则触发阈值分别由训练期或验证期确定，但上游占用率分母采用全时期节点最大活跃数, 负荷跳变标记采用全时期正差分的 90% 分位数。因此，不能把后续训练期标准化概括为全部预处理与测试时期隔离。数据来源、时间跨度和关键审计结果汇总于表 2-1。

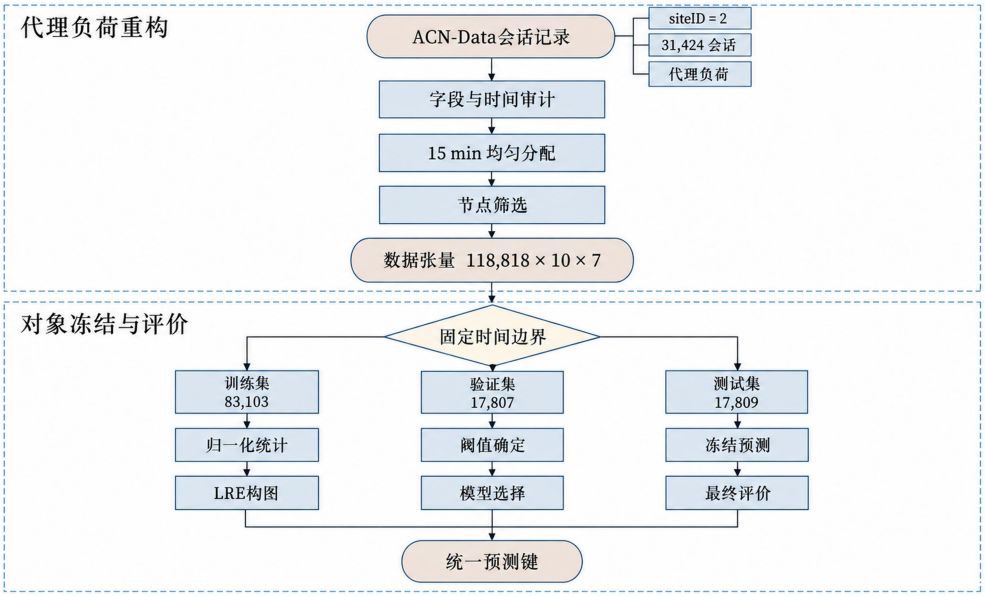


图 2-1　数据重构与数据划分流程

注：原始归档含 31,424 条会话；10 个主分析节点对应 11,085 条会话，均匀分配至覆盖的 15 min 时间片以形成节点代理负荷。节点筛选、z-score 参数和冻结触发阈值分别由训练期或验证期确定；旧上游占用率分母与跳变标记阈值另使用全时期统计，范围见 2.1.1 节。本图不表示在线电表功率测量。

表 2-1　原始数据形态与审计结果

项目	审计结果	口径说明
数据形态	ACN-Data 中 siteID=2 的充电会话记录	本文使用的归档不含连续电流或电表功率序列
原始记录数	31,424 条	共 11 个字段
候选节点数	55 个	统一以 spaceID 标识
原始接入时间范围	2018-04-25 11:08:04—2021-09-14 01:52:37	最晚断开时间为 2021-09-14 03:05:10

项目	审计结果	口径说明
重构时间网格	2018-04-25 11:00—2021-09-14 03:15	共 118,818 个时间步
采样间隔	15 min	118,817 个相邻间隔均一致
节点代理负荷单位	kWh/15 min	表示时间片分摊电量，不是瞬时功率
标识映射	stationID=EVSEID，且与 spaceID 一一对应	三者均为设备标识；场站字段为 siteID
时间字段解析	接入、断开各 31,424 条；充电完成 29,369 条	重构使用接入、断开与总交付电量

2.1.1 三套评估协议的任务边界

三套协议使用 15 min 规则时间网格。时间戳s_k表示第k片的左端；预测输入含索引$k-95$至k的 96 片，最后一片为$[s_k, s_k+15min)$。其结束时刻$\tau_o = s_k + 15min$为预测发布时刻。四个目标依次为$k+1$至$k+4$片，片起点相对发布时刻为 0、15、30 和 45 min，覆盖$[\tau_o, \tau_o+60min)$。因此首个目标片从发布时刻开始，四片共同覆盖未来 1 h。行为计数按片末可见处理，但原始归档没有上报到达时间戳，通信延迟和丢失率未核验；目标代理标签可能在后续会话结束后才成熟。

Caltech 回溯协议（SG-DATA-005）在固定节点、时间切分和统一预测键上，比较不同模型在事后均摊代理序列上的预测及诊断结果。历史片值由会话最终交付电量和断开时间构造；在发布时刻仍未结束的会话，其最终字段可能尚未确定。因此，历史窗口时间戳早于发布时刻，并不足以证明片值当时可获得。该协议支持事后重构序列上的离线回溯比较，0.01376 kWh/15 min 及相应基线降幅均按这一任务解释。旧上游全时期统计的处理范围见 2.1 节。

Caltech 事件时刻协议（SG-DATA-006-eventtime-v1）以接入、离站、活跃计数和当地日历编码为输入，移除旧代理负荷及其派生特征，目标仍为事后会话能量代理。计数特征按片末可见的假设构造；因此该协议收紧了输入字段权限，但不代表行为上报延迟已验证。现有 SG-EXP-019 的 36 次运行及同参数门控对照分别见 3.6.2 和 3.7.1 节。该协议与 Caltech 回溯协议的输入、切分和测试键不同，误差应在各自协议内解释。

Caltech 事件时刻协议沿用旧筛选的 10 个节点，并要求训练、调参、校准和测试的完整窗口留段；测试时期仍已查看。旧回溯协议则存在边界跨段：训练与验证各有 4 个原点的目标窗口跨段，验证与测试各有 95 个原点的历史窗口进入前一段。使用过去历史本身不等于未来泄漏，但旧划分不满足完整窗口留段约定。JPL 独立筛选节点并采用四段留窗，定义见 2.1.3 节。三套协议的回答范围见表 2-2。

表 2-2 三套数据与评价协议的回答范围

协议	预测时输入	目标与评价	主要回答的问题	不支持的结论
Caltech 回溯协议 (SG-DATA-005)	旧代理负荷及其派生通道、行为通道	事后重构代理负荷；共同测试键	离线回溯口径下 MRG-GCN 相对时间和图基线的表现及机制诊断	在线可执行精度、实测功率等价性
Caltech 事件时刻协议 (SG-DATA-006-eventtime-v1)	接入、离站、活跃计数及当地日历编码	仍为事后代理目标；完整窗口留段	片末可见假设下行为输入的相对价值与协议敏感性	与回溯协议 MAE 直接合并、证明实际上报无延迟或证明实测部署性能
JPL 重拟合协议 (SG-DATA-007-JPL)	JPL 接入、离站、活跃计数及当地日历编码	JPL 会话总电量的事后均匀分摊代理；独立场站四段留窗	在同属 ACN 体系的另一场站独立筛选节点、构图和训练后，核验整体 MAE 及节点级门控相对共享门控的差异能否重现	零样本迁移、未来时期或不同数据家族泛化、实测功率精度及真实运行收益

2.1.2 分摊支持范围与实测形态核查

为检验均摊终点的影响，先核对 10 节点的充电完成时刻。11,085 条会话中，10,399 条的完成时刻位于接入与断开之间，420 条缺失，266 条不满足这一顺序条件。合法记录从完成充电到断开的停留时间中位数为 62.67 min。6,967 条会话在完成之后仍包含完整 15 min 时间片，原分摊规则向这些片分配了 28,403.239 kWh，占 10 节点总交付电量的 30.66%。

该比例描述单会话分摊超出记录充电完成时刻的范围，不代表节点实测误差、模型 MAE 偏差或预测输入可见性风险；多个会话的重叠也使它不能直接说明节点在相应片内没有充电。

仅当 connectionTime <= doneChargingTime <= disconnectTime 时，才以充电完成时刻替代断开时刻作为分摊终点；完成时刻缺失或不满足该区间条件时，回退至 disconnectTime。替代重构与原重构的总电量均为 92,650.017 kWh，最大逐节点守恒差为 4.91×10^{-10} kWh，但对应节点时间片的平均绝对差为 0.0477816 kWh/15 min。该值只表示同一批会话在两种标签分配规则下的逐节点时间片平均绝对差，不是模型误差、真实负荷不确定度上限，也不与模型 MAE 作大小比较。

SG-EXP-032 随后在 Caltech 事件时刻协议的固定测试键上使用这一替代目标重新训练预测模型；预测输入、原图、切分和起点键保持不变，仅依替代目标的新训练前缀重算目标标准化参数。该敏感性结果见 3.8.4 节。

完成时刻也不是连续功率测量，不能将替代序列认定为真实负荷。

此外, 利用 ACN-Data 公开历史静态快照[82-83]核查同一节点会话的电流形态。固定主 10 节点各一个 2018 年 5 月正电量会话的匹配清单, 其中 8 条通过电流非负、时间递增、首末覆盖误差和采样间隔门禁，CA-315 与 CA-327 的两条记录因零积分或长采样间隙未通过。CA-303 试探样本在固定完整清单前已查看，因此该组属于探索性便利样本，不能代表全站或独立确认数据。

对通过门禁的 8 条记录，以分段左常数积分计算各 15 min 片的电流积分，再除以该会话积分总量，得到无量纲片份额，与原等片份额比较。两种份额分布的总变差距离为 0.0645 ~ 0.5957，实际电流积分的最大片份额为均匀份额的 1.10 ~ 4.38 倍。这些读数表明部分会话的过程集中程度会被均摊压低。

由于所匹配记录的电压、功率列均缺失，电流积分未换算为 kWh，也不用于估计场站功率峰值或模型实测误差。完成时刻核查与电流形态检查共同说明：代理负荷保留能量总量, 但对充电过程作了近似。原始归档仍缺事件接收时间戳，采样间隔门禁不能代替实际通信延迟验证。

另以 EPFL Level-3 两 CCS 端口记录作探索性形态参照[84]。以端口及会话首末时间连接，不以电量或跨表会话编号作键，1,878 条会话全部一一匹配；经连续一分钟覆盖、非负功率与正能量等检查后，1,620 条时长不少于 15 min 的会话纳入, 258 条短会话排除。将表内 P 字段作梯形积分, 以会话接入为锚分为 15 min 片，并与按时长均匀分配的电量各自归一化，总变差距离中位数为 0.0736，四分位数为 0.0308、0.1276。

P 积分与会话电量之比中位数为 1.1492，累计电量首末差与会话电量之比为 0.9943，计量边界尚不明确。该核查描述外部直流快充记录中的形态差异；其会话锚定分箱、按时长分配口径也不同于本文固定时钟等片目标，不能据此校准 ACN 标签或评价模型实测精度。

2.1.3 JPL 另一场站数据与验证口径

为检验模型比较能否在另一充电场站重现，本文依据 ACN 官方 JPL 普通会话数据建立独立的训练与评价张量[82]。全量必要元数据包含 33,638 条会话，stationID 和 spaceID 各有 52 个唯一值并稳定一一映射；记录接入时间覆盖 2018 年 9 月 5 日至 2021 年 9 月 14 日。根据训练边界前已成熟会话筛选 10 个车位节点（AG-1F08、AG-1F10、AG-1F06、AG-1F13、AG-1F02、AG-1F04、AG-1F01、AG-1F12、AG-1F07、AG-1F03），涉及 11,041 条会话。连续 UTC 15 min 网格共 106,096 个时间片，按时间顺序分为训练 70%、调参 7.5%、独立校准 7.5%和测试 15%，合法预测原点分别为 74,168、7,826、7,828 和 15,816；每个 96 片历史窗与 4 片目标窗均完整留在所属分段内。

JPL 输入只含接入数、离站数、活跃数和当地日历编码，不含由未来最终电

量构造的历史代理负荷。目标仍将会话总电量均匀分配至接入至断开所覆盖的时间片，单位为 kWh/15 min；零会话时间格表示无已记录会话贡献，不证明设备在线或实际需求为零。完成时间缺失 2,037 条，另有 3,211 条完成时间落在接入—断开区间之外；标签成熟时刻保守取断开时间与非空完成时间的较晚者，输入事件时刻不随之改变。2020 年 9—10 月没有会话记录，未据此删去时间段。JPL 与 Caltech 会话键、设备和车位标识无交集，但同属 ACN 数据体系且年份重叠。因此，本节对应另一场站重新筛选、构图和训练的比较，不是零样本迁移、不同数据家族或未来时期验证；两站标签也都不是连续电表功率。

JPL 验证流程汇总见图 2-13，点预测比较结果见 3.6.3 节。

2.2 节点可用性筛选与质量门禁

55 个候选节点的记录密度差异较大。为减少近乎无活动序列造成的估计不稳定性，本文在训练前固定主分析与敏感性分析两级筛选门槛。节点入选只依据训练集和验证集，测试集仅标记后续可评价性。

数据按时间顺序划分为训练集、验证集和测试集，预测原点数量分别为 83,103、17,807 和 17,809，占比约为 70%、15%和 15%。原点索引所对应的最后输入片左端时间戳范围依次为 2018 年 4 月 26 日 10:45 至 2020 年 9 月 8 日 2:15、2020 年 9 月 8 日 2:30 至 2021 年 3 月 12 日 14:00，以及 2021 年 3 月 12 日 14:15 至 2021 年 9 月 14 日 2:15；按 2.1.1 节定义，实际发布时刻为这些时间戳各加 15 min。三部分时间连续、互斥且顺序固定；按日历月份计，训练、验证和测试阶段分别涉及 30、7 和 7 个自然月，其中各段首尾月份并非完整月份。

节点筛选从会话活跃度、时间覆盖和负荷稳定性三个方面设置六项条件，具体门槛见表 2-3。主分析门槛要求训练期接入事件不少于 100 次、验证期不少于 10 次，训练期非零负荷时间片不少于 200 片，训练期和验证期活跃月份比例均不低于 0.50，且训练期月度能量变异系数不高于 2.5。较宽松门槛另生成 15 节点敏感性候选集合，目前只核验筛选覆盖，尚未完成该集合的模型重训练，不能据此证明预测结论对节点范围稳健。按主分析门槛，验证期接入事件数和活跃月份比例分别使 44 个和 42 个候选节点未通过，这两项条件是节点减少的主要原因；训练期各条件造成的未通过数量相对较少。

表 2-3 节点筛选门槛及主分析条件下的未通过数量

筛选条件	主分析门槛	敏感性门槛	主分析条件下未通过节点数
训练期接入事件数	≥100 次	≥40 次	7
验证期接入事件数	≥10 次	≥5 次	44
训练期非零负荷时间片数	≥200 片	≥80 片	2
训练期活跃月份比例	≥0.50	≥0.25	7
验证期活跃月份比例	≥0.50	≥0.25	42
训练期月度能量变异系数	≤2.5	≤3.5	2

六项条件联合筛选后，55 个候选节点中有 10 个进入主分析集合，且均可在测试期评价；敏感性候选集合包含这 10 个节点及另外 5 个节点，共 15 个，其中 14 个在测试期可评价。图 2-2 展示各候选节点在训练、验证和测试阶段的活跃月份比例以及筛选归属。图中测试期覆盖仅描述冻结节点集合的后续可评价性，并未反向参与筛选，也不代表 15 节点预测实验已完成。

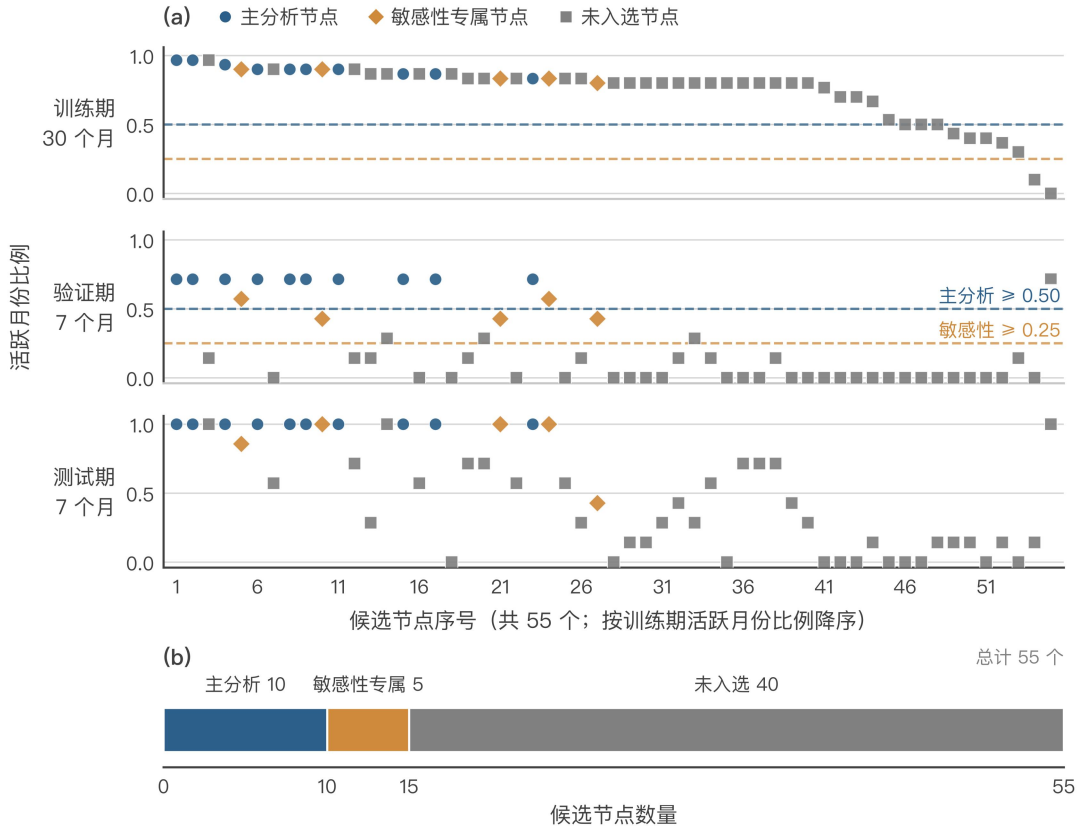


图 2-2 候选节点覆盖率与筛选结果

注：（a）55 个候选节点在训练、验证和测试阶段的活跃月份比例，横向参考线给出主分析门槛 0.50 和敏感性门槛 0.25；（b）主分析节点、敏感性专属节点和未入选节点的筛选结果。按日历月份计，三个阶段分别涉及 30、7 和 7 个自然月，首尾月份可能不完整。节点清单只依据训练期与验证期统计量冻结，测试期覆盖率仅用于可评价性检查。该图为全量描述性统计，不含抽样误差棒。

除节点筛选外，本文还检查了时间片数量、时间戳间隔、标识映射、张量维

度、时间划分连续性与互斥性、节点顺序以及测试边界等数据质量条件，9 项门禁均通过。上述检查保证了进入后续实验的数据在时间轴和节点轴上一致，但并不把统计筛选结果解释为物理充电设施的完备清单。

2.3 节点负荷统计特征

主分析集合由 CA-303、CA-304、CA-305、CA-307、CA-311、CA-315、CA-317、CA-321、CA-327 和 CA-489 共 10 个节点组成。对 118,818 个时间步、10 个节点的节点代理负荷进行统计，全量样本均值为 0.0780 kWh/15 min，标准差为 0.2186 kWh/15 min，最大值为 2.9671 kWh/15 min；非零样本占 21.59%，即零值约占 78.41%。在后续模型使用的测试集预测键上，非零目标占 12.75%，零值约占 87.25%。因此，该数据同时具有大量零值和非零部分长尾波动两种特征。

连续四周的节点负荷热力图如图 2-3 所示。各节点按累计负荷排序，并按节点自身最大值归一化以突出时间结构；右侧条带表示同期累计负荷的相对规模。稀疏负荷片段主要随日内时段成组出现，不同节点的活跃程度和持续模式并不一致。图 2-4 进一步展示三个代表性节点的自相关函数，在 96 片和 672 片滞后位置附近均出现局部峰值，分别对应 24 h 和 168 h 周期。由于数据中存在大量并列零值，这些图形用于描述周期性线索，不据此作平稳性或因果判断。

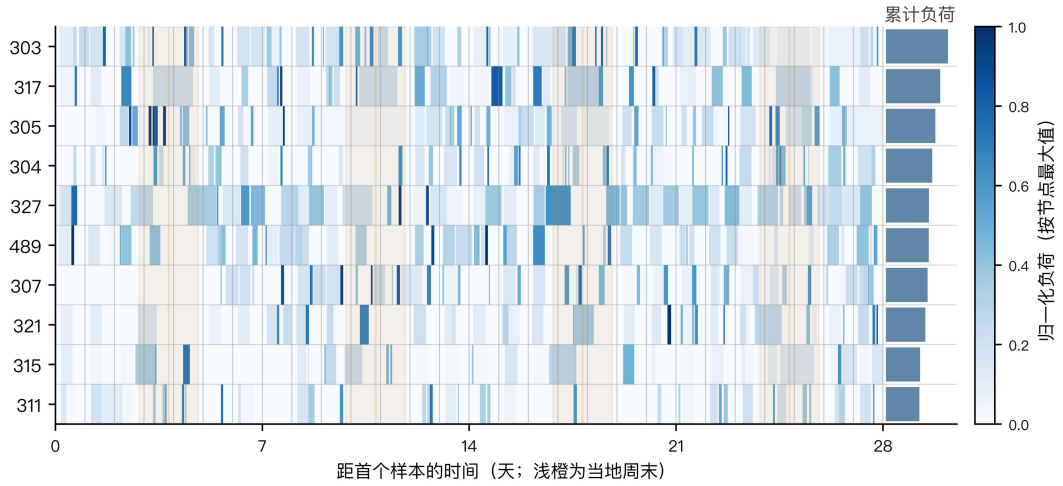


图 2-3　连续四周节点负荷热力图

注：颜色表示各节点相对于自身最大负荷的归一化值，节点自上而下按同期累计负荷降序排列，右侧条带表示同期累计负荷的相对规模。横轴为距首个样本的时间，周末底纹按 America/Los_Angeles 当地日历对齐。图中使用所示四周的完整时间片，不含误差棒，节点排序不表示物理拓扑。

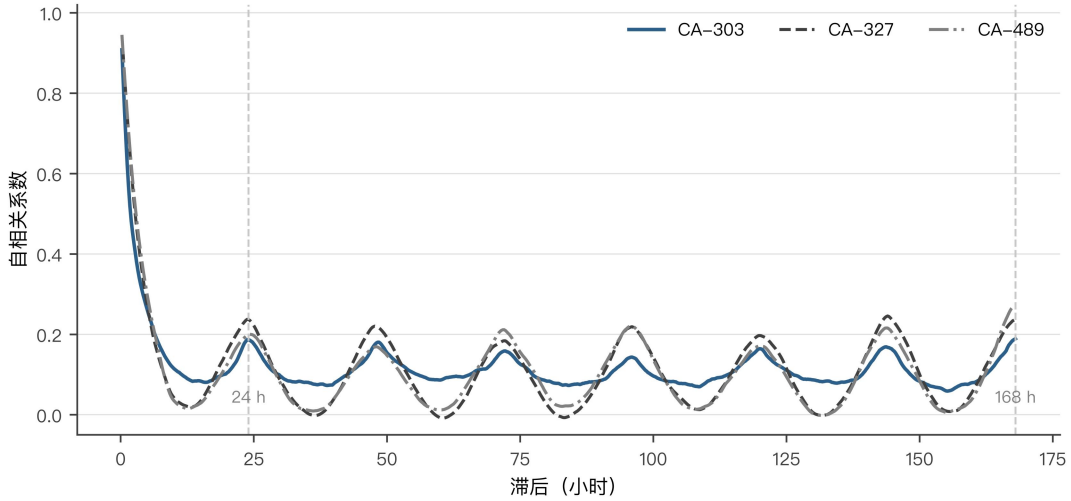


图 2-4 代表性节点代理负荷的自相关函数

注：展示 CA-303、CA-327 和 CA-489 在不同滞后片数下的样本自相关，虚线标示 96 片（24 h）和 672 片（168 h）。三节点在两个周期位置均呈正相关，但相关系数约为 0.19～0.27，因此仅说明日、周滞后具有可利用的统计依赖，不表示强确定性周期。

由表2-4可见，节点间存在明显异质性。CA-303 的均值为 0.1323 kWh/15 min、非零率为 31.45%，均为主分析节点中的较高水平；CA-321 的均值最低，为 0.0562 kWh/15 min；CA-311 的非零率最低，为 14.62%。最高与最低非零率相差超过 2 倍，最高与最低均值约相差 2.35 倍。峰均比则介于约 22.4 和 44.4 之间，说明低平均负荷节点也可能出现相对突出的局部峰值。该差异提示模型训练与误差分析应保留节点维度，避免仅用全站聚合量掩盖节点表现。

表 2-4 主分析节点代理负荷统计

节点	均值 /(kWh/15 min)	非零率/%	最大值 /(kWh/15 min)	标准差 /(kWh/15 min)	峰均比
CA-303	0.1323	31.45	2.967	0.2885	22.4
CA-304	0.0650	15.84	2.747	0.2188	42.2
CA-305	0.1078	27.40	2.849	0.2585	26.4
CA-307	0.0798	19.09	2.663	0.2332	33.4
CA-311	0.0614	14.62	2.725	0.2059	44.4
CA-315	0.0684	21.27	2.803	0.1968	41.0
CA-317	0.0724	21.33	2.241	0.2071	30.9
CA-321	0.0562	17.89	1.983	0.1662	35.3
CA-327	0.0735	27.46	1.761	0.1856	24.0
CA-489	0.0629	19.54	2.350	0.1852	37.3

三个代表性节点在日、周滞后位置的自相关系数列于表 2-5。

表 2-5 代表性节点日、周滞后自相关系数

节点	96 片（24 h）	672 片（168 h）
CA-303	0.187	0.189
CA-327	0.237	0.236
CA-489	0.200	0.273

三个代表性节点的日内起伏和工作日—周末差异见图 2-5，非零节点代理负荷的经验分布见图 2-6。后者使用对数纵轴，仍可观察到随负荷增大而逐渐变稀

的右尾。两图与表 2-4 共同说明：多数时间片没有充电活动，但发生充电时的幅度和持续模式具有较大差异。

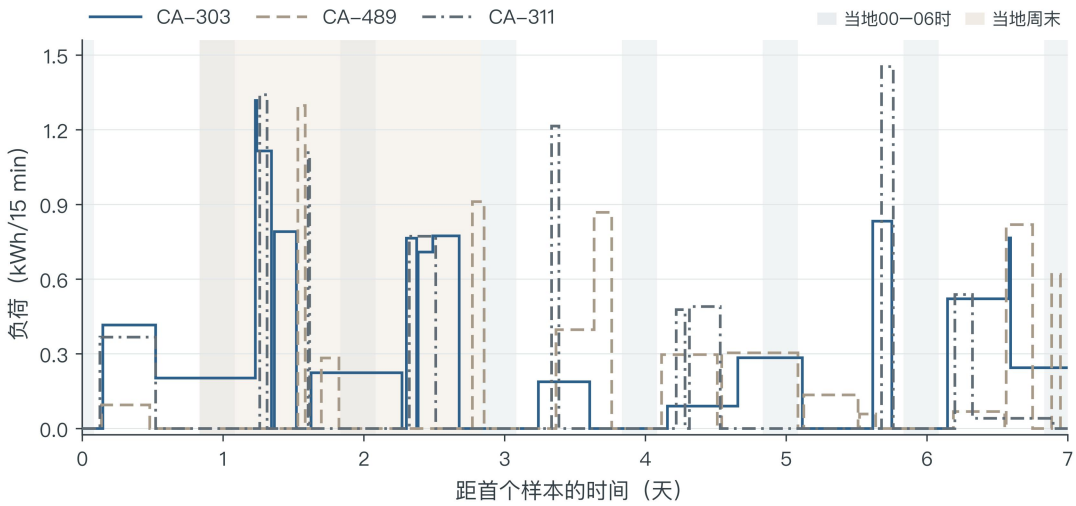


图 2-5　代表性节点典型周负荷曲线

注：曲线为 CA-303、CA-489 和 CA-311 自第 2,880 个时间片起连续 7 日的实际代理负荷序列，并非跨周聚合均值。横轴为距该段首个样本的时间；浅灰表示当地 00—06 时，浅橙表示当地周末，时区为 America/Los_Angeles。图中不含误差棒，用于描述所选时段的节点差异，不代表全年平均节律。

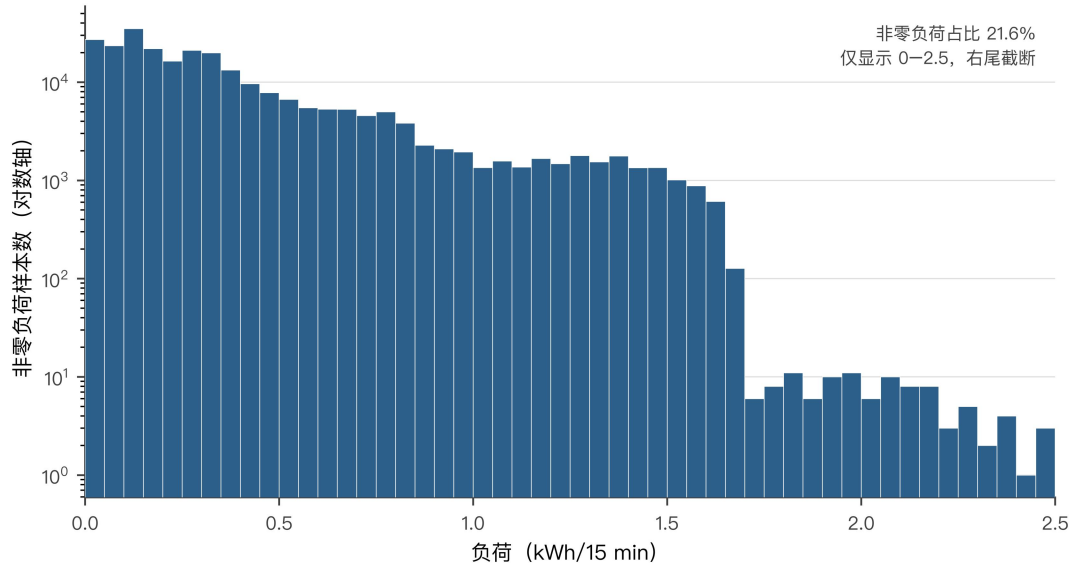


图 2-6　非零节点代理负荷经验分布

注：统计对象为 10 个主分析节点全时段的非零节点代理负荷，横轴单位为 kWh/15 min，纵轴采用对数刻度以展示低频右尾。图中为完整样本的经验频数，不含误差棒；横轴显示范围用于突出主要分布区域，不改变表 2-4 中的全量最大值统计。

2.4　事件分数构成与事件窗口统计

为描述会话接入、离站、活跃状态突变和负荷突变共同形成的短时行为变化，本文构造节点级规则事件分数。设节点i在时间片t的新接入数、离站数、活跃会话数和节点代理负荷分别为$a_{t,i}$、$d_{t,i}$、$c_{t,i}$和$y_{t,i}$，相应分量的训练期标准差为$\sigma_{a,i}$、

$\sigma_{d,i}$、$\sigma_{\Delta c,i}$和$\sigma_{\Delta y,i}$，则事件分数定义为

$$q_{t,i}=\frac{a_{t,i}}{max\,(\sigma_{a,i},\varepsilon)}+\frac{d_{t,i}}{max\,(\sigma_{d,i},\varepsilon)}+\frac{|c_{t,i}-c_{t-1,i}|}{max\,(\sigma_{\Delta c,i},\varepsilon)}+\frac{|y_{t,i}-y_{t-1,i}|}{max\,(\sigma_{\Delta y,i},\varepsilon)},\tag{2-2}$$

式中，ε为防止分母为零的极小常数。四个标准差均按节点在训练集上计算，使不同活跃度节点和不同量纲的行为分量能够在同一规则中比较。对于每个节点，在验证集非零事件分数上取 95%分位数作为阈值；超过阈值的时间片记为规则触发点，并只向未来扩展 2 个时间片。阈值和扩展规则一经确定便保持不变，测试集不参与阈值估计，相邻或重叠的触发窗口合并为连续窗口。该规则属于含事后代理负荷差分的回溯诊断，不解释为发布时刻可用的在线触发。完整生成流程见图 2-7。

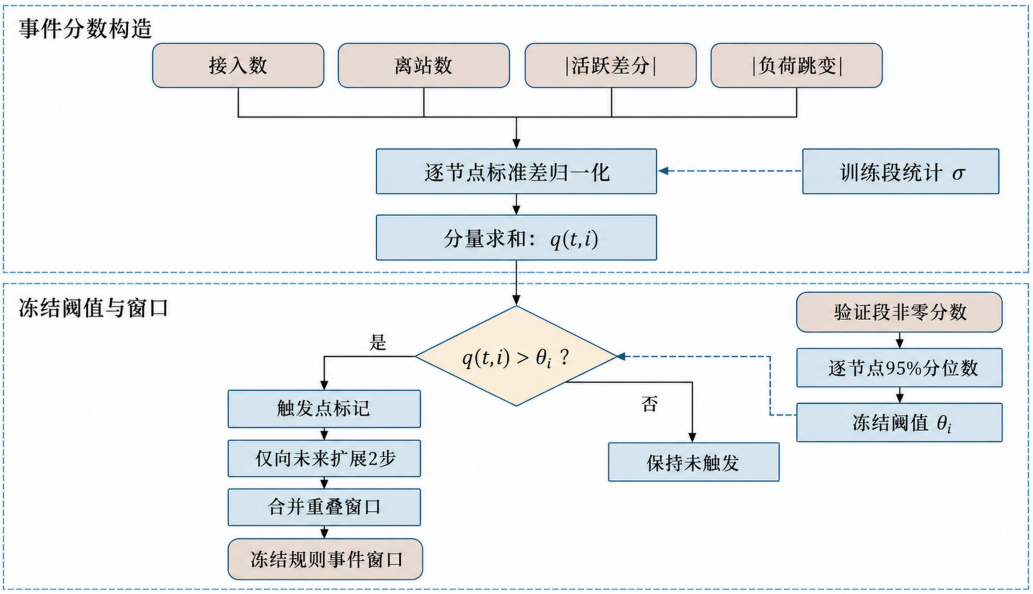


图 2-7 事件分数与冻结规则事件窗口生成流程

注：接入、离站、活跃变化和负荷变化四个分量经逐节点标准差归一化后求和，采用验证集 95%分位阈值触发，并仅向未来扩展 2 个时间片。标准差来自训练集，测试集不参与阈值估计。

标签事件时间步的日内分布见图 2-8，事件并非在一天内均匀出现。图 2-9 展示冻结规则窗口中四个标准化分量的节点平均贡献。该图描述旧回溯规则分数的构成，负荷变化分量仍依赖事后重构，不表示实时行为识别或分量对预测误差的因果贡献。

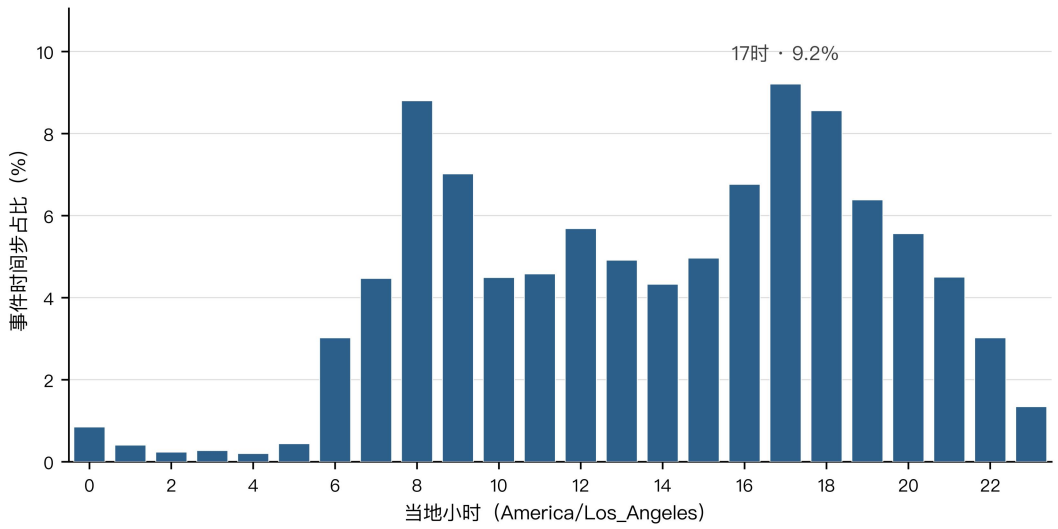


图 2-8 标签事件时间步的日内分布

注：在全部 118,818 个时间步中，将任一主分析节点具有目标侧事件标签的时间步按 America/Los_Angeles 当地小时汇总；柱高表示该小时事件时间步数占全部事件时间步数的比例，峰值标记由同一统计数组计算。该图不区分事件类型，柱高也不是分类准确率或条件事件概率；全量描述性统计不含误差棒。

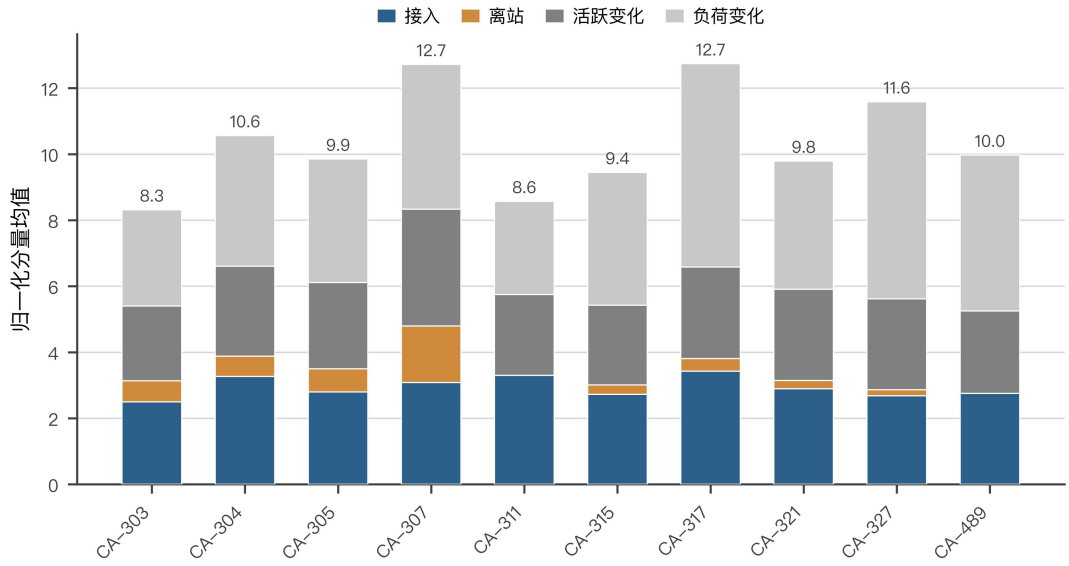


图 2-9 冻结规则事件窗口的分量构成

注：对测试集冻结规则事件窗口内的接入、离站、活跃变化和负荷变化四个标准化分量按节点取平均。事件窗口包含原始阈值触发点及其向未来扩展的两个时间片；阈值由验证集冻结，测试集仅执行规则。图中为完整窗口样本的描述性均值，不含误差棒。

事件统计必须区分“目标侧标签事件”和“冻结规则触发”两种口径。内部字段 target_event 由未来 4 个目标片中的接入、离站或负荷突变标签定义，直接作用于形状为$[S, H, N]$的预测评价键；它是按目标侧观测构造的事后评价标签，不是人工核验的现实事件真值。测试集中共有 10,160 个标签事件样本，占 712,360 个预测键的 1.426%，约为 1.43%。旧字段 rule_trigger 取每个预测原点对应的回溯规则状态，原始形状为$[S, N]$，在四格诊断和规则路由时广播到 4 个目标片；测

试集中共有 3,060 个触发预测键，占 0.430%，约为 0.43%。该状态依赖事后代理负荷差分，不能解释为发布时刻可用的触发信息。前者用于评价模型在标签事件窗口上的误差，后者用于第 4 章四格诊断和第 5 章冻结规则路由。两者定义和信息时点不同，但广播后的上述比例具有相同预测键分母；不得把原始节点—起点数与广播后预测键数直接混算，定义与用途对照见图 2-10。

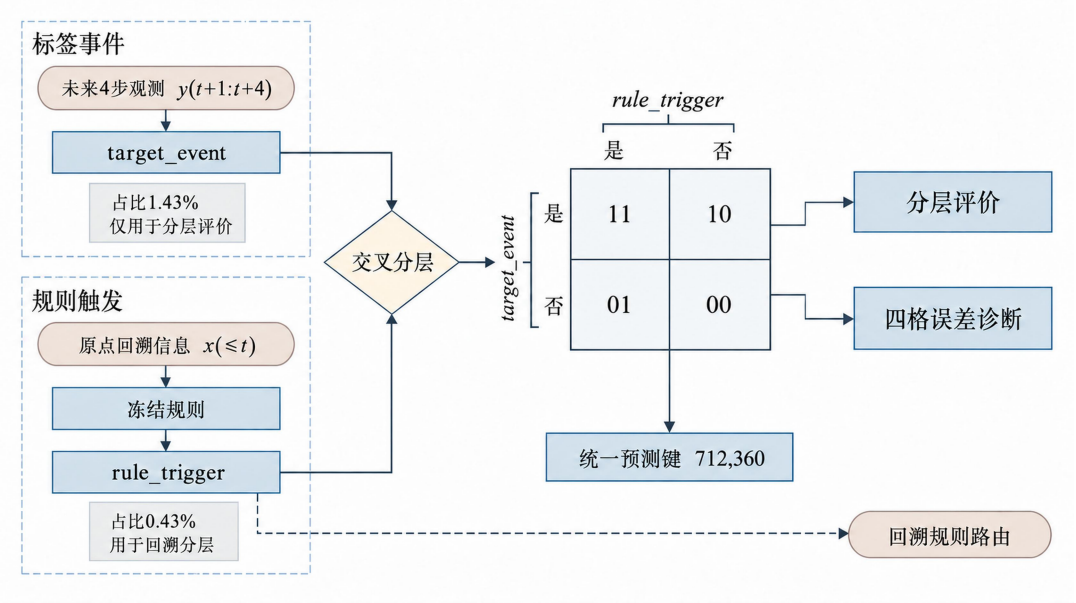


图 2-10 标签事件与冻结规则触发的双口径对比

注：target_event 用于事后评价，旧 rule_trigger 用于回溯分层及规则路由；两者共同定义四格诊断，标签事件不进入规则路由。原始张量分别为[S,H,N]与[S,N]，后者广播到各目标片后，1.43%和 0.43%均以 712,360 个测试预测键为分母。旧标签的负荷跳变阈值采用全时期统计，旧规则含事后重构负荷差分，均不能解释为实时事件识别效果。

逐节点验证统计见表 2-6。验证集非零事件分数占比为 0.20%～1.06%，冻结阈值为 18.9～32.5；原始触发点占节点时间片的 0.011%～0.056%，向未来扩展后占 0.034%～0.168%。在测试集上，规则共产生 254 个连续窗口，其中 253 个长度为 3 个时间片，1 个因相邻触发合并为 6 个时间片。

表 2-6 逐节点冻结规则事件统计

节点	验证集非零分数占比/%	冻结阈值	验证集触发点占比/%	验证集前向窗口占比/%
CA-303	0.82	18.9	0.045	0.135
CA-304	0.37	22.7	0.022	0.067
CA-305	0.61	25.5	0.034	0.101
CA-307	0.27	29.2	0.017	0.051
CA-311	0.79	23.5	0.045	0.135
CA-315	0.20	22.1	0.011	0.034
CA-317	0.25	32.5	0.017	0.051
CA-321	1.06	22.4	0.056	0.168
CA-327	1.04	27.7	0.056	0.168
CA-489	0.44	24.5	0.022	0.067

规则在训练、验证和测试三个数据段内分别执行，因此每段最前面的两个预测起点不会继承上一数据段的触发状态。该处理避免跨划分传递信息，最多影响

测试评价键中的 80 个位置，即 2 个起点×4 个目标片×10 个节点，占 712,360 个测试预测键的约 0.011%，属于保守的边界处理。

2.5 特征构成与协议输入

以下表 2-7 描述的是 Caltech 回溯协议（SG-DATA-005）的七项输入：节点代理负荷、新接入会话数、离站会话数、活跃会话数、占用率、需求强度和负荷突变标志。其中，节点代理负荷、活跃会话数、占用率和需求强度的非零率均为 21.59%; 接入和离站计数的非零率约为 0.93%, 负荷突变标志的非零率约为 0.14%。需求强度在当前处理中与节点代理负荷取值一致, 活跃会话数与占用率之间也存在确定的比例联系，故这些变量是状态的相关表征，不应被视为相互独立的信息源。

表 2-7 Caltech 回溯协议输入特征的全量描述性统计

特征	含义	非零率/%	均值	最大值
load	节点代理负荷	21.589	0.0780	2.9671
access_count	新接入会话数	0.933	0.0093	2
departure_count	离站会话数	0.933	0.0093	2
active_count	活跃会话数	21.589	0.2164	2
occupancy_rate	占用率	21.589	0.1082	1
demand_intensity	需求强度	21.589	0.0780	2.9671
load_jump_flag	负荷突变标志	0.135	0.0014	1

7 项特征在全部时间步和节点上展平后的 Spearman 秩相关系数见图 2-11。Spearman 秩相关用于描述单调关联，不要求变量服从正态分布或满足线性关系；但本数据存在大量并列零值，因此系数仅作描述性比较。节点代理负荷、活跃会话数、占用率和需求强度之间相关程度较高，而三项稀疏事件特征与主体状态特征的相关程度相对较低。这一结果说明输入同时包含状态表征冗余和低频行为信号，后续需要通过模型对比和消融而非仅凭相关矩阵判断各特征的预测作用。

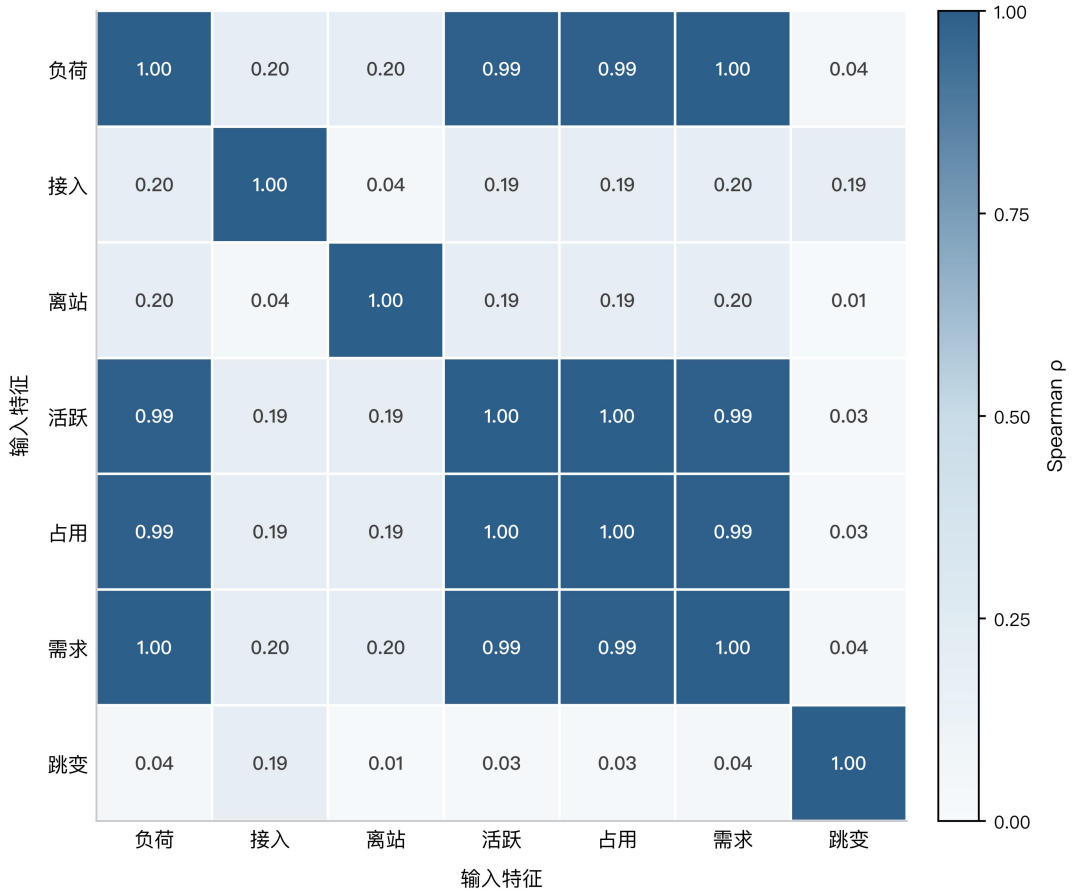


图 2-11 输入特征 Spearman 秩相关矩阵

注：相关系数由 118,818 个时间步、10 个主分析节点的 7 维特征展平计算，颜色和单元格数字共同表示相关方向与大小。该图为全量描述性统计，不含误差棒；大量零值造成并列秩，因而不将相关系数解释为独立贡献或因果关系。

按星期和小时聚合 10 个节点代理负荷所得结果见图 2-12。不同星期类别在白天和晚间呈现不同的负荷强度，周末与工作日的分布也有差异，与 2.3 节的自相关结果相互印证。后续模型据此选取连续 96 片、即完整 24 h 的历史信息作为基本输入窗口，并通过图结构补充同一时段节点之间的统计联系。

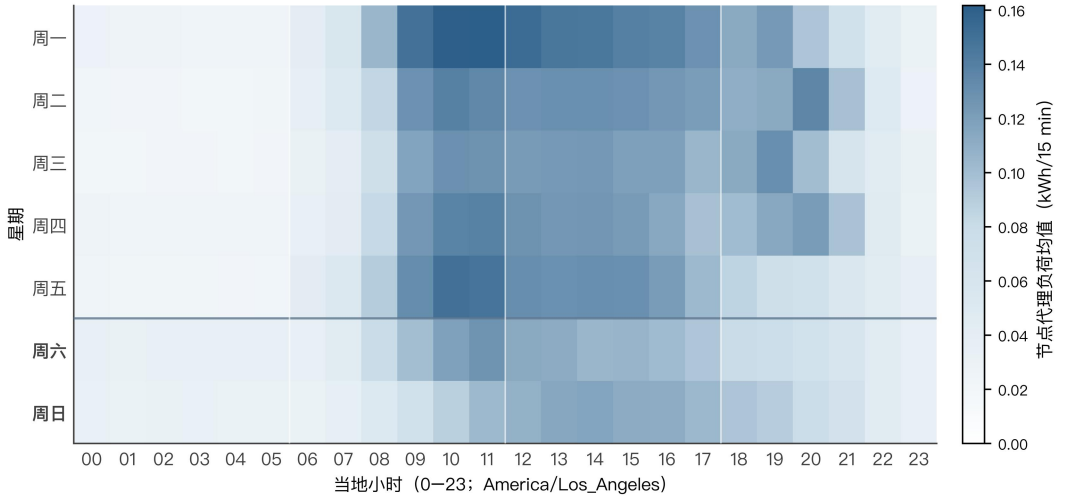


图 2-12　全站节点代理负荷的星期—小时聚合热力图

注：每个单元格为 10 个主分析节点在对应当地星期和小时上的平均节点代理负荷，并非节点负荷之和；时区为 America/Los_Angeles。色阶覆盖完整聚合值范围，周末以分隔线区分。该图由全时段样本直接聚合，不含误差棒，颜色不表示事件发生概率。

该回溯协议的模型输入形状为 $96 \times 10 \times 7$，输出为 4×10。归一化参数仅由训练集估计，验证集和测试集沿用冻结参数。严格事件时刻协议虽然也是 7 通道，但语义完全不同：只含 access_count、departure_count、active_count 及当地小时、星期的正余弦编码，不含 load、demand_intensity、occupancy_rate 或 load_jump_flag。它仍使用 96 片历史与 4 片代理目标，时间边界统一按 2.1.1 节定义；不得因张量形状相同而将旧输入、检查点或模型结果移入新协议。

2.6 数据特征对建模的启示

数据特征提出四项建模要求。其一，零值与长尾并存，宜使用 MAE、RMSE 和 WAPE，并分别评价事件、稳定和非零样本。其二，节点异质性与多类统计联系为 LRE 构图提供动机，但其有效性须由消融检验。其三，标签事件与规则触发错位，需用四格诊断及区间覆盖分别分析。其四，状态特征相关、行为信号稀疏，故保留 7 维统一输入，不凭相关矩阵直接删除特征或主张预测贡献。

JPL 补充实验将这些建模要求落实为固定的数据与评价协议（图 2-13）。行为输入和回顾性目标分别构造，节点筛选仅使用训练边界前已成熟的记录，标准化参数与 LRE 关系图仅由训练段拟合。调参集用于选择检查点，所有检查点锁定后，各运行才导出一次测试预测；整体与分层比较使用共同的预测键。

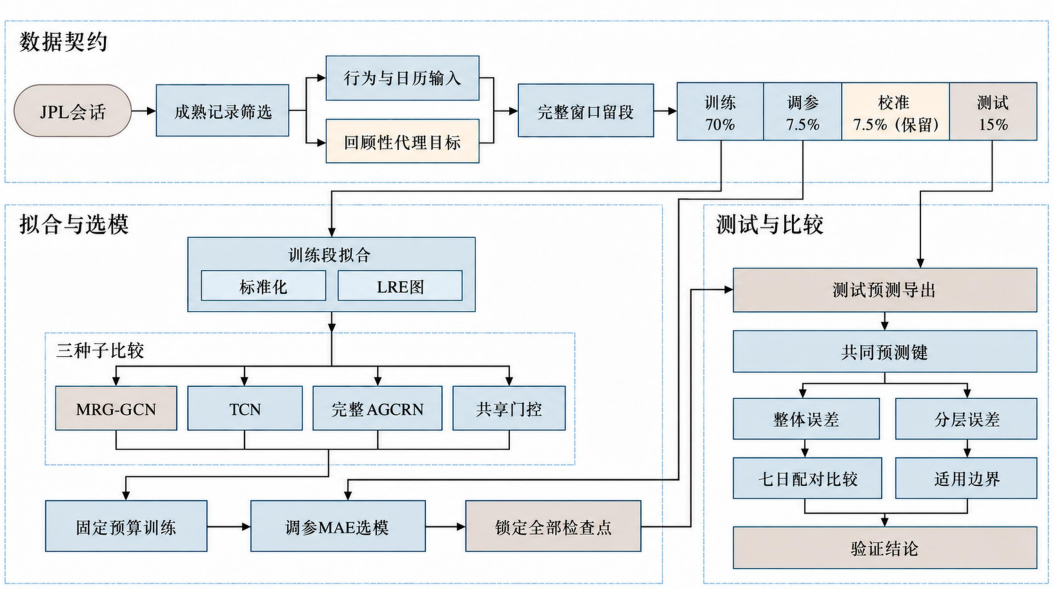


图 2-13 JPL 固定协议重新拟合验证流程

注：输入为接入、离站、活跃计数及当地日历编码，假定行为计数在所属时间片结束时可见；实际接收延迟未核实。目标为会话电量在接入至断开区间内均匀分摊的代理能量。训练、调参、校准和测试按时间分段，96 片历史窗与 4 片目标窗完整留段，目标片起点按 2.1.1 节统一口径解释。四种模型各运行三个种子，以调参集原单位 MAE 选择检查点；全部检查点锁定后，每次训练运行仅导出一次测试预测，在 632,640 个共同预测键上评价，整体 MAE 另按 24 个七日块进行配对比较。训练预算与早停规则见 3.6.3 节。校准段在预登记点预测比较时保留，后续独立区间评价见 5.3.5 节；该流程对应另一 ACN 场站的重新拟合验证。

2.7 本章小结

本章将覆盖约 3.39 年的 31,424 条会话重构为 118,818 步、55 个候选节点的 15 min 代理序列，筛选后的 10 个主节点涉及 11,085 条会话。六项筛选和九项质量门禁约束节点集合及张量一致性；旧上游全时期统计与跨段窗口的限制见 2.1.1 节。新协议另行收紧输入字段和窗口划分，代理目标仍须与电表功率区分。

统计分析表明，主分析节点的全量负荷零值约占 78%，测试预测键零值约占 87%，节点非零率和平均负荷均存在较大差异，并呈现日内与周内滞后依赖。事件分析进一步区分了目标侧标签事件与冻结规则触发：二者在测试预测键上分别占 1.43%和 0.43%，用于不同的评价与路由场景。7 维输入中，主体状态特征存在较高相关性，而接入、离站和负荷突变信号高度稀疏。

这些特征为下一章的 LRE 关系构建和分层评价提供依据。完成时刻截断目标的预测敏感性见 3.8.4 节；JPL 另按 2.1.3 节独立筛选节点、划分数据和建模，两站预测键不混合。

第 3 章　基于多关系门控图卷积的节点短期负荷预测

3.1 引言

第 2 章揭示了节点代理负荷的稀疏性、周期依赖和节点异质性，也表明站内节点存在多类统计联系。单节点时序模型无法直接聚合其他节点的信息，单一关系图又难以区分负荷耦合、行为共现和轮廓相似。为此，本章构建负荷—行为—轮廓关系编码（load–event–pattern relation encoding，LRE），并提出多关系门控图卷积网络（multi-relational gated graph convolutional network，MRG-GCN）。模型先由时间卷积网络编码历史信息，再以关系级权重和节点级门控完成两层图传播，最后融合不同深度的表示并输出未来 1 h 的节点代理负荷。

本章先定义任务、关系图与模型，再以 Caltech 事件时刻预测和 JPL 重拟合为主要比较，回溯结果为补充。随后分别报告同参数门控、关系邻接及其他组件对照，并综合训练预算和目标敏感性证据。三套协议的输入、切分与预测键不同，误差仅在各自协议内比较；完成时刻截断实验固定 Caltech 事件时刻协议的测试键。模型整体架构见图 3-1。

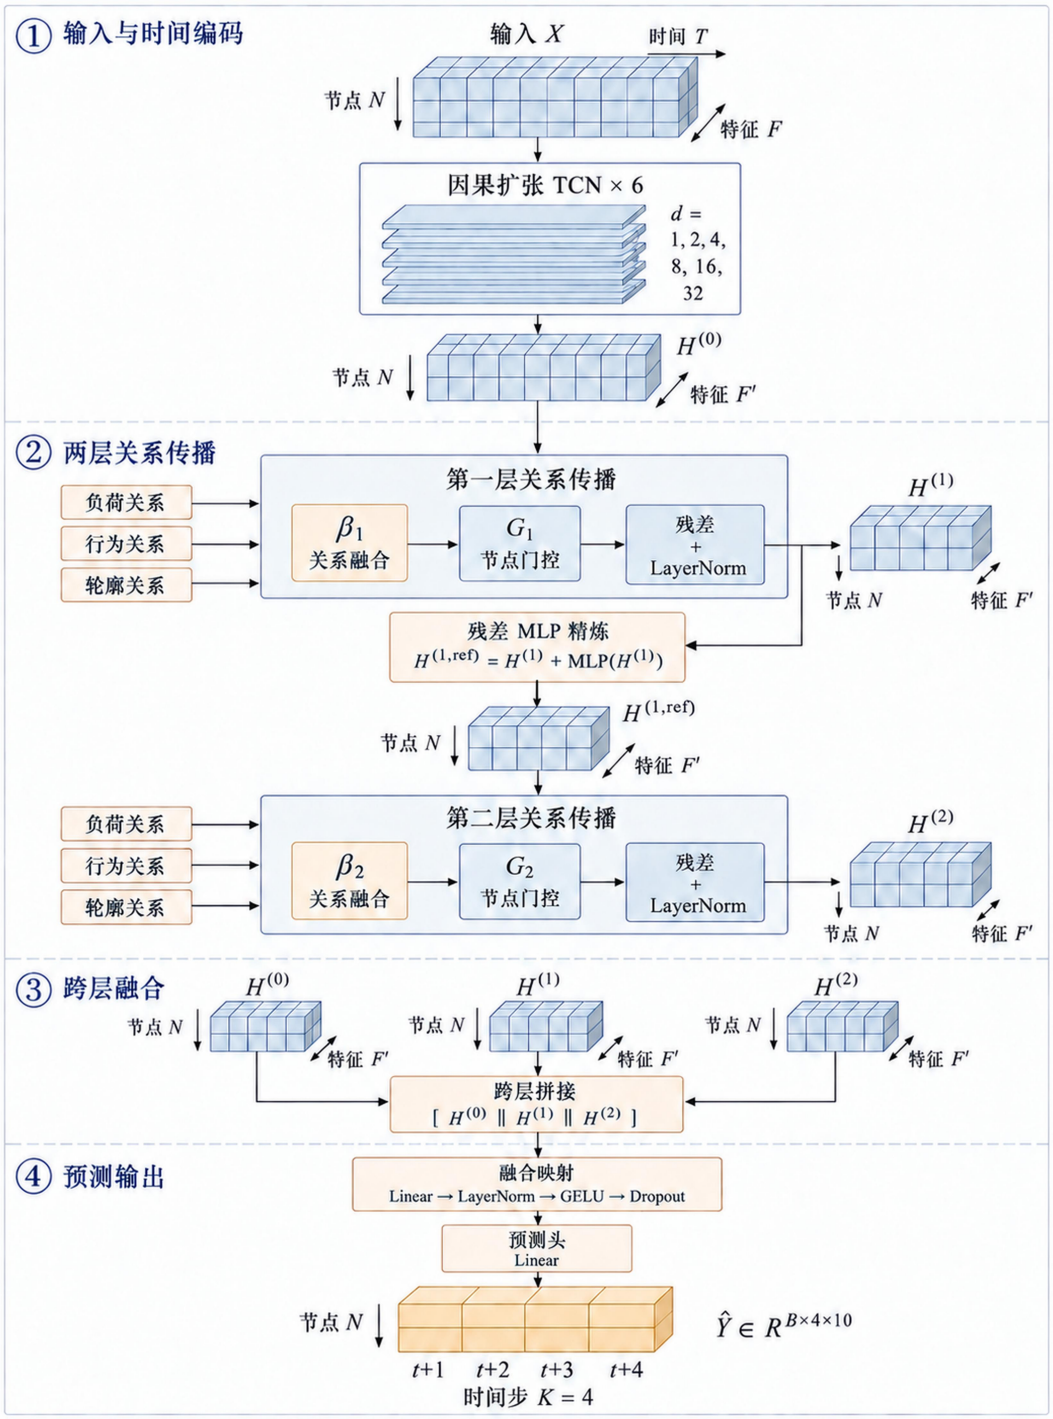


图 3-1 MRG-GCN 整体架构

注：历史输入依次经过因果扩张 TCN、第一层多关系传播、残差 MLP 精炼和第二层多关系传播。原始 $H^{(0)}$、$H^{(1)}$与 $H^{(2)}$经跨层拼接、融合映射和线性预测头输出未来 4 个连续 15 min 目标片的节点代理负荷，片起点按 2.1.1 节定义；精炼表示不直接参与跨层拼接。三类固定关系仅由训练集构建。分区中重复的状态符号指同一表示而非额外计算层；张量网格为示意，隐藏状态的实际形状均为[B,N,32]。

为避免在整体图中堆叠局部运算，图 3-2 单独展开多关系传播单元，图 3-3 补充时间编码与跨层融合路径；相关符号在 3.2 ~ 3.5 节依次定义。

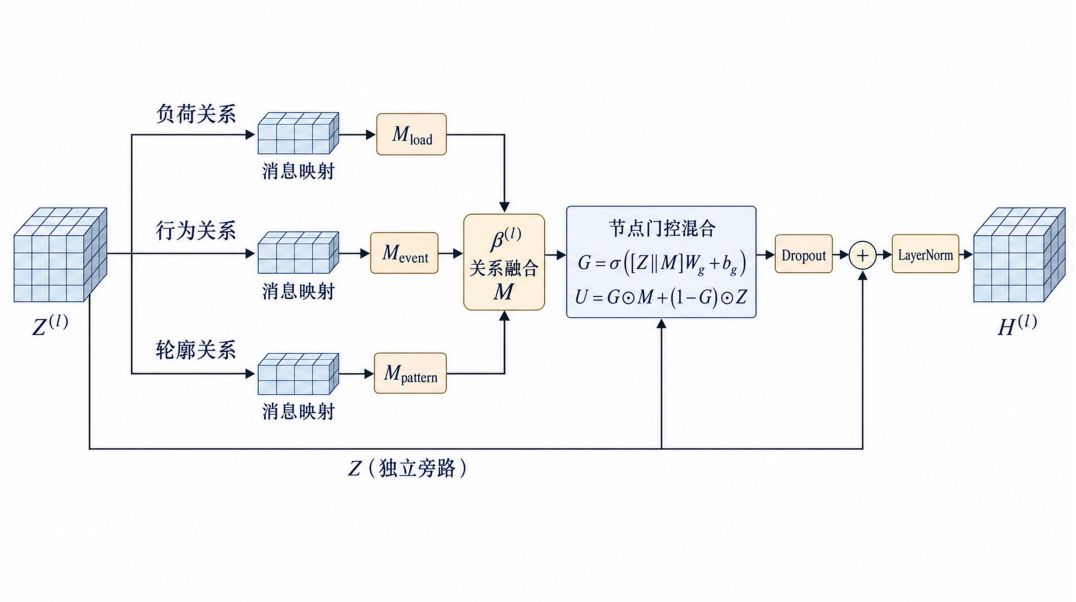


图 3-2　多关系门控传播单元

注：三类关系消息经关系级权重融合后，由节点级门控与该层实际输入混合，并通过残差连接与层归一化形成层输出。两层传播单元结构相同、参数独立；第二层实际输入为精炼表示$H^{(l,ref)}$。

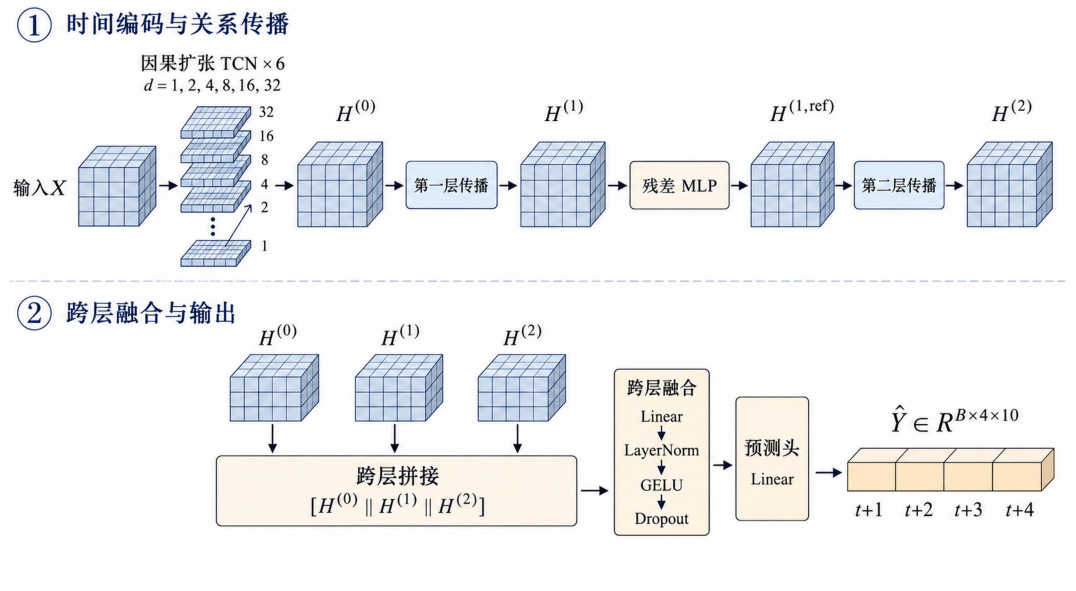


图 3-3　时间编码与跨层融合预测结构

注：上部展示时间编码与两层传播，下部以同名状态重复展示拼接输入，不表示新增模型分支。跨层融合使用原始$H^{(0)}$、$H^{(1)}$和$H^{(2)}$，经融合映射与线性预测头得到 4 个连续 15 min 目标片的输出；精炼状态$H^{(l,ref)}$仅作为第二层传播输入，目标片起点按 2.1.1 节定义。

3.2　预测任务形式化定义

设主分析节点集合为$\mathcal{V} = \{v_1, \ldots, v_N\}$，其中$N = 10$。令$s_k$为末个输入时间片的左端时间戳，时间片宽度$\Delta t = 15$ min，发布时刻为$\tau_o = s_k + \Delta t$。预测输入为索

引$k-95$至k的 96 片历史特征：

$$\mathbf{X}_o \in \mathbb{R}^{H\times N\times F},\ H=96,\ F=7, \tag{3-1}$$

预测目标为未来$P=4$个目标片的节点代理负荷：

$$\widehat{\mathbf{Y}}_o = f_\theta(\mathbf{X}_o, \mathcal{A}),\ \widehat{\mathbf{Y}}_o, \mathbf{Y}_o \in \mathbb{R}^{P\times N},\ P=4, \tag{3-2}$$

其中，$\mathcal{A}$为训练集构建的关系矩阵集合，f_θ为待学习模型。模型输出$P=4$个连续目标片，记为$\widehat{\mathbf{Y}}_o=(\widehat{y}_{k+1},\dots,\widehat{y}_{k+4})$，对应真实值$\mathbf{Y}_o=(y_{k+1},\dots,y_{k+4})$，共同覆盖$[\tau_o,\tau_o+60min)$；各片起点相对发布时刻依次为 0、15、30、45 min。输入覆盖发布前完整 24 h；“未来 1 h”指从发布时刻到第四片结束的覆盖范围，不表示首个目标片起点延后 15 min。每个评价单元由“协议—发布时刻—目标片编号—节点”唯一标识，所有同协议模型按共同预测键比较。标准化参数由训练集估计并冻结；标签事件 target_event 和规则触发 rule_trigger 不作为模型输入。

3.3 场景驱动的 LRE 三关系图构建

LRE 从训练期数据中构建负荷耦合、行为共现和轮廓相似三类无向统计关系。三类图使用相同节点集合，但刻画不同语义；测试数据不参与关系估计。构建与稀疏化流程见图 3-4。

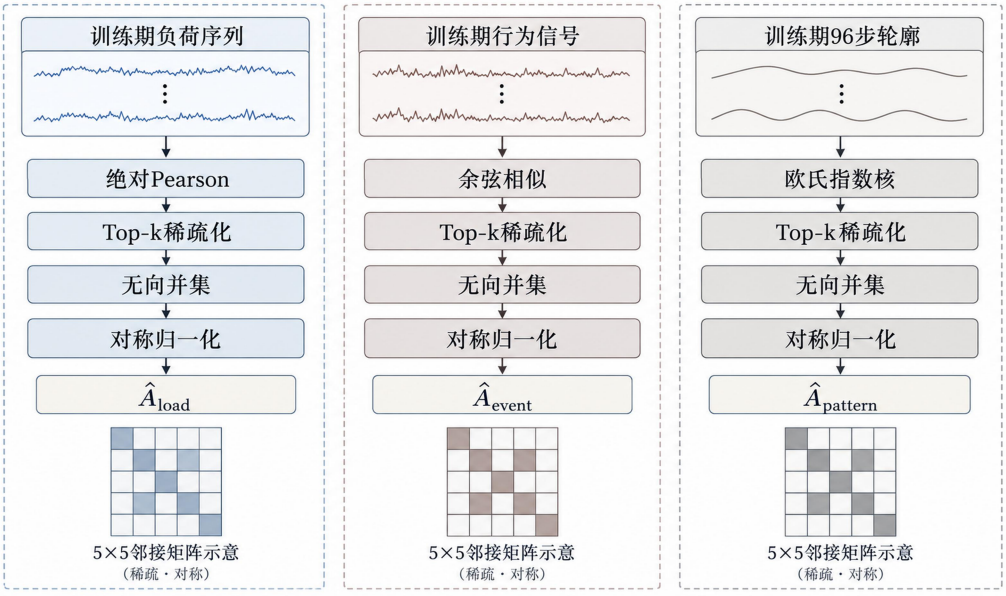


图 3-4 LRE 三关系构建流程

注：训练期负荷序列、行为信号和 96 片轮廓分别形成负荷耦合、行为共现和轮廓相似关系，随后经 Top-k 稀疏化、无向并集和对称归一化得到三类固定邻接矩阵。

3.3.1 负荷耦合关系图

设$\mathbf{l}_i \in \mathbb{R}^T$为节点$i$的训练期节点代理负荷序列。节点$i$与$j$的负荷耦合强度定义为绝对 Pearson 相关系数：

$$A_{ij}^{load} = \left| \frac{(\mathbf{l}_i - \bar{l}_i)^{\top}(\mathbf{l}_j - \bar{l}_j)}{\|\mathbf{l}_i - \bar{l}_i\|_2 \|\mathbf{l}_j - \bar{l}_j\|_2} \right|. \tag{3-3}$$

绝对值表示耦合强度，不保留正负方向；任一序列方差为零时，对应权重置零。该关系描述节点负荷在训练期的同步程度，不解释为物理连线或因果联系。

3.3.2 行为共现关系图

对节点i构造行为序列

$\mathbf{b}_i = \mathbf{x}_i^{access} + \mathbf{x}_i^{departure} + |\Delta \mathbf{x}_i^{active}|$，再以余弦相似度定义行为共现关系：

$$A_{ij}^{event} = \frac{\mathbf{b}_i^{\top}\mathbf{b}_j}{\|\mathbf{b}_i\|_2 \|\mathbf{b}_j\|_2}. \tag{3-4}$$

分母为零时权重置零。该关系侧重接入、离站与活跃变化在时间上的共同出现，对行为规模差异相对不敏感。

3.3.3 轮廓相似关系图

训练序列从数据起点按固定相位切分为 96 步窗口，对各窗口同一相位位置取均值，得到节点轮廓$\mathbf{p}_i \in \mathbb{R}^{96}$，其元素单位为 kWh/15 min。数据首时刻为 11:00，因此这是固定相位的 96 步窗口轮廓，不是自然日 00:00 起算的日曲线。记节点轮廓均值为$\bar{p}_i$，中心化轮廓为$\tilde{p}_{iq} = p_{iq} - \bar{p}_i$；以节点对中心化轮廓的均方根距离表征形状差异，再以指数核转换为相似度：

$$\bar{p}_i = \frac{1}{96}\sum_{q=1}^{96} p_{iq},\ \tilde{p}_{iq} = p_{iq} - \bar{p}_i,\ d_{ij} = \sqrt{\frac{1}{96}\sum_{q=1}^{96}(\tilde{p}_{iq} - \tilde{p}_{jq})^2},\ s = \begin{cases} median\{d_{uv} : u < v,\ d_{uv} > 0\}, & 若存在正距离, \\ 1, & 否则, \end{cases} A_{ij}^{pattern} = \exp\left[-\frac{d_{ij}}{\max(s, 10^{-6})}\right]. \tag{3-5}$$

式中，i, j, u, v为节点索引，q为 96 个固定相位位置之一；d_{ij}与s的单位均为 kWh/15 min。中心化去除节点轮廓均值，故该关系反映相对形状而非负荷水平。尺度s取所有无序节点对(u, v)中正距离的中位数；若无正距离则回退为 1 kWh/15 min。为避免分母过小，指数核分母下限为10^{-6} kWh/15 min。该关系与负荷耦合关系表达不同的统计信息。

3.3.4 top-k 稀疏化与对称归一化

三类关系矩阵分别进行稀疏化。首先在每行保留权重最大的k个非自身邻居，

随后以$max\ (\mathbf{A}, \mathbf{A}^{\top})$取得无向并集。因此，某节点最终的非零邻居数可能略多于k。Caltech 回溯协议主模型（SG-DATA-005、SG-EXP-003）冻结为$k = 3$；后文另行报告的$k = 5$、$k = 7$属于不同登记实验的稀疏度敏感性，不能改写该主结果的配置。Caltech 事件时刻协议（SG-DATA-006-eventtime-v1）另行冻结为$k = 5$，两套 Caltech 结果不直接比较。在加入单位自环后，采用对称归一化：

$$\widehat{\mathbf{A}}_r = \widetilde{\mathbf{D}}_r^{-1/2}(\mathbf{A}_r + \mathbf{I})\widetilde{\mathbf{D}}_r^{-1/2}, r \in \{load, event, pattern\}. \tag{3-6}$$

三类关系矩阵见图 3-5。它们均为训练期统计关系，颜色只表示关系权重，不表示地理距离、配电拓扑或因果方向。

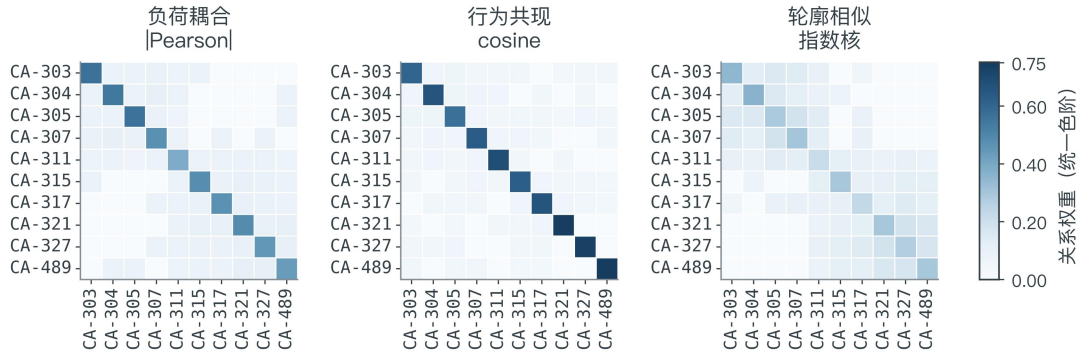


图 3-5 LRE 三类站内关系矩阵

注：三个面板依次表示负荷耦合、行为共现和轮廓相似关系，并采用统一色阶。矩阵由训练集一次性构建，不含跨种子误差棒。

3.4 时间基线：TCN

时间骨干采用 TCN[24]。对每个节点独立处理 96 片历史输入，六层一维卷积的膨胀率依次为 *1,2,4,8,16,32*，卷积核宽度为 3。网络使用因果填充并裁去右侧多余输出，使时刻t的表示只依赖t及其历史。其感受野为

$$R = 1 + (K - 1)\sum_{l=0}^{L-1} 2^l = 1 + 2(1 + 2 + 4 + 8 + 16 + 32) = 127, \tag{3-7}$$

能够覆盖 96 片历史窗口。每层在通道维执行逐时间步 LayerNorm，不跨时间汇总统计量；最终时刻的隐藏状态作为节点初始表示$\mathbf{H}^{(0)} \in \mathbb{R}^{B\times N\times D}$。主实验取隐藏维$D = 32$、dropout 为 0.1。TCN 既作为 MRG-GCN 的时间编码器，也作为无图基线。

3.5 双层多关系门控图卷积网络（MRG-GCN）

3.5.1 总体架构

MRG-GCN 由时间编码、两层多关系图卷积、层间特征精炼、跨层融合和预

测头组成。TCN 输出$\mathbf{H}^{(0)}$；第一层图卷积得到$\mathbf{H}^{(1)}$；中间残差 MLP 生成精炼表示$\mathbf{H}^{(1,ref)}$，并作为第二层图卷积的输入，得到$\mathbf{H}^{(2)}$。最后拼接$\mathbf{H}^{(0)}$、$\mathbf{H}^{(1)}$和$\mathbf{H}^{(2)}$，经线性映射、层归一化（LayerNorm）、GELU 激活和随机失活融合，预测未来 4 个目标片的负荷。该结构同时保留纯时序、一阶邻域和二阶传播信息。为统一两层记号，定义$\mathbf{Z}^{(1)} = \mathbf{H}^{(0)}$、$\mathbf{Z}^{(2)} = \mathbf{H}^{(1,ref)}$，即$\mathbf{Z}^{(l)}$表示第$l$层传播的实际输入。

3.5.2 单关系消息传递

对第l层输入$\mathbf{Z}^{(l)}$，关系r的消息为

$$\mathbf{M}_r^{(l)} = \widehat{\mathbf{A}}_r \mathbf{Z}^{(l)} \mathbf{W}_r^{(l)}, \tag{3-8}$$

其中，$\mathbf{W}_r^{(l)} \in \mathbb{R}^{D\times D}$为关系专属变换矩阵。邻接聚合沿节点维进行，不改变批次维和隐藏维。

3.5.3 关系级门控

每层设置独立的未归一化权重参数（logit）$\mathbf{a}^{(l)}$，经 Softmax 得到三类关系的全局融合权重：

$$\beta_r^{(l)} = \frac{exp\,(a_r^{(l)})}{\sum_{s=1}^{3} exp\,(a_s^{(l)})}, \mathbf{M}^{(l)} = \sum_{r=1}^{3} \beta_r^{(l)} \mathbf{M}_r^{(l)}. \tag{3-9}$$

$\boldsymbol{\beta}^{(l)}$在同一层内由全部节点共享，用于表示该层的关系混合偏好，不是逐节点贡献度，也不等同于因果效应。两层参数相互独立，允许不同传播深度采用不同关系组合。

3.5.4 节点级门控

关系消息聚合后，模型按样本、节点和特征维计算门值：

$$\begin{aligned} \mathbf{G}^{(l)} &= \sigma([\mathbf{Z}^{(l)} \| \mathbf{M}^{(l)}] \mathbf{W}_g^{(l)} + \mathbf{b}_g^{(l)}), \\ \widetilde{\mathbf{H}}^{(l)} &= \mathbf{G}^{(l)} \odot \mathbf{M}^{(l)} + (1 - \mathbf{G}^{(l)}) \odot \mathbf{Z}^{(l)}. \end{aligned} \tag{3-10}$$

$$\mathbf{H}^{(l)} = LayerNorm\,[\mathbf{Z}^{(l)} + Dropout\,(\widetilde{\mathbf{H}}^{(l)})]. \tag{3-11}$$

关系级$\boldsymbol{\beta}$与各关系变换共同缩放聚合消息，节点级$\mathbf{G}$在自身表示和邻域消息间分配门值。β不能脱离关系变换的尺度单独解释为重要性，详见 4.2.5 节。Caltech 回溯协议未对$\mathbf{G}$单独重训练消融；Caltech 事件时刻协议的固定门值结果只作为受限功能证据，详见 3.7.2 节及附表 A-1。

3.5.5 关系随机失活

关系随机失活（relation dropout）在训练时按关系类型采样掩码，并对保留关系的$\boldsymbol{\beta}$重新归一化；若三类关系均被屏蔽，则随机恢复其中一类，以保证消息传播路径非空。该机制只在$p > 0$时启用，主模型配置$p = 0$，因此不是主结果中的有效正则项；其$p = 0.2$和$p = 0.4$设置仅用于 3.7.2 节敏感性检验。

3.5.6 逐层关系选择与跨层融合

第一层输出$\mathbf{H}^{(1)}$经残差 MLP 精炼后输入第二层，但跨层融合使用原始$\mathbf{H}^{(1)}$，而非精炼后的$\mathbf{H}^{(1,ref)}$。最终表示为

$$\mathbf{H}^{fuse} = Dropout\,(GELU\,\{LayerNorm\,[\mathbf{W}_f(\mathbf{H}^{(0)} \| \mathbf{H}^{(1)} \| \mathbf{H}^{(2)})]\}). \quad (3\text{-}12)$$

预测头将每个节点的融合表示映射为 4 个目标片。图 3-1 给出整体数据流，图 3-2 和图 3-3 分别展开关系传播单元与跨层融合路径。

3.5.7 目标函数与训练策略

训练目标采用标准化空间中的 L1 损失：

$$\mathcal{L}(\theta) = \frac{1}{BPN}\sum_{b=1}^{B}\sum_{p=1}^{P}\sum_{i=1}^{N}|\widehat{Y}_{bpi} - Y_{bpi}|. \quad (3\text{-}13)$$

式中，Y_{bpi}和$\widehat{Y}_{bpi}$分别为由训练段拟合的标准化参数变换后的目标值与模型预测值。事件时刻协议及 JPL 重拟合实验使用标准化 L1 训练，以调参集原单位 MAE 选择检查点；连续 8 轮未改善时早停，最多训练 60 轮。正式结果采用 2024、2025 和 2026 三个随机种子；校准集和测试集不参与选模。回溯协议的历史选模口径另见表 3-14 注。

3.5.8 与现有方法的区别

相关方法先例及本文的任务化定位见 1.2.2 节。Graph WaveNet[51]和 AGCRN[52]作为统一协议下的模型对照；整体预测结果与受控组件比较分别见 3.6—3.8 节。

3.5.9 节点门控与残差更新的分工

图 3-6 给出$\boldsymbol{\beta}$与$\mathbf{G}$的计算位置。冻结替换改变$\boldsymbol{\beta}$而保留关系变换，检验联合配置敏感度；节点维门控增量则由同参数共享门控训练比较，见 3.7.1 节。两类权重均不作物理因果解释。

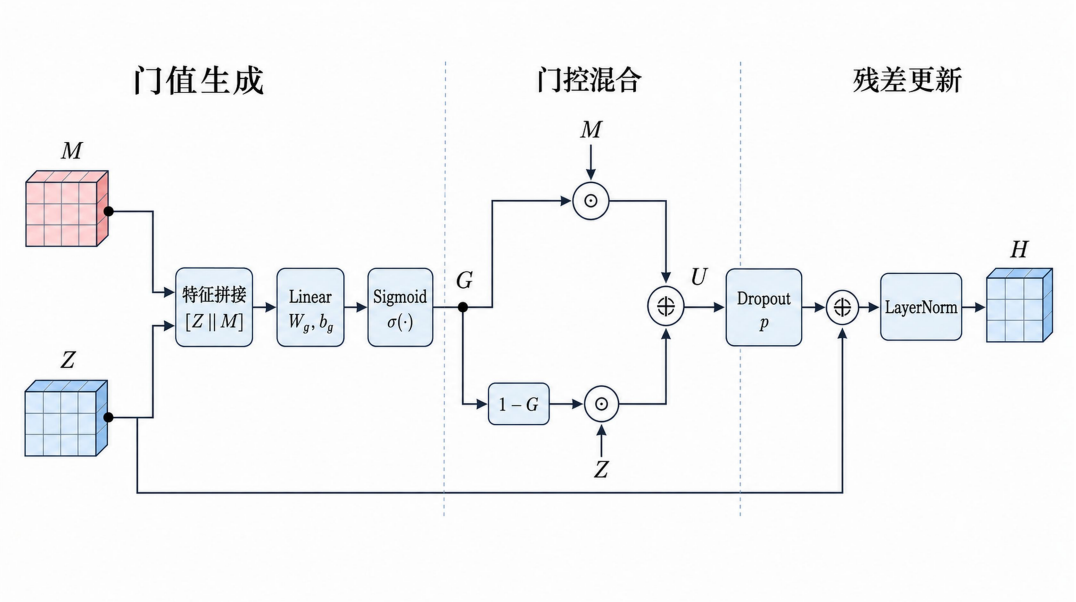


图 3-6　节点门控与残差更新细节

注：三类关系消息先形成融合消息$\mathbf{M}^{(l)}$，再与层输入$\mathbf{Z}^{(l)}$共同生成节点门值；门控混合后通过残差更新和 LayerNorm 得到$\mathbf{H}^{(l)}$。底部身份路径表示输入状态直接参与残差更新，不表示额外的关系边。

3.5.10　跨层表示的使用原则

第一层输出$\mathbf{H}^{(1)}$经残差 MLP 精炼后仅作为第二层传播入口；预测头拼接$\mathbf{H}^{(0)}$、原始$\mathbf{H}^{(1)}$和$\mathbf{H}^{(2)}$。该跨层路径未单独进行重训练消融，不能将整体 MAE 差异归因于拼接本身。数据流见图 3-7。

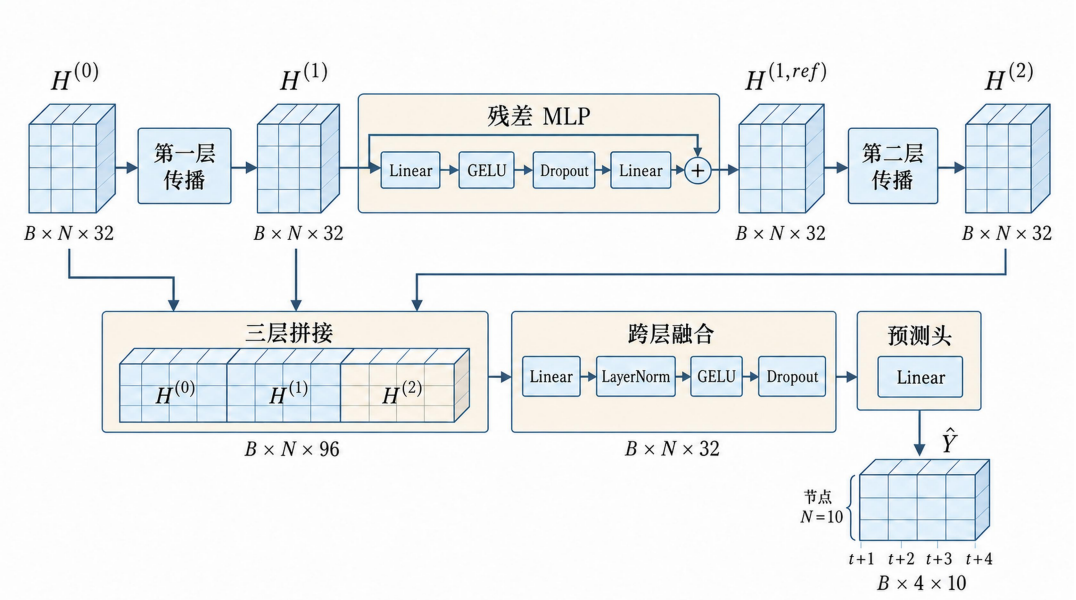


图 3-7　跨层表示路径

注：第一层输出$\mathbf{H}^{(1)}$经残差 MLP 得到$\mathbf{H}^{(1,ref)}$后进入第二层传播；跨层拼接仅接收$\mathbf{H}^{(0)}$、原始$\mathbf{H}^{(1)}$和$\mathbf{H}^{(2)}$。图中下方重复的状态块表示三层原始状态分别作为拼接输入，不表示新增模型分支，也不将$\mathbf{H}^{(1,ref)}$接入跨层拼接。

3.6 主要预测结果与回溯补充

3.6.1 评价协议与指标

本章以 Caltech 事件时刻预测和 JPL 重新拟合作为主要证据，分别检验行为输入条件下的模型比较及另一场站的站内适用性。Caltech 回溯结果保留为历史配置和 MDP 诊断依据。三套协议的输入权限、切分和预测键不同，比较均在协议内部进行，基本设置见表 3-1。

表 3-1 三套协议的任务与评价设置

协议	输入与用途	正式配置/实验	测试预测键
Caltech 事件时刻	行为计数及日历；主要预测比较	SG-EXP-019; 节点门控配对 SG-EXP-027	708,560
JPL 重新拟合	本站行为输入、节点筛选与构图；另一场站比较	SG-EXP-028; 事后关系替换 SG-EXP-031	632,640
Caltech 回溯	含事后会话代理负荷；历史与诊断补充	SG-EXP-003 StaticGraph 及既有对照	712,360

注：各协议均用 10 节点、96 片历史预测 4 个连续 15 min 目标片，发布与目标起点见 2.1.1 节。随机初始化采用 2024、2025、2026 三种子，报告样本标准差。种子是训练重复，预测键是误差单元，时间块描述固定期变化；三者均不是独立场站样本。输入、容量和选模预算统一列于 3.8.3 节。回溯配置按 7：1.5：1.5 切分；两套行为输入协议另设独立调参、校准段。

完整的训练、预测与分层评价流程见图 3-8。主指标为 MAE，并辅以 RMSE 和 WAPE：

$$MAE = \frac{1}{M}\sum_{m=1}^{M}|\widehat{y}_m - y_m|, RMSE = \sqrt{\frac{1}{M}\sum_{m=1}^{M}(\widehat{y}_m - y_m)^2}, \tag{3-14}$$

$$WAPE = \frac{\sum_{m=1}^{M}|\widehat{y}_m - y_m|}{\sum_{m=1}^{M}|y_m|}. \tag{3-15}$$

MAE 和 RMSE 单位为 kWh/15 min，WAPE 无量纲。MAE 为主要比较指标；零目标、非零目标及事件 MAE 用于检验收益分布，RMSE 用于检查大误差权衡。高零值比例使 MAPE 不适用。事件标签为事后评价标记，分层结果不追认为新的预登记主终点。

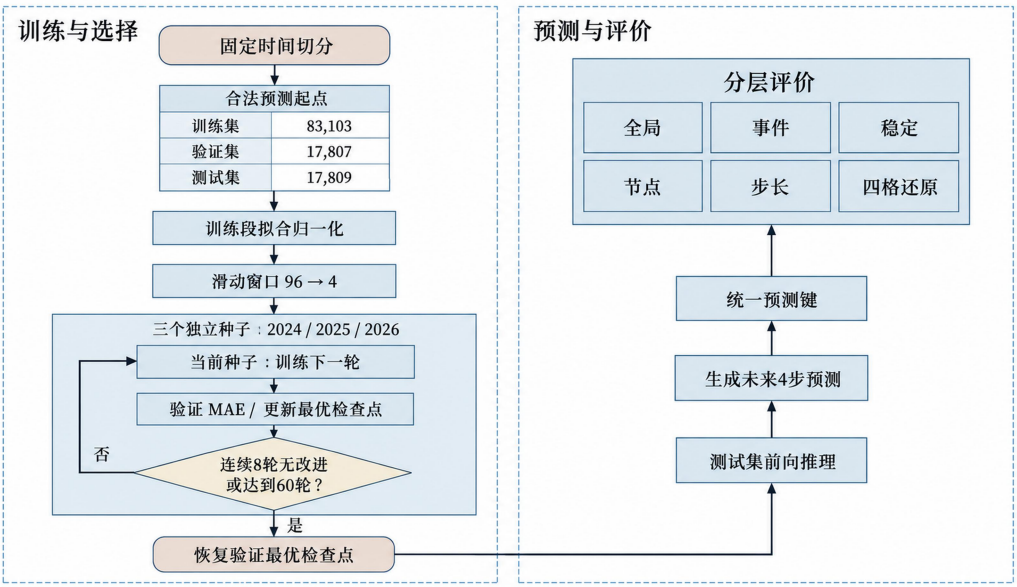


图 3-8　训练—预测—评价流程

注：数据按固定时间边界划分后构造 96 片历史输入与 4 片目标输出窗口，采用 2024、2025 和 2026 三个种子训练；事件时刻及 JPL 协议以调参集原单位 MAE 选取检查点，最多 60 轮、早停耐心 8 轮。校准集不参与选模，测试集仅用于冻结预测和评价。标准化参数及 LRE 图由训练集拟合；结果按全局、事件、稳定、节点、目标片和四格口径报告。目标片起点见 2.1.1 节；旧协议限制亦见该节。

冻结预测与检查点已逐键复核；除三个旧 AdaptiveGraph 运行外，原 CPU 前向及指标复算通过。AdaptiveGraph 在匹配 PyTorch 2.4.1/CUDA 12.1 环境下恢复逐键匹配，原生 CPU 差异定位于 top-k 并列选边；固定 CUDA 邻接后 CPU 亦通过。训练 Git 标识缺失及历史 Mac 环境差异仍是来源限制，详见 3.6.4 节。

3.6.2 Caltech 事件时刻协议的预测结果

Caltech 事件时刻协议（SG-DATA-006-eventtime-v1，SG-EXP-019）检验更严格行为输入条件下的关系与组件价值。接入、离站和活跃计数按片末可见处理，与当地日历组成七通道输入；目标仍为事后会话代理负荷。训练、调参、校准和测试按完整窗口分段，以 96 片历史预测 4 个目标片，时间定义见 2.1.1 节。该协议与回溯代理输入及实测功率任务具有不同解释范围。

该协议共完成 12 种配置、每种配置 3 个随机种子，采用共同训练预算上限与模型选择规则。表 3-2 并列报告整体与关键分层误差，完整组件结果及训练轮次见附表 A-1。tcn_wide 与 mrg_full 分别含 32,674 和 32,714 个参数，差约 0.12%，用于容量近似匹配的无图比较；完整 AGCRN 含 199,912 个参数，用于检验更大模型规模下的预测表现。参数量描述模型规模，训练成本与推理效率还需实测。

表 3-2 Caltech 事件时刻协议的整体与关键分层误差

模型	全局 MAE	零目标 MAE	非零目标 MAE	标签事件 MAE	参数量
完整 AGCRN	0.03743 ±0.00022	0.00385 ±0.00016	0.26723 ±0.00076	0.37743 ±0.00078	199,912
MRG-GCN	0.03890 ±0.00010	0.00403 ±0.00024	0.27751 ±0.00244	0.38101 ±0.00090	32,714
容量近似 TCN	0.04634 ±0.00029	0.01312 ±0.00007	0.27365 ±0.00267	0.37463 ±0.00188	32,674
TCN	0.04629 ±0.00019	0.01312 ±0.00015	0.27323 ±0.00189	0.37506 ±0.00069	16,996

注: 误差单位为 kWh/15 min, 三种子均值±样本标准差。四种模型使用 708,560 个共同测试键；零目标与非零目标依据目标值划分，标签事件依据冻结 target_event 划分，两种分组可重叠。零目标比例 87.25%。12 种完整配置及训练轮次见附表 A-1，预算见表 3-14。

表 3-2 显示, MRG-GCN 较容量近似 TCN 低 16.1%全局 MAE; 完整 AGCRN 误差更低，参数量约为 MRG-GCN 的 6.1 倍。该结果反映所检配置在误差表现与模型规模之间的取舍，不能据参数量推断效率或单一组件作用。

分层结果显示，零目标键占 87.25%，MRG-GCN 的零目标 MAE 低于 TCN; 其非零目标和标签事件 MAE 则较高。零目标组的误差减少相当于全局净改善的 106.6%，说明总体增益由零目标组驱动，未转化为活跃或事件样本优势。现有比较也未覆盖行为 GRU 及容量匹配 AGCRN，架构结论限于表 3-2 所列模型。

节点门控和关系增量的受控证据见 3.7.1—3.7.3 节。

3.6.3 JPL 重拟合协议：另一场站的点预测比较

为检验 MRG-GCN 的整体误差优势和节点级门控增量是否只出现在 Caltech 场站，本文依据 2.1.3 节冻结的 JPL 数据与输入协议重新筛选节点、拟合关系图并训练模型。比较对象为 MRG-GCN、参数量近似匹配的 TCN、完整 AGCRN 及参数量相同的共享门控 MRG-GCN；每种配置均使用 2024、2025、2026 三个种子。12 次运行在同一张 RTX 4090 D 上完成, 统一采用 AdamW、batch size 256、最多 60 轮、patience 8 和调参集原单位 MAE 选模；未进行额外超参数搜索。所有模型均在相同的 15,816 个测试原点、4 个目标片和 10 个节点上评分, 共 632,640 个预测键。主要结果见表 3-3。

表 3-3 JPL 另一场站的点预测比较

模型	MAE（kWh/15 min）	RMSE（kWh/15 min）	可训练参数
MRG-GCN	0.081067±0.000304	0.210353±0.001390	32,714
TCN	0.083888±0.000180	0.206888±0.000451	32,674
AGCRN（完整）	0.083268±0.000552	0.210973±0.002195	199,912
共享门控	0.083325±0.000713	0.211498±0.000730	32,714

注：数值为 2024、2025、2026 三个种子的均值±样本标准差。参数量为模型

可训练参数总数；TCN 与 MRG-GCN 参数量相差 0.12%，共享门控模型与 MRG-GCN 参数量相同。各配置训练轮数按“实际停止/验证集最佳”列出：MRG-GCN 为 35/27、33/25、32/24，TCN 为 19/11、18/10、23/15，完整 AGCRN 为 13/5、13/5、12/4，共享门控为 60/59、41/33、56/48。共享门控 seed-2024 在最佳轮次后仅继续 1 轮即触及 60 轮上限，8 轮耐心值未耗尽；因此相同上限和早停规则不证明各配置已达到相同优化充分度。MAE 为预登记主要指标，RMSE 和分层误差用于说明整体优势的适用范围。

MRG-GCN 的三个种子整体 MAE 均低于三个对照，平均 MAE 较参数量近似匹配的 TCN、完整 AGCRN 和同参数共享门控分别低 3.36%、2.64%和 2.71%。其中节点门控对照虽保持相同参数量、输入和预登记训练规则，但共享门控 seed-2024 在验证集最佳轮次后未满早停耐心便达到训练上限；因此 2.71%应解释为该配对预算下的观测增量，尚未检验延长预算后差异是否保持。

按 UTC 预测原点划分 24 个非重叠七日块，在三组主要比较上进行 10,000 次配对重采样，并用 Bonferroni 方法校正后，基线减 MRG-GCN 的 Bonferroni 校正 98.33%置信区间分别为 TCN [0.001240, 0.004937]、完整 AGCRN [0.000313, 0.005495]、共享门控 [0.001517, 0.002976] kWh/15 min，均高于零，达到预登记整体 MAE 判据。区间以块内三种子逐键绝对误差均值为基础，反映这一固定测试期的时间块差异，不涵盖场站抽样和全部训练随机性。

JPL 的 12 个锁定检查点全部通过上述逐键复核，每运行覆盖 632,640 个测试键；CPU 重放与归档 GPU 预测的最大绝对差为 2.7×10^{-6} ，全局 MAE 最大差为 4.11×10^{-9} ，均低于预设容差。表 3-3 的复算链及检查点锁登记于项目复核附件。

整体 MAE 及时间块配对比较见图 3-9。

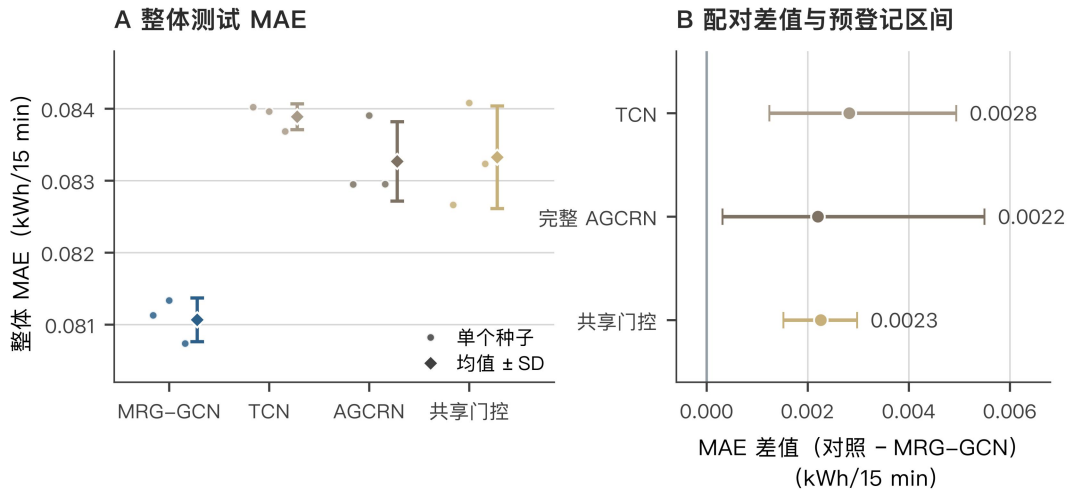


图 3-9 JPL 整体 MAE 与七日时间块配对比较

注：左侧显示四种模型在 2024、2025、2026 三个种子下的整体 MAE，汇总为均值±样本标准差；右侧显示基线减 MRG-GCN 的 MAE 差及 Bonferroni 校正 98.33%置信区间。时间块分析基于 24 个非重叠七日块和 10,000 次配对重采样，差值为正表示 MRG-GCN 误差较低。两类误差棒分别反映种子离散度与固定测试期的时间块差异，不作相同统计解释。

分层结果限定了这一优势的范围（图 3-10）。零目标键占 72.75%，标签事件键占 2.08%。相对 TCN，MRG-GCN 的零目标 MAE 和稳定窗口 MAE 较低（分别为 0.007361 对 0.012034、0.073820 对 0.076763 kWh/15 min）；TCN 的 RMSE、事件 MAE 和非零目标 MAE 较低（0.206888 对 0.210353、0.419209 对 0.422111、0.275718 对 0.277839 kWh/15 min）。因此，MRG-GCN 取得的是整体 MAE 优势，并非所有指标或样本层面的全面领先。

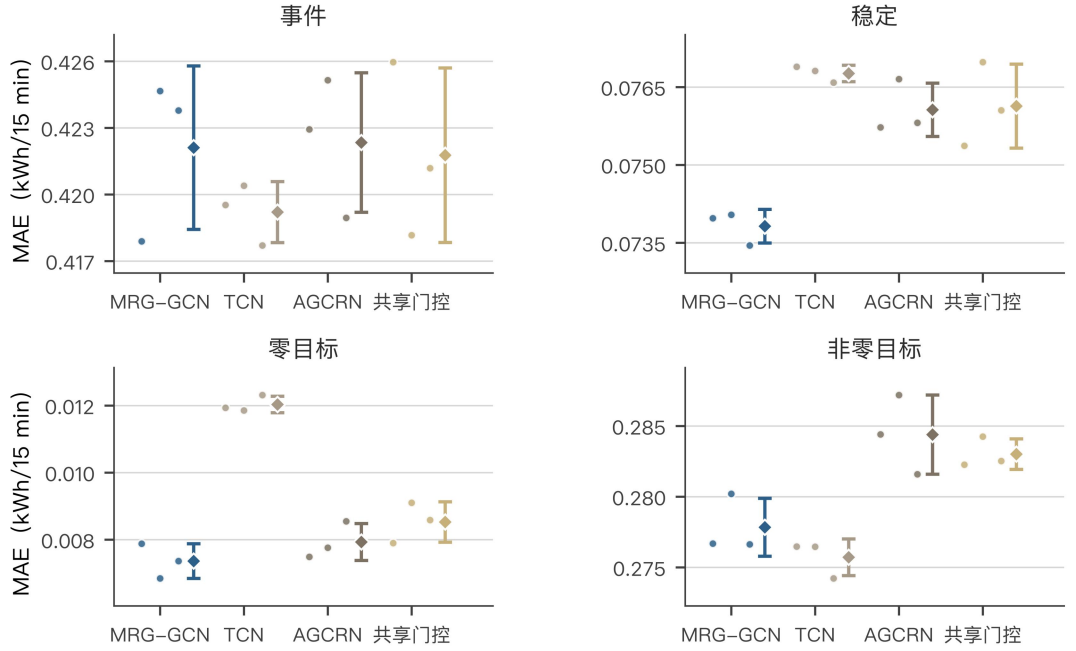


图 3-10 JPL 分层 MAE 比较

注：四个面板分别显示标签事件、稳定、零目标与非零目标预测键上的 MAE，散点为三个种子，汇总为均值±样本标准差；各模型使用相同的冻结分层掩码。各面板纵轴独立设置范围，下限均不为零，跨面板比较须依据刻度。分层结果用于界定整体 MAE 优势的范围，不表示各层均由 MRG-GCN 取得最低误差。

Caltech 与 JPL 同参数门控比较方向一致，但分别受各自协议和预算约束，不合并为跨站效应。统一输入、容量和预算说明见 3.8.3 节，JPL 独立区间校准见 5.3.5 节。

JPL 关系替换训练是另一项补充实验，配置与配对误差见 3.7.2 节表 3-10。它使用同一固定测试期，但不属于表 3-3 的预登记模型与基线比较；其结果用于判断三关系配置中各邻接相对于自环替代的条件性增量，不改变表 3-3 的整体—分层误差权衡。

3.6.4 回溯补充：完整配置与复算状态

表 3-4 Caltech 回溯协议全局预测指标对比

模型	MAE/(kWh/15 min)	MAE 标准差	RMSE/(kWh/15 min)	WAPE
Persistence	0.07828	—	0.23946	1.6270
LightGBM	0.03758	—	0.11998	0.7811
XGBoost	0.03873	—	0.12063	0.8051
ARIMA	0.02260	—	0.13229	—
MLP	0.02112	0.00019	0.10112	0.4390
GRU	0.02965	0.00003	0.10838	0.6162
TCN	0.02952	0.00014	0.10831	0.6136
GWN（简化变体）	0.01773	0.00054	0.10023	0.3685
AGCRN（简化变体）	0.02057	0.00029	0.09820	0.4276
AdaptiveGraph	0.01396	0.00017	0.09920	0.2902
EventResidual（探索记录）	0.01390	0.00015	0.09925	0.2889
MRG-GCN（StaticGraph）	0.01376	0.00023	0.09918	0.2860

注：MAE 与 RMSE 单位为 kWh/15 min，WAPE 无量纲。随机初始化模型为三种子均值，标准差为$n = 3$样本标准差，计算时分母为$n - 1$，对应自由度为 2；确定性基线标“—”。ARIMA 正式结果未提供 WAPE。各列加粗值为该指标的最小值。

本节保留包括 ARIMA[85]在内的回溯历史比较，供配置追溯及第 4 章诊断使用。GWN 仅作一步图聚合，AGCRN 共享门参数且未实现节点参数池，两者均为简化变体；EventResidual 只作探索记录。

AdaptiveGraph 的三个既有检查点在匹配 PyTorch 2.4.1/CUDA 12.1 环境下通过逐键复算，与归档预测的最大绝对差为 7.47×10^{-7}，低于 5×10^{-6} 容差。原生 CPU 有 7、8、9 行邻接选择与 CUDA 不同，均位于 top-k 截断并列候选；固定 CUDA 邻接后，CPU 预测最大差低于 9.27×10^{-7}。这支持并列选边解释本轮后端偏差。历史 macOS/PyTorch 2.13 失败记录和缺失训练 Git 标识仍保留，不将检查点重放称为从头训练复现。

表 3-4 中 MRG-GCN 的 MAE 为 0.01376 kWh/15 min，AGCRN 简化变体的

RMSE 最低。该表描述回溯代理序列的历史配置表现；主要预测结论以 3.6.2—3.6.3 节的行为输入比较为依据。

MRG-GCN、EventResidual 和 AdaptiveGraph 的 MAE 差仅为 0.00014 ~ 0.00020，与三者的跨种子标准差处于同一量级，三次重复不足以建立稳定次序，正文不使用“显著优于”。EventResidual 保留在表中，是为了完整记录已执行的探索路线，并不将其列为正式方法贡献。各模型的 MAE 及其离散度见图 3-11。

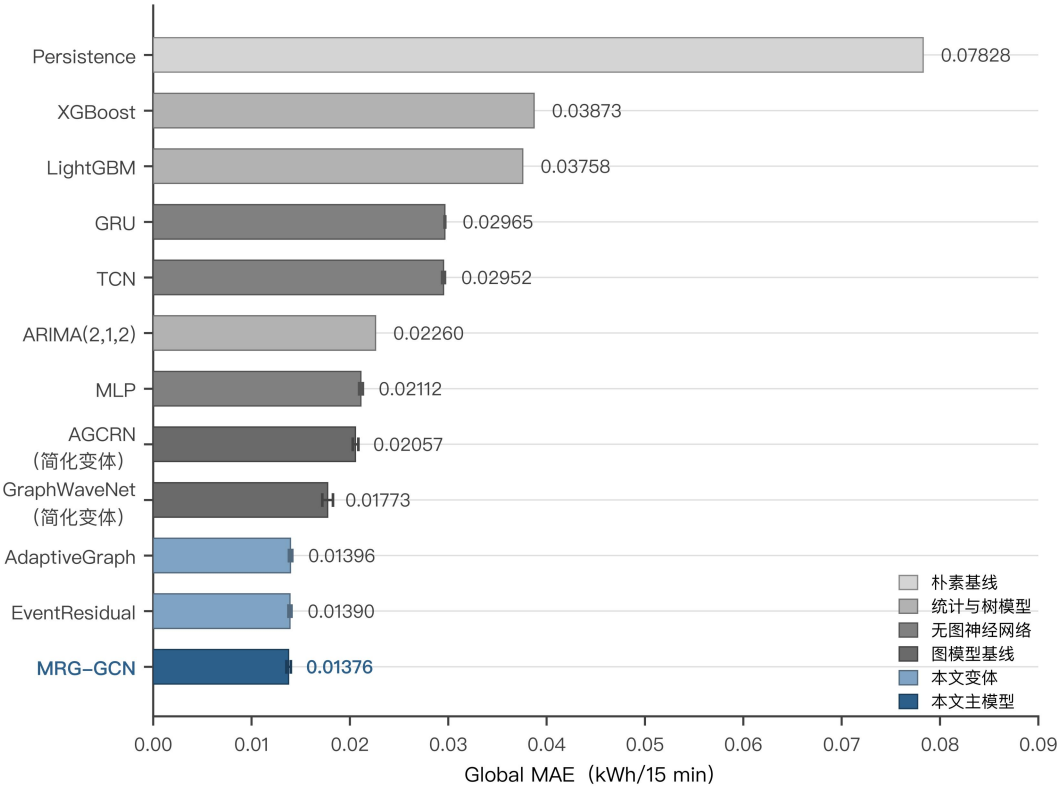


图 3-11 不同模型的全局 MAE

注：随机初始化模型显示三种子均值和标准差；确定性基线无误差棒。所有结果使用相同预测键和 kWh/15 min 口径。

由图 3-12 可见，各模型 MAE 随目标片向后移动而增加。MRG-GCN 在第 1 至第 4 个目标片（h1—h4，对应[0,15)、[15,30)、[30,45)、[45,60) min）的 MAE 分别为 0.00432、0.01072、0.01697 和 0.02302 kWh/15 min。

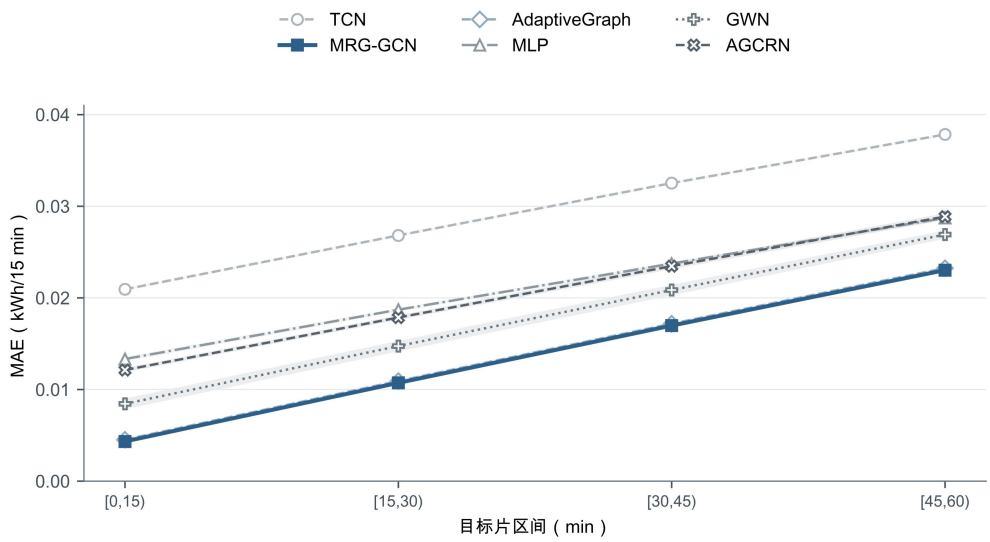


图 3-12　不同模型的逐目标片 MAE

注：横轴区间以预测发布时刻为 0，依次为[0,15)、[15,30)、[30,45)和[45,60) min；曲线为三种子均值，阴影为跨种子样本标准差。实心方形表示 MRG-GCN（StaticGraph）；GWN 和 AGCRN 为本文所检简化变体。

以预测键为重采样单元的 Bootstrap 分析见图 3-13，该分析对三种子预测结果进行点级合并。结果可描述大量测试键上的误差差异，但预测键存在时间、节点和种子内相关性，因此 95%区间和单侧比例不作为跨种子统计显著性证据。

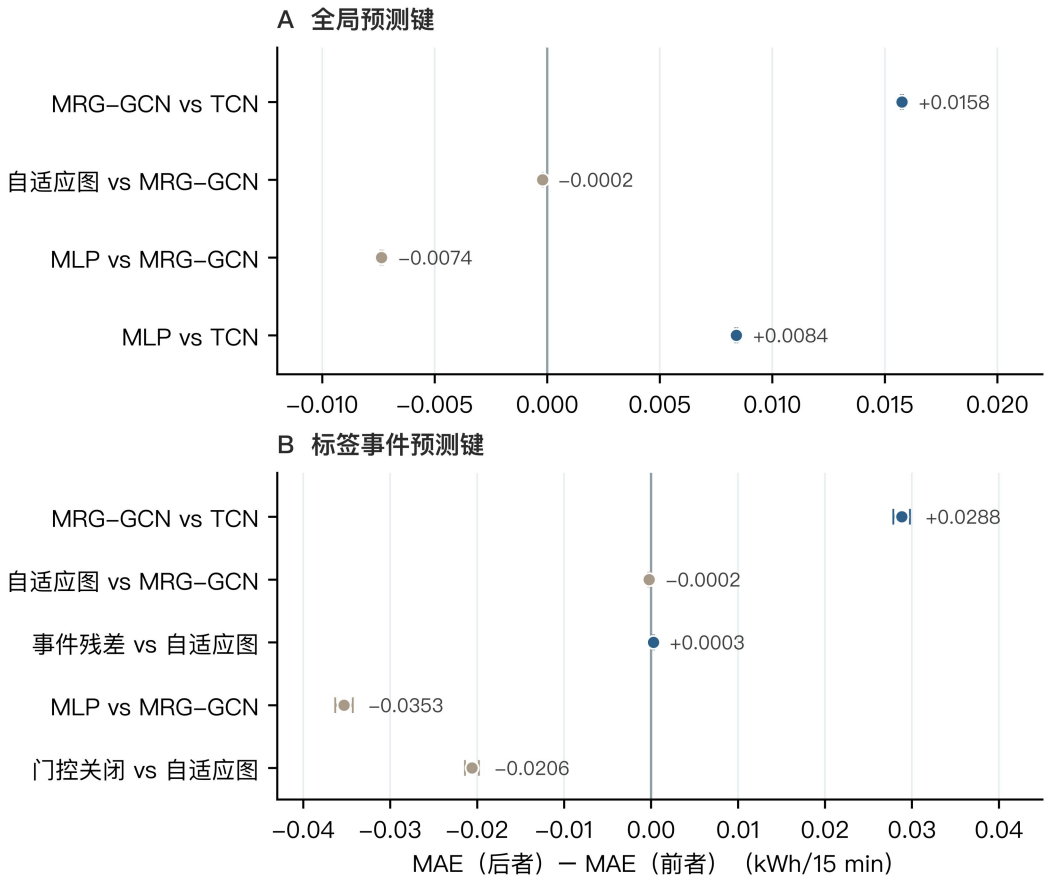


图 3-13 模型误差差的点级 Bootstrap

注：每行纵轴按“前者 vs 后者”列出比较模型，点为 MAE(后者)−MAE(前者)，正值表示前者误差更低；并非所有行都以 MRG-GCN 为比较对象。误差棒为 10,000 次重采样的 95%百分位区间。预测键存在时间、节点及种子内相关性，该区间仅作点级误差差描述，不作跨种子显著性判断。

为避免将点级重采样误差棒误读为时间序列证据，本文进一步对同一批原始预测执行时间块复核。具体做法是：对每个共同预测键计算“基线绝对误差−MRG-GCN 绝对误差”，按预测原点的 UTC 日聚合，并在相同键上先取三种子的逐键平均；随后分别以 1 日和 7 日为重采样单元进行 10,000 次有放回百分位 Bootstrap。这里的种子平均是误差序列的算术平均，不是将三个模型输出组成集成预测。区间仅描述锁定测试期内的时间块稳定性，不替代跨场站或未见时期验证。

表 3-5 原主实验时间块误差差复核

对照（基线−MRG-GCN）	平均误差差	1 日块 95%区间	正差块	7 日块 95%区间	正差块
TCN	0.01576	[0.01517, 0.01640]	187/187	[0.01495, 0.01662]	27/27
AdaptiveGraph	0.00020	[0.00016, 0.00025]	166/187	[0.00015, 0.00026]	27/27

表 3-5 中正值表示 MRG-GCN 误差较低。MRG-GCN 相对 TCN 的优势在全部日块和周块中保持为正；相对 AdaptiveGraph 的优势幅度很小，1 日块中有 21

个块并不为正，但种子平均的时间块区间仍为正，因而只能表述为“在本测试期内具有小幅、总体稳定的优势”，不使用显著优于或必然优于的措辞。

3.6.5 回溯补充：分层与节点误差

分层结果见表 3-6：依据目标侧标签事件 target_event 划分事件与稳定窗口，并另行报告非零负荷子集。事件窗口占测试预测键的 1.43%，冻结规则触发率 0.43%不用于本表分层。

表 3-6 Caltech 回溯协议分层 MAE 对比

模型	事件窗口	稳定窗口	非零负荷
Persistence	0.4382	0.0731	0.3640
LightGBM	0.3074	0.0337	0.1402
XGBoost	0.3084	0.0348	0.1411
ARIMA	0.2939	0.0187	0.0909
MLP	0.3114	0.0169	0.1292
GRU	0.3042	0.0257	0.1274
TCN	0.3049	0.0255	0.1264
GWN（简化变体）	0.2732	0.0140	0.0693
AGCRN（简化变体）	0.2924	0.0166	0.0995
AdaptiveGraph	0.2763	0.0102	0.0720
EventResidual	0.2760	0.0101	0.0715
MRG-GCN (StaticGraph)	0.2761	0.0100	0.0711

注：单位为 kWh/15 min；随机初始化模型为三种子均值。事件与稳定窗口分别含 10,160 和 702,200 个预测键。

事件窗口中 GWN 的 MAE 最低，非零负荷子集同样如此；MRG-GCN 在稳定窗口最低。MRG-GCN 的事件窗口 MAE 约为稳定窗口的 28 倍，表明全局优势主要来自占比 98.57%的稳定窗口，而稀有事件仍是共同难点。该结果也说明，全局最优不能直接等同于事件窗口最优；不同评价窗口的量级对比见图 3-14。

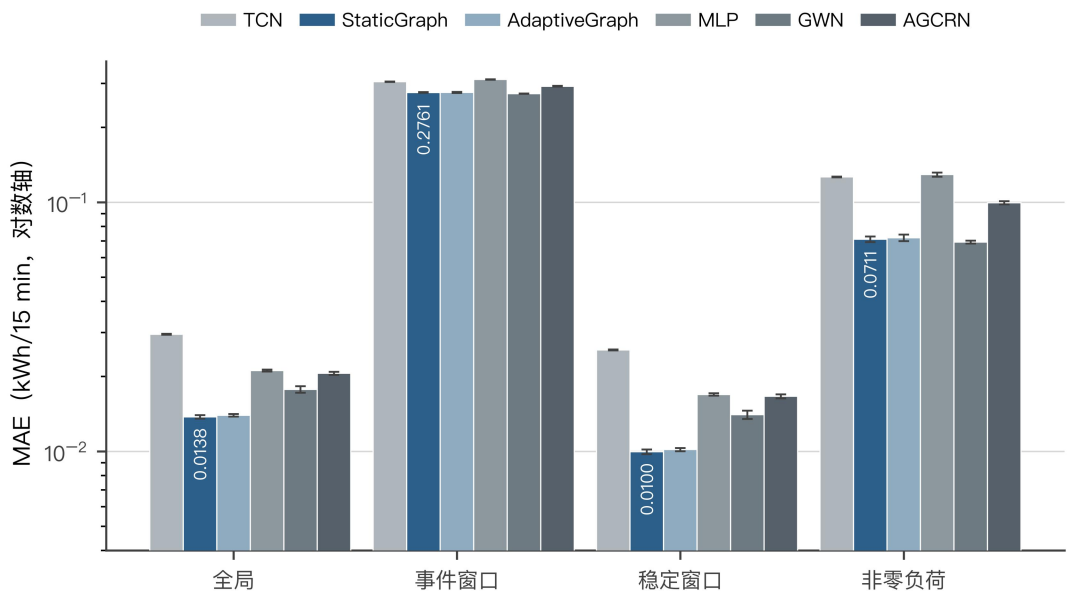


图 3-14 不同评价窗口的 MAE

注：柱高为三种子均值，误差棒为跨种子标准差；纵轴采用对数尺度，以同时显示事件和稳定窗口的量级差异。

MRG-GCN 的逐目标片和逐节点误差列于表 3-7。

表 3-7 Caltech 回溯协议下 MRG-GCN 目标片区间与逐节点 MAE

目标片区间 (min)	MAE	节点	MAE	节点	MAE
h1 [0,15)	0.00432	CA-303	0.02582	CA-315	0.00616
h2 [15,30)	0.01072	CA-304	0.01171	CA-317	0.00686
h3 [30,45)	0.01697	CA-305	0.02234	CA-321	0.00642
h4 [45,60)	0.02302	CA-307	0.01863	CA-327	0.01318
—	—	CA-311	0.01810	CA-489	0.00839

注：目标片区间均以预测发布时刻为 0，采用左闭右开表示；各 MAE 单位为 kWh/15 min。

节点 MAE 从 0.00616 至 0.02582，相差约 4.2 倍。CA-303 和 CA-305 误差较高，CA-315、CA-317 和 CA-321 较低，与第 2 章的节点负荷规模差异相符。由于绝对误差受节点负荷幅值影响，这一结果用于刻画评价难度，不据此判断某节点的相对预测质量。六种模型的逐节点对比见图 3-15。

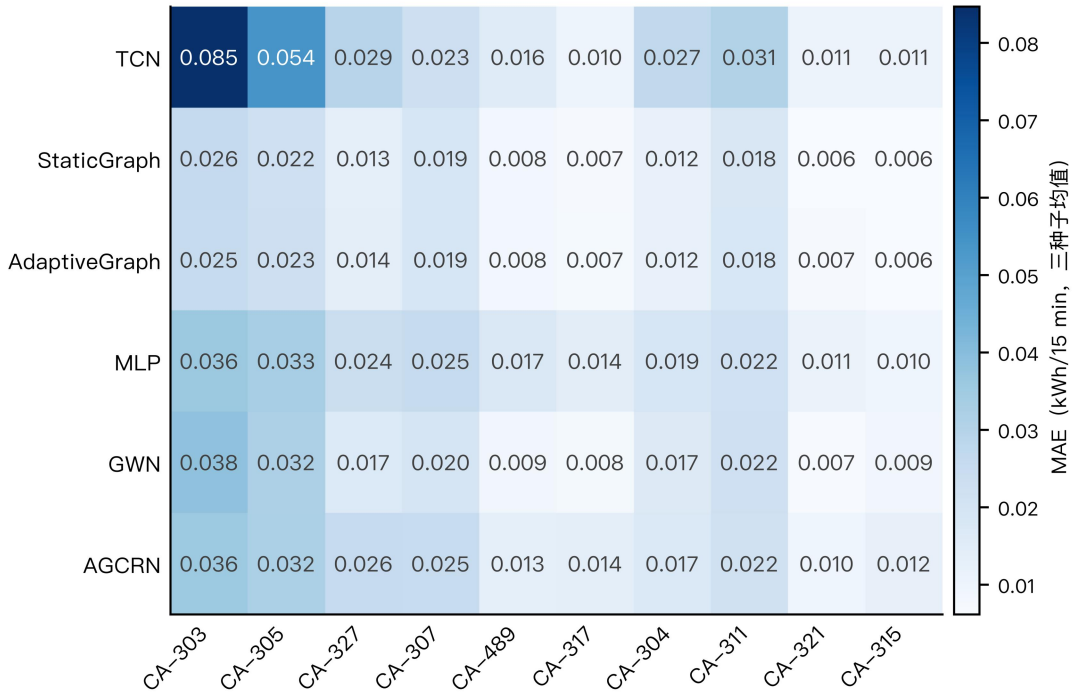


图 3-15　不同模型的逐节点 MAE

注：热力图为 10 个节点和 6 个模型的三种子均值；节点按主张量测试预测起点对应时刻的累计代理负荷降序排列。颜色与数值使用同一节点映射，颜色表示误差大小，不表示节点间关系；GWN 与 AGCRN 为原主实验的简化变体。

3.6.6　回溯补充：模型规模与训练记录

回溯配置的规模与训练耗时列于表 3-8。

表 3-8　模型规模与正式训练耗时

模型	可训练参数量	单种子训练耗时均值/min	全局 MAE
GRU	4,068	1.7	0.02965
AGCRN（简化变体）	4,252	51.9	0.02057
TCN	16,996	2.9	0.02952
MRG-GCN（StaticGraph）	32,714	7.7	0.01376
AdaptiveGraph	35,005	5.4	0.01396
GWN（简化变体）	40,084	9.3	0.01773
MLP	228,968	1.3	0.02112

注：耗时取三种子正式运行记录均值。MLP 来自 Apple Silicon/MPS 环境；TCN、MRG-GCN、AdaptiveGraph、GWN、AGCRN 和 GRU 来自 Linux/CUDA 12.1 环境，GPU 具体型号未写入相应实验元数据。耗时包含训练与验证早停，不含数据预处理；因硬件与软件栈不同，不作跨模型速度排名。

表 3-8 记录所检实现的参数规模和训练耗时，硬件、图聚合及早停轮次均影响读数。相同协议下的完整配置差异不能直接归为单一图算子的贡献；同参数节点门控与关系邻接增量由 3.7 节的受控比较判断。现有记录未提供统一端到端推理时延。

3.7 组件增量与协议敏感性

本节按待检验问题组织组件证据：先报告跨协议同参数门控对照，再讨论关系路径和关系子集，继而说明关系级参数干预、组合消融与评价还原检查。各组结果保留自身协议和内部基线，不合并为一套消融排序。

3.7.1 同参数节点级门控配对对照

固定门值消融同时改变参数量，无法单独检验节点门值差异。为此，在事件时刻输入协议下另设节点共享门控: 两层均先对节点门控网络的线性输出沿节点维求均值，再经 Sigmoid 并广播至全部节点；其门值仍随样本和特征变化。完整模型保留逐节点门值。两组骨干、关系变换及预测头相同, 可训练参数均为 32,714；在同一 RTX 5090 上，以 2024、2025、2026 三个种子配对训练，逐参数初始化相同，最多 60 轮、早停耐心 8 轮、优化器、批量和选模规则一致。该对照只改变门值是否保留节点维差异。

六次正式运行均完成训练和预测导出，并在相同 708,560 个测试预测键上核对原点、节点、目标片编号、真值及掩码。结果见表 3-9。节点级门控的平均整体 MAE 比节点共享门控低 0.001067 kWh/15 min，按共享门控均值计低 2.69%；三个种子的配对差分别为 0.000685、0.001309 和 0.001207 kWh/15 min，方向一致。事件组的绝对差仅 0.001239，仍需结合其高基线误差判断实际意义。

表 3-9 Caltech 事件时刻协议下同参数节点门控配对结果

模型	整体 MAE	标签事件 MAE	稳定 MAE
节点级门控	0.038677±0.000289	0.379462±0.000556	0.033698±0.000300
节点共享门控	0.039744±0.000142	0.380701±0.000604	0.034762±0.000146

注：单位为 kWh/15 min，均值±样本标准差来自三个配对种子。两组参数量和训练预算上限相同；实际停止轮次分别为节点级门控 38/22/22、共享门控 60/40/54，最佳轮次分别为 30/14/14 与 52/32/46。Caltech 共享门控 seed-2024 同样达到 60 轮上限，故配对差支持的是当前预算和选模规则下的节点差异门控增量；对更长训练预算下的稳定性尚无证据，不据此声称各配置已充分收敛。这六次运行单独报告，不替换表 3-2 中的原 36 次结果。

为核查时间相关性，先在每个预测键上取三个配对种子的绝对误差差均值，再按发布时刻的洛杉矶当地日期划分 27 个七日非重叠块，块内保留全部节点和四个目标片。对块进行 10,000 次配对有放回重采样，以累计误差差除以累计键数计算 MAE 差, 避免将长短不同的末尾块等权平均。七日块整体差的描述性 95% 区间为[0.000747, 0.001378] kWh/15 min; 185 个一日块的敏感性区间为[0.000799, 0.001334]，方向一致。该分析在结果已查看后制定，是锁定历史测试期、固定三种子平均误差上的条件区间，不包含跨站、未见时期或重新抽取训练种子的全部

不确定性。

为检查总体门控增量是否由单个节点主导，另对 SG-EXP-027 和 JPL 的测试键逐一剔除一个节点，并按保留节点重新计算三种子平均 MAE。十次留一在两个协议下的差值均为正：Caltech 节点级门控 MAE 降幅为 2.25% ~ 2.89%，JPL 为 2.13% ~ 3.20%。这是基于已查看测试期的事后节点构成敏感性分析；它说明点估计不依赖某一个被评价节点，但不增加独立样本，也不构成新时期或跨站确认。

七日块下，非零组差为 0.005305 [0.002869, 0.007861]，事件组为 0.001239 [0.000045, 0.002413]；均为未作多终点校正的描述性区间。相同参数控制了模型规模，但训练轮次和优化轨迹不同；结果仅支持当前协议与预算下的节点差异增量。

3.7.2 关系路径、关系子集与敏感性

JPL 受控关系替换。 本节的主检验为 SG-EXP-031 同参数自环替换：保留全部关系分支和参数，仅将指定邻接矩阵替换为单位自环并从头重训。该检验复用已查看测试期，属于事后补充分析。结果见表 3-10。

表 3-10 JPL 三关系图自环替换的配对重训练结果

替换配置	替换配置 MAE−完整模型 MAE (kWh/15 min)	完整模型 MAE 降幅 /%	Bonferroni 98.333%七日块区间 (kWh/15 min)	同向种子	结论
负荷耦合关系→自环	0.001501	1.82	[0.000048, 0.002689]	3/3	支持当前设置下的条件性整体 MAE 增量
行为共现关系→自环	0.000120	0.15	[-0.000432, 0.000728]	2/3	区间跨零, 增量尚不确定
轮廓相似关系→自环	0.001252	1.52	[0.000167, 0.002275]	3/3	支持当前设置下的条件性整体 MAE 增量

注：每个替换配置均保留三个关系分支和 32,714 个可训练参数，仅将指定邻接矩阵替换为单位自环，再按同一规则从头训练；每配置三个种子，共 12 次运行，同一种子各配置的非图参数初始值一致。差值定义为“替换配置 MAE−完整模型 MAE”，正值表示完整模型误差较低。降幅以替换配置 MAE 为分母。区间对三项比较作 Bonferroni 校正, 基于固定 JPL 测试期 24 个当地七日块及 10,000 次配对重采样；测试期已查看，本结果为事后补充分析。

负荷耦合和轮廓相似关系对应的整体 MAE 差三种子均为正，Bonferroni 校正区间下限均高于零；行为共现关系的区间跨零。因此，前两类关系在本架构、

协议和预算下具有相对自环替代的条件性整体增量证据，第三类仍不确定。事件组中，行为或轮廓关系替换后的 MAE 反而分别低 0.005142 和 0.003677，表明整体改善不必然延伸至事件样本。

负荷邻接的事后分层显示，替换为自环后的配置非零组 MAE 较完整模型高 0.004893 kWh/15 min，三个种子方向均为正；该结果来自已查看测试期，未作多重校正。它比较的是当前图模型内的关系组件，而非不同模型。JPL 完整 MRG-GCN 非零组 MAE 为 0.277839，高于 TCN 的 0.275718 kWh/15 min；Caltech 事件时刻和完成时刻截断目标也呈相同方向。因此，“负荷关系相对自环改善非零组”与“完整模型非零组尚未胜过 TCN”可以同时成立：前者支持在所检架构内保留并复核该关系，后者要求按分层表现选择模型。

SG-EXP-031 四种配置的最佳与停止轮次均低于 60 轮上限，降低了触顶对这组关系比较的影响，但不能据此认定充分收敛；027 及 028 共享门控的触顶限制属另一项对照。各组结果均按各自架构、预算和测试期解释。

其他关系子集与配置敏感性。 旧 Caltech 回溯协议的关系子集见表 3-11：单关系配置与三关系基线 MAE 接近，但删去分支同时改变参数量和传播路径，不能据此识别条件增量，故作为历史补充单独解释。

表 3-11 关系子集与超参数敏感性

实验组	配置	全局 MAE	组内结论
关系子集	三关系	0.01412	组内基线
关系子集	仅负荷	0.01415	与基线接近
关系子集	仅行为	0.01415	与基线接近
关系子集	仅轮廓	0.01401	数值略低
稀疏度	top-$k = 5$	0.01391	组内基线
稀疏度	top-$k = 7$	0.01448	+4.1%
关系随机失活	$p = 0.2$	0.01391	变化不足 0.03%
关系随机失活	$p = 0.4$	0.01391	变化不足 0.03%

附表 A-1 中单关系变体均值高于三关系模型，但参数量与路径同时变化，不能证明每类关系必需；固定门值变体亦受参数量与部分种子触顶混淆，节点门值增量以 3.7.1 节的同参数比较为准。去除跨层拼接和精炼的变化较小。top-k实验中，$k = 5$ 和$k = 7$ 的 MAE 分别为 0.01391 和 0.01448，较密的$k = 7$ 配置上升 4.1%；该结论不外推到未正式比较的其他稀疏度。关系随机失活概率取 0、0.2 和 0.4 时，MAE 均为 0.01391，差异不足 0.03%，未观察到实质收益。因此，主模型保持$p = 0$。这些已完成的小网格实验不构成输入长度、15 节点范围或规则阈值/扩展长度的全面敏感性验证；后几项尚未完成，不声称模型对其稳健。

Caltech 事件时刻协议下，等权β重训练取得略低的全局 MAE，现有证据不支持学习β具有正向精度净增益。该设置允许各关系变换重新适应等权约束，检验参数化选择；旧协议 L1 固定其他参数、仅在推理时替换β，检验既有模型的功能依赖。二者差异由 4.2.5 节结合关系变换的尺度解释。

按预测发布的当地日期划分 27 个连续七日非重叠时间块，保留全部节点、目标片和三种子，对种子平均的同键误差差作 2,000 次配对 Bootstrap。以“对照 MAE 减 MRG-GCN MAE”为正向改善，等宽 TCN 与自环对照的全局 MAE 差分别为 0.00744 和 0.00720 kWh/15 min，描述性 95%区间分别为[0.00693, 0.00798]和[0.00664, 0.00773]；相对等宽 TCN 的标签事件差为−0.00638，区间为[−0.00847, −0.00444]。这些结果把关系路径的证据范围限定在本测试时期和样本组成上。该区间反映固定三种子平均后的时间段变动，不包含重新抽取训练种子的全部不确定性，且未作多终点校正。

时间块分析中，等权β比完整模型低 0.000277 kWh/15 min，“等权减完整”区间为[−0.000470, −0.000089]；这是已查看时期的条件差异，尚不足以证明等效或普遍更优。跨层拼接差异区间跨零；精炼去除的差异较小。

3.7.3 关系级参数干预

该实验对 Caltech 回溯协议的训练模型仅替换β，保持关系变换及其他参数不变，检验已训练配置的功能依赖。详细权重、七种替换结果及β与关系变换的共同作用见第 4 章 L1。Caltech 事件时刻协议的等权变体重训结果见附表 A-1 与 3.7.2 节，用于评价重训练后的参数化选择。

3.7.4 组合配置消融与事件残差探索

在 MRG-GCN 之外，本文还检验了固定主模型参数、联合更新主模型参数、容量调整和阈值调整等事件残差修正实现。各实现均未获得可复现的事件窗口改进，未达到预设的正式纳入标准。因此，正式方法止于 MRG-GCN；表 3-4 保留 EventResidual 行用于记录实验事实，完整设置、结果和终止依据保留于实验登记表及归档材料。本结论只是否定所检实现，不推断事件预测问题本身不可改进。

该组结构消融以事件残差修正实验组的完整配置作为内部基线，其 MAE 为 0.01390。该基线包含 TCN、图模块和事件门控残差路径，与表 3-4 的正式 MRG-GCN 不是同一比较基准。表 3-12 显示，无图变体 MAE 升至 0.02960，是该组配置中退化最大的变体；这一结果只支持图增强结构在该组合配置中具有较强功能影响。仅固定图和仅自适应图相对内部基线分别上升 2.5%和 2.3%，差异较小。

“门控关闭”同时取消选择性触发、联合更新主模型参数并将修正作用于全样本，属于复合重训练变体；其 90.5%的退化不能归因于某一个门变量，只能说明该复合配置不适合替代原配置。各结构消融项的三种子汇总见图 3-16。

表 3-12 组合配置下的结构消融结果

配置	全局 MAE	相对内部基线
完整配置（内部基线）	0.01390	—
仅自适应图	0.01422	+2.3%
仅固定图	0.01425	+2.5%
门控关闭（复合变体）	0.02648	+90.5%
无图	0.02960	+113.0%

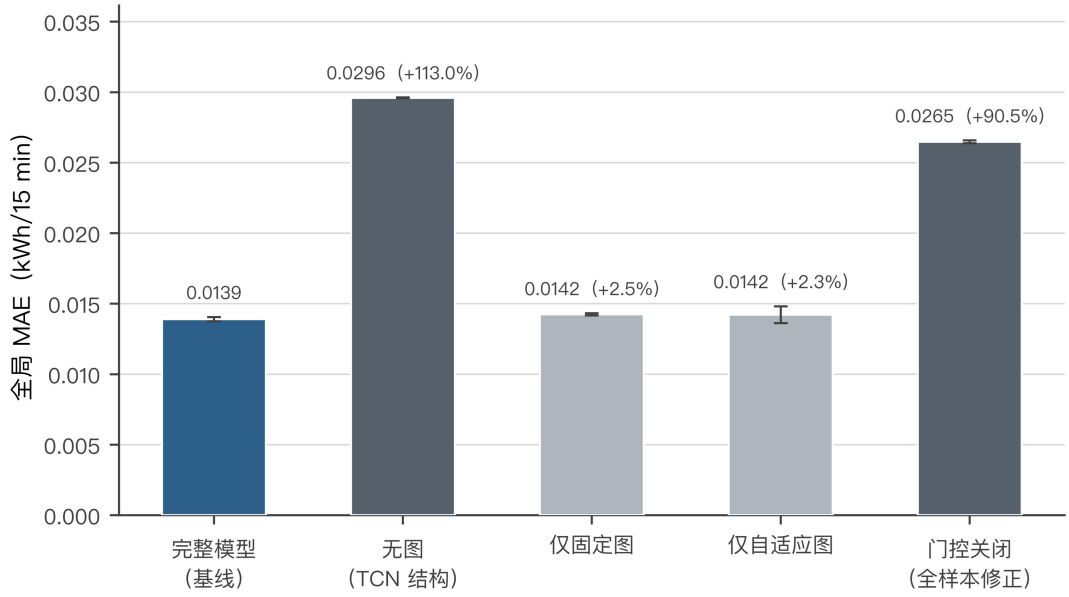


图 3-16 结构消融结果

注：柱高为三种子均值，误差棒为跨种子标准差。百分比仅相对于消融套件内部基线 0.01390 计算；该配置与表 3-4 正式 MRG-GCN 结果不同，不作直接比较。

3.7.5 四格评价的加权还原检查

目标侧标签事件 target_event 与冻结规则 rule_trigger 含义不同。本文按二者的 0/1 组合将测试预测键划分为四格，并验证

$$MAE_{global} = \frac{\sum_{a=0}^{1}\sum_{b=0}^{1} n_{ab} MAE_{ab}}{\sum_{a=0}^{1}\sum_{b=0}^{1} n_{ab}}. \tag{3-16}$$

原正式 MRG-GCN 的三个种子分别按四格样本量和绝对误差之和加权还原全局 MAE，最大数值差低于10^{-9}；对应的 712,360 个测试键均完整分配到四格。本章将其作为评价接口的一致性检查，逐格误差与贡献见 4.4 节，不将算术闭合当作机制证明。

3.8 证据综合与适用范围

本章主比较限定于三套协议及其各自的预测键；SG-EXP-032 则在已查看的 Caltech 事件时刻测试键上固定输入、图和切分，单独检验另一代理目标构造下的模型比较。它不构成新的独立测试期。组件层面的证据强弱和协议边界分别汇

总如下。

3.8.1 方法组件与目标敏感性证据综合

表 3-13 按对照类型归纳组件证据及其权限。节点门控和两类关系的整体增量证据均限于所检协议、预算与基线；负荷关系的非零组差异仍属探索性结果。基础图卷积、TCN 和门控算子沿用已有方法。

表 3-13 方法组件与目标敏感性证据、贡献范围

组件	直接证据及定位	可以支持的判断	尚未建立的判断
LRE 三关系图	表 3-2 主要比较、附表 A-1 单关系及同参数自环; 表 3-11 旧协议关系子集；表 3-10 JPL 同参数关系自环替换	跨节点关系路径在事件时刻协议下有整体 MAE 价值; JPL 同参数重训练支持负荷耦合和轮廓相似关系相对自环替换的条件性整体 MAE 增量	行为关系增量尚不确定；负荷关系非零组结果属未校正事后描述，不等同完整模型胜过 TCN; 旧协议子集仍受容量差异限制，也未证三类关系普遍必要
完成时刻截断目标 (032)	表 3-15；原 Caltech 事件时刻目标与替代目标在共同测试键上分别比较	两种会话代理目标下，MRG-GCN 相对容量近似 TCN 的全局 MAE 排序方向一致	替代目标零值占 94.27%，非零目标组 MRG-GCN 误差更高；不能据此确认实测功率效度、活跃负荷优势或替代拓扑下的端到端稳健性
关系级β	表 4-2、表 4-3 冻结替换; 3.7.2 节等权重训练; 4.2.5 节重参数化	已训练β与关系变换的联合配置有功能敏感度	β独立正增益、权重大小等同关系贡献或关系不可替代
节点级G	表 3-9 Caltech 同参数配对；表 3-3 JPL 同参数配对	当前预算及选模规则下，保留节点差异使整体 MAE 分别低 2.69%和 2.71%	更长预算下差异仍保持、所有样本层面占优或站点普遍优势
精炼与跨层融合	附表 A-1 删除变体及 3.7.2 节时间块分析	描述所检配置的优化响应；跨层拼接去除的差异区间跨零	所有模块分别必需或均有稳定独立增量
关系随机失活	表 3-11 的p = *0/0.2/0.4* 比较	所检小网格未见实质收益，主配置关闭	对其他数据与失活设置普遍无效
MDP 诊断组织	第 4 章参数干预、受检学生与四格还原；表 4-6 判断变化	修正关系解释、替代性判断与误差报告口径	新的预测收益、现实因果机制或已验证的运行收益

注：组件证据来自不同实验协议，表中不把冻结参数替换、删除后重训练和同参数配对合并解释；本文新增价值按任务化构造、所检增量及诊断判断分别陈述。

3.8.2 三套协议的回答范围与比较边界

Caltech 回溯、Caltech 事件时刻和 JPL 重拟合分别使用 712,360、708,560 和 632,640 个测试预测键。前者比较事后重构序列上的历史配置，后两者比较行为输入条件下的预测；输入权限、切分和节点来源不同，绝对 MAE 不跨协议相减。回溯 AGCRN 与 GWN 为简化变体；行为输入协议的模型设置见 3.6.2—3.6.3 节。JPL 重新筛选节点、构图和训练，不代表零样本迁移或未来时期验证。

SG-EXP-032 复用 Caltech 事件时刻协议的输入、图、切分及 708,560 个测试键，仅更换代理目标并重算目标标准化参数。它检验固定拓扑下的标签构造敏感性；替代目标下重建图的全流程仍未验证，详见 3.8.4 节。

3.8.3 输入、容量与训练选模预算

表 3-14 汇总主要模型对照、同参数门控及关系替换训练的输入、容量和实际训练记录。各行均使用 96 片历史、4 片目标和 2024/2025/2026 三个种子，但不同协议的输入权限、选模指标及预测键不同。预算上限相同并不保证优化充分度相同。

表 3-14 主要比较的输入、模型容量与训练选模预算

协议/配置	输入	可训练参数	上限/耐心；选模指标	最佳轮次；停止轮次
Caltech 回溯：AdaptiveGraph	A	35,005	60/8；标准化 MAE	17/13/13；25/21/21
Caltech 回溯：MRG-GCN	A	32,714	60/8；标准化 MAE	22/29/25；30/37/33
Caltech 回溯：TCN	A	16,996	60/8；标准化 MAE	8/6/5；16/14/13
Caltech 事件时刻（019）：mrg_full	B	32,714	60/8；原单位 MAE	27/19/19；35/27/27
Caltech 事件时刻（019）：tcn_wide	B	32,674	60/8；原单位 MAE	11/4/3；19/12/11
Caltech 事件时刻（019）：agcrn_full	B	199,912	60/8；原单位 MAE	1/1/1；9/9/9
Caltech 门控配对（027）：mrg_full	B	32,714	60/8；原单位 MAE	30/14/14；38/22/22
Caltech 门控配对（027）：mrg_shared_gate	B	32,714	60/8；原单位 MAE	52/32/46；60/40/54
JPL（028）：mrg_full	B	32,714	60/8；原单位 MAE	27/25/24；35/33/32
JPL（028）：tcn_wide	B	32,674	60/8；原单位 MAE	11/10/15；19/18/23
JPL（028）：agcrn_full	B	199,912	60/8；原单位 MAE	5/5/4；13/13/12
JPL（028）：mrg_shared_gate	B	32,714	60/8；原单位 MAE	59/33/48；60/41/56

续上表

协议/配置	输入	可训练参数	上限/耐心；选模指标	最佳轮次；停止轮次
JPL 关系替换（031）：完整模型	B	32,714	60/8；原单位 MAE	27/25/24；35/33/32
JPL 关系替换（031）：负荷耦合→自环	B	32,714	60/8；原单位 MAE	42/41/28；50/49/36
JPL 关系替换（031）：行为共现→自环	B	32,714	60/8；原单位 MAE	23/41/32；31/49/40
JPL 关系替换（031）：轮廓相似→自环	B	32,714	60/8；原单位 MAE	34/41/22；42/49/30
Caltech 目标敏感性（032）：mrg_full	B	32,714	60/8；原单位 MAE	16/12/14；24/20/22
Caltech 目标敏感性（032）：tcn_wide	B	32,674	60/8；原单位 MAE	6/12/4；14/20/12

注：输入 A 为回溯七通道（代理负荷、接入数、离站数、活跃数、占用率、需求强度、负荷跳变标志）；输入 B 为事件时刻七通道（接入数、离站数、活跃数及当地小时、星期的正余弦编码），假定行为计数在片末可见。两类输入均按相应训练段统计量标准化。所有列示运行采用 AdamW、学习率 0.001、权重衰减 0.0001、batch size 256 和标准化 L1 训练损失，最多 60 轮、早停耐心 8 轮。回溯协议按验证集标准化 MAE 选模；019、027、028、031 及 032 按调参集原单位 MAE 选模，校准和测试不参与选模。轮次依 seed-2024/2025/2026 列出；表内参数和日志已逐项复核。019 与 027 分别保留自身正式运行，不以 027 的较低点估计替换 019 结果；031 的四种配置均未达到 60 轮上限，且仅替换指定邻接、保留其余关系分支和模型参数。031 未触及上限只说明训练在耐心规则下提前停止，未检验更长预算或不同收敛判据，不能单独证明优化已充分收敛。032 使用替代目标重算目标标准化参数，但固定 B 输入、原训练前缀图、切分及预测起点键。完整 AGCRN 的 199,912 个参数未与 MRG-GCN 容量匹配。AdaptiveGraph 匹配 CUDA 复算、原生 CPU 选边差异及来源限制见 3.6.4 节。

Caltech 门控配对及 JPL 共享门控 seed-2024 触及 60 轮上限(JPL 最佳 59 轮、停止 60 轮）；门控增量因此限于该预算。参数量相近不代表推理时延或能耗相同。

SG-EXP-031/032 的训练源码、逐运行配置与环境、检查点和预测文件已按哈希清单封存。两项源码包分别核验 67、91 项，18 次运行的已有预测指标复算通过。031 入口未受历史 Git 记录覆盖，032 缺可验证的历史提交号，源码身份依冻结文件清单确定。本轮复算不加载检查点，也不重建训练过程。

3.8.4 完成时刻截断目标敏感性（SG-EXP-032）

SG-EXP-032 仅改变代理目标：有效完成时刻作为分摊终点，缺失或非法时

回退至断开时刻，并保持会话电量守恒。输入、原图、切分和预测键固定，目标标准化参数按新训练前缀重算；两个近似等参数模型各训练三种子。测试期已查看，本实验属于事后敏感性分析。

表 3-15 显示，替代目标下 MRG-GCN 全局 MAE 仍低于容量近似 TCN；同键误差差为 0.008302 kWh/15 min，95%七日块区间为[0.007757, 0.008797]，27/27 个区块为正。因此，MRG-GCN 相对容量近似 TCN 的整体 MAE 排序在该目标下保持；新旧目标的绝对 MAE 不可直接相减。

替代目标的零值比例为 94.27%。MRG-GCN 零目标组 MAE 低于 TCN，非零组则高 0.013938 kWh/15 min；全局差异仍由零目标组驱动。RMSE 近乎持平并略偏向 TCN。按原 target_event 划分的事件组均值略低，但仅 2/3 个种子方向一致，且该标签未随目标重建；不据此声称事件组稳定改善。零值与事件标签是边际分层，未作联合误差贡献分解。

表 3-15 完成时刻截断代理目标下的 Caltech 测试结果

指标	MRG-GCN	容量近似 TCN
可训练参数	32,714	32,674
全局 MAE	0.043401±0.000303	0.051703±0.000074
RMSE	0.193411±0.000728	0.193320±0.000349
零目标组 MAE	0.008700	0.018353
非零目标组 MAE	0.614498	0.600560
冻结原事件标签组 MAE	0.480282	0.484651
冻结原非事件组 MAE	0.037018	0.045377

注：误差单位为 kWh/15 min；全局 MAE 与 RMSE 为三种子均值±样本标准差，其余为种子平均描述值。共同测试键 708,560 个，替代目标零值比例 94.27%；事件标签仍为原 SG-DATA-006 的冻结分组，未据新目标重建。分析固定原关系图，属于已查看测试期上的目标构造敏感性；新旧目标绝对 MAE 不直接相减。

3.9 本章小结

Caltech 与 JPL 结果均显示 MRG-GCN 在所检配置下具有整体 MAE 优势，但该优势没有稳定延伸至非零和事件样本；Caltech 完整 AGCRN 的整体 MAE 更低。受控比较支持节点门控在当前预算下的整体增量，以及 JPL 负荷耦合和轮廓相似关系相对自环替换的条件性整体增量；行为关系仍不确定。完成时刻截断后，MRG-GCN 相对容量近似 TCN 的整体 MAE 排序保持，非零组 MAE 仍高于 TCN。回溯结果与参数干预作为补充证据，由第 4 章解释。

第 4 章　三层机制诊断协议（MDP）与模型可解释性分析

4.1 引言：MDP 协议的定义与设计原则

预测精度与权重画像不能完整解释关系使用及误差来源[80], 本文据此建立三层机制诊断协议（mechanism diagnosis protocol，MDP）：L1 替换关系级$\boldsymbol{\beta}$以检查功能敏感度；L2 检验指定 TCN 学生在给定蒸馏设置下能否逼近 StaticGraph 教师；L3 交叉标签事件与规则触发，描述样本误差构成。操作、实验和边界见图 4-1 及表 4-1。三层均属模型诊断，不识别现实负荷的因果机制。

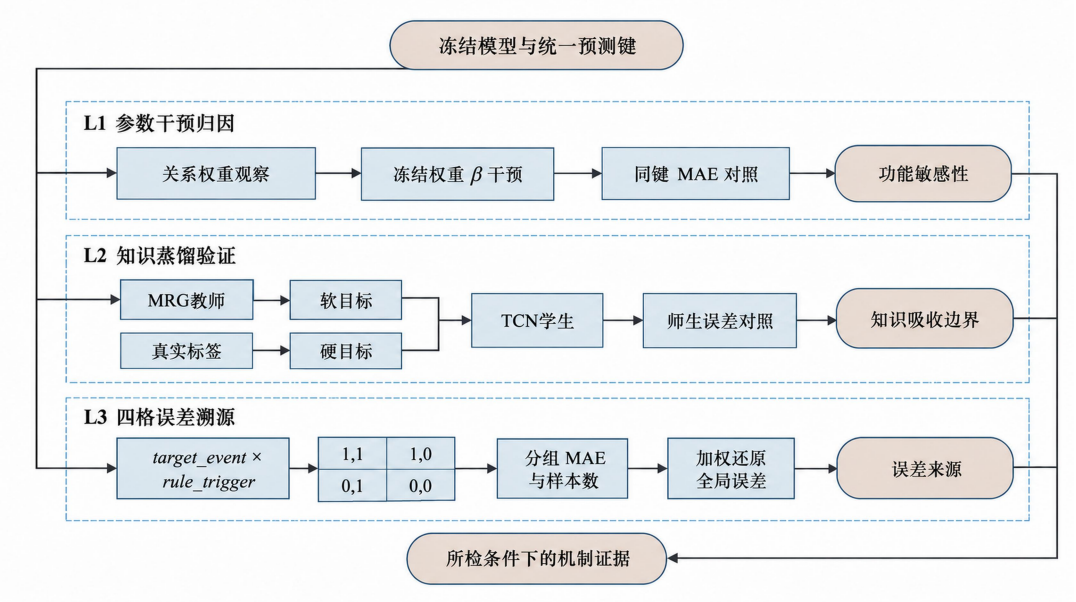


图 4-1 三层机制诊断协议

注：L1 关系参数干预、L2 受检学生蒸馏和 L3 四格误差溯源依次对应参数干预、蒸馏训练和误差还原。图中“溯源”指对预定义样本组的误差构成作描述性分解，不表示因果归因；图示呈现三层诊断的操作顺序与证据汇合关系。L2 只评价所检学生架构、蒸馏目标和权重范围，具体读数见表 4-1 及相关结果表。

表 4-1 MDP 三层机制画像

层次	研究问题	操作与证据	本文判定及边界
L1 干预归因	当前模型对所学关系分配是否敏感?	两层$\boldsymbol{\beta}$观察 + 7 种冻结模型前向干预×3 种子	所检替换均退化，显示对联合参数配置的功能依赖；不能单独识别$\boldsymbol{\beta}$的正向增益
L2 蒸馏验证	指定纯时序学生能否在所检设置下逼近教师?	StaticGraph→TCN; 4 个蒸馏权重×3 种子	学生未弥合差距；不能据此证明图知识不能由时序模型吸收
L3 四格误差溯源	全局误差在标签与规则分组中如何分布?	目标侧标签事件×冻结规则触发；样本量加权还原	事件窗口单键误差较高；四格还原全局 MAE，但不构成事件级因果归因

4.2 L1 干预归因层（IA）：关系分配的功能依赖

4.2.1 观察操作

从 Caltech 回溯协议主模型的三个随机种子检查点中，提取两层关系级门控的 Softmax 输出$\boldsymbol{\beta}^{(1)}$和$\boldsymbol{\beta}^{(2)}$。它们是层内共享的三关系混合权重，分别对应负荷耦合、行为共现和轮廓相似；并非逐节点贡献，也不能解释为物理因果强度。

4.2.2 干预操作

基于上述 Caltech 回溯协议检查点，在同一测试预测键上保持其余模型参数不变，将两层$\boldsymbol{\beta}$强制替换为指定组合，仅作前向推理。设置包括两层固定为单一关系、两层等权、两层学习值交换，以及保留一层学习值而固定另一层，共 7 种干预组合；学习值作为第 8 种基线配置。该操作属于模型内部的参数干预敏感度分析，借鉴“改变内部单元并观察输出”的解释思路[86]，不识别数据生成过程中的因果效应。

4.2.3 观察证据

三个种子的第一层均以行为共现权重最高（表 4-2）。第二层负荷耦合均值最高，但 seed-2025 中行为共现略高。因此，第一层排序在三个种子中一致，第二层只呈现均值差异。

表 4-2　两层关系级$\boldsymbol{\beta}$门控权重

层次	关系	seed-2024	seed-2025	seed-2026	均值	样本标准差
GCN1	负荷耦合	0.3433	0.3386	0.3481	0.3433	0.0047
GCN1	行为共现	0.4053	0.4030	0.3985	0.4022	0.0035
GCN1	轮廓相似	0.2514	0.2584	0.2534	0.2544	0.0036
GCN2	负荷耦合	0.3537	0.3465	0.3573	0.3525	0.0055
GCN2	行为共现	0.3026	0.3506	0.3133	0.3222	0.0252
GCN2	轮廓相似	0.3437	0.3029	0.3294	0.3253	0.0207

注：数值由三个随机种子的正式模型权重文件提取，标准差为$n = 3$样本标准差，分母为$n - 1$，对应自由度为 2；不进行统计显著性检验。

4.2.4 干预证据

两层三关系$\boldsymbol{\beta}$的种子离散度与均值见图 4-2。图 4-3 显示，学习值基线的全局 MAE 为 0.01376 kWh/15 min；7 种干预的 MAE 均升高，范围为 0.02695 至 0.04591。最小退化来自“第一层保持学习值、第二层固定为轮廓相似”，退化幅度为 95.9%；两层等权和交换两层学习值分别退化 143.8%和 148.4%。这些数值均为三种子均值，误差棒为跨种子标准差。

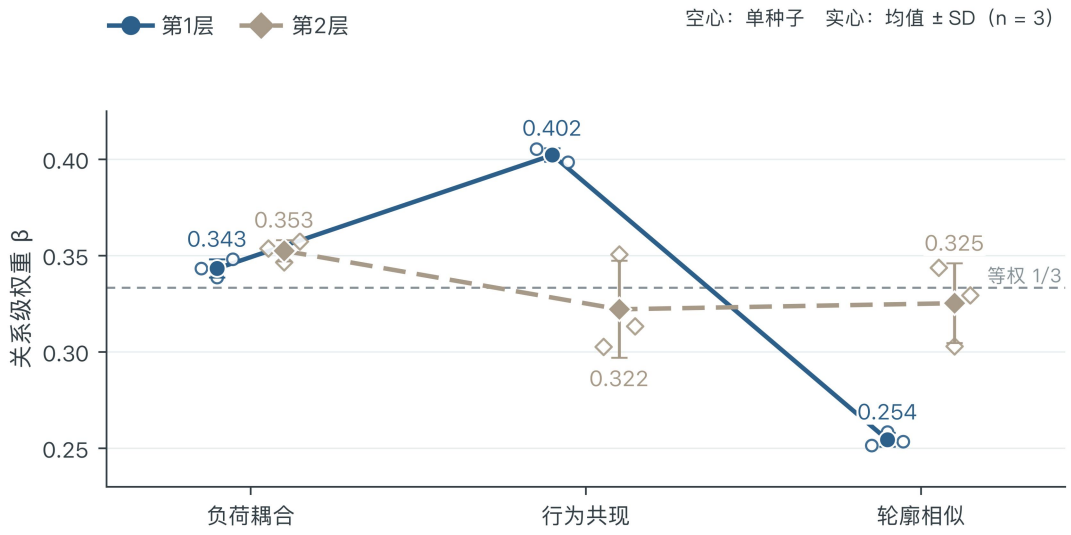


图 4-2　两层关系级β门控权重画像

注：StaticGraph 正式三种子中，空心点表示各随机种子的 Softmax 权重，实心点与误差棒表示均值±跨种子样本标准差。每层三类固定关系权重之和为 1；该图为观察性参数画像，不等同于节点级门控或关系因果效应。

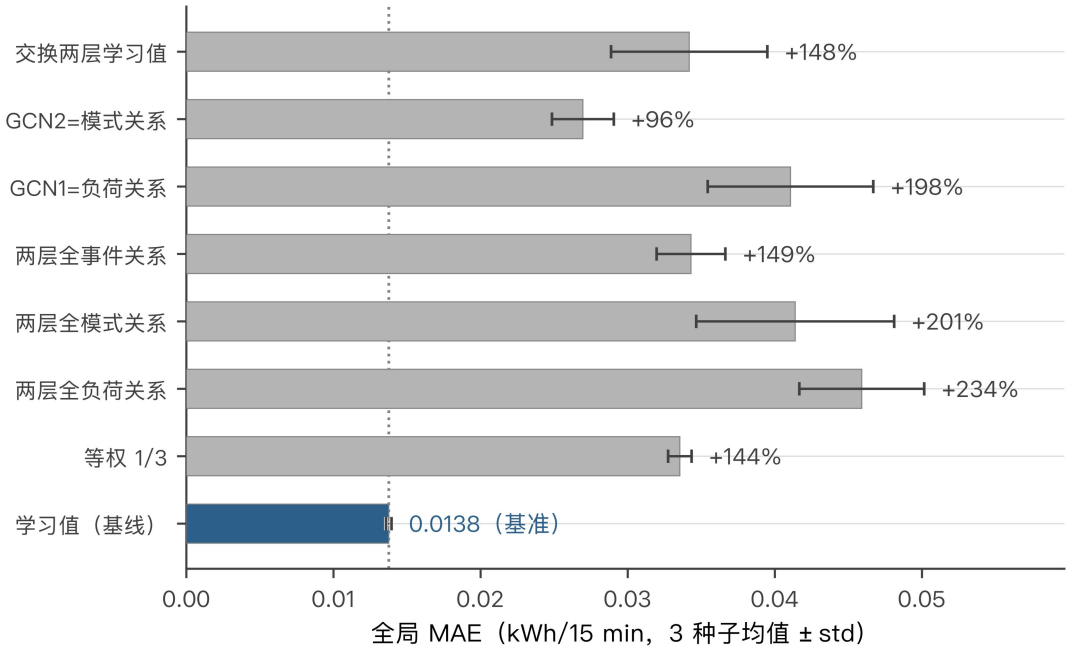


图 4-3 关系级门控参数干预结果

注：Caltech 回溯协议下，蓝色为学习值基线，其他配置强制替换两层$\boldsymbol{\beta}$后仅作前向推理。柱高为三种子均值，误差棒为跨种子标准差；百分比相对于学习值基线，正值表示退化。

4.2.5 L1 判定结论

L1 说明，在关系变换及其他参数固定时，所检 7 种β替换破坏了已训练联合配置，不能无代价地替代原值。这不是β本身不可替代的证明。每层消息由β与各关系变换共同决定，可写为$M = \sum_r \beta_r W_r(\widehat{A}_r H)$。本实现为每类关系配置独立无偏置线性变换，且主配置关系随机失活为 0；令$\beta_r^{'} = 1/3$、$W_r^{'} = 3\beta_r W_r$，即可保持每类加权消息及其总和不变。因此，β大小不能脱离W_r的尺度单独解释为关系重要性，等权参数化也不必缩小该消息函数的表达范围。

上述重参数化不等于两个训练过程相同：权重衰减、梯度尺度和初始化会改变优化轨迹。旧干预固定W_r、只替换β，回答既有配置的功能依赖；新协议等权变体从头训练，允许W_r重新适应，回答另一参数化能否达到接近的误差。结合 3.7.2 节等权重重训及历史时间块分析，本文不主张β具有独立的正向精度净增益，也不把观察权重转换为关系因果贡献。

节点级G的增量由表 3-9 单独检验：两组均含 32,714 个参数，仅改变门值是否保留节点维差异，整体 MAE 差为 2.69%。该结果及时间块区间支持当前预算下的节点差异价值；冻结β替换则只回答联合配置敏感度，两类证据分别解释。

4.2.6 分层敏感度：关系分配干预的样本响应

4.2.6.1 方法与指标

本节沿用 4.2.2 节冻结模型、预测键及 7 种$\boldsymbol{\beta}$替换，只补充标签事件窗口、稳定窗口和逐节点汇总。对评价层c计算相对变化：

$$\Delta MAE^{(c)} = \frac{MAE^{(c)}_{intervention} - MAE^{(c)}_{learned}}{MAE^{(c)}_{learned}}. \tag{4-1}$$

其中c可取全局、标签事件窗口、稳定窗口或节点。该量描述冻结模型对参数替换的功能敏感度，不等同于关系贡献或因果效应；它与 4.2.3 节的权重画像、4.2.4 节的整体干预和 4.4 节的样本误差分解回答不同问题。

4.2.6.2 分层敏感度结果

三种子汇总结果见表 4-3。所有干预在全局、事件和稳定窗口的 MAE 均高于学习值基线。全局退化范围为 95.9%至 233.6%；稳定窗口的相对变化为 132.1%至 316.6%，高于标签事件窗口的 5.5%至 35.6%。这一差异说明不同样本层面对同一参数替换的相对响应不同；仅凭该相对变化不能识别其由何种数据机制导致。

表 4-3 分层参数干预敏感度

干预配置	全局ΔMAE	标签事件窗口 ΔMAE	稳定窗口ΔMAE
第一层学习值、第二层固定为轮廓相似	+95.9%	+5.5%	+132.1%
两层固定为行为共现	+149.3%	+17.6%	+202.1%
两层学习值交换	+148.4%	+21.6%	+199.2%
两层等权	+143.8%	+21.3%	+192.9%
第一层固定为负荷耦合、第二层学习值	+198.4%	+35.6%	+263.7%
两层固定为轮廓相似	+200.7%	+17.1%	+274.4%
两层固定为负荷耦合	+233.6%	+26.6%	+316.6%

注：基线为学习值；数值为三种子汇总。当前分层汇总结果未保留逐种子离散度，故本表与图 4-4 不报告误差棒。

逐节点最大相对退化从 CA-327 的 171.3%至 CA-303 的 409.2%。CA-317、CA-315 和 CA-304 的最大退化也分别为 361.2%、351.6%和 349.8%。这些数值说明节点对所检关系替换的敏感程度不同；因未对节点差异进行独立统计检验，正文不据此划分固定的“高敏感”或“低敏感”节点类别。

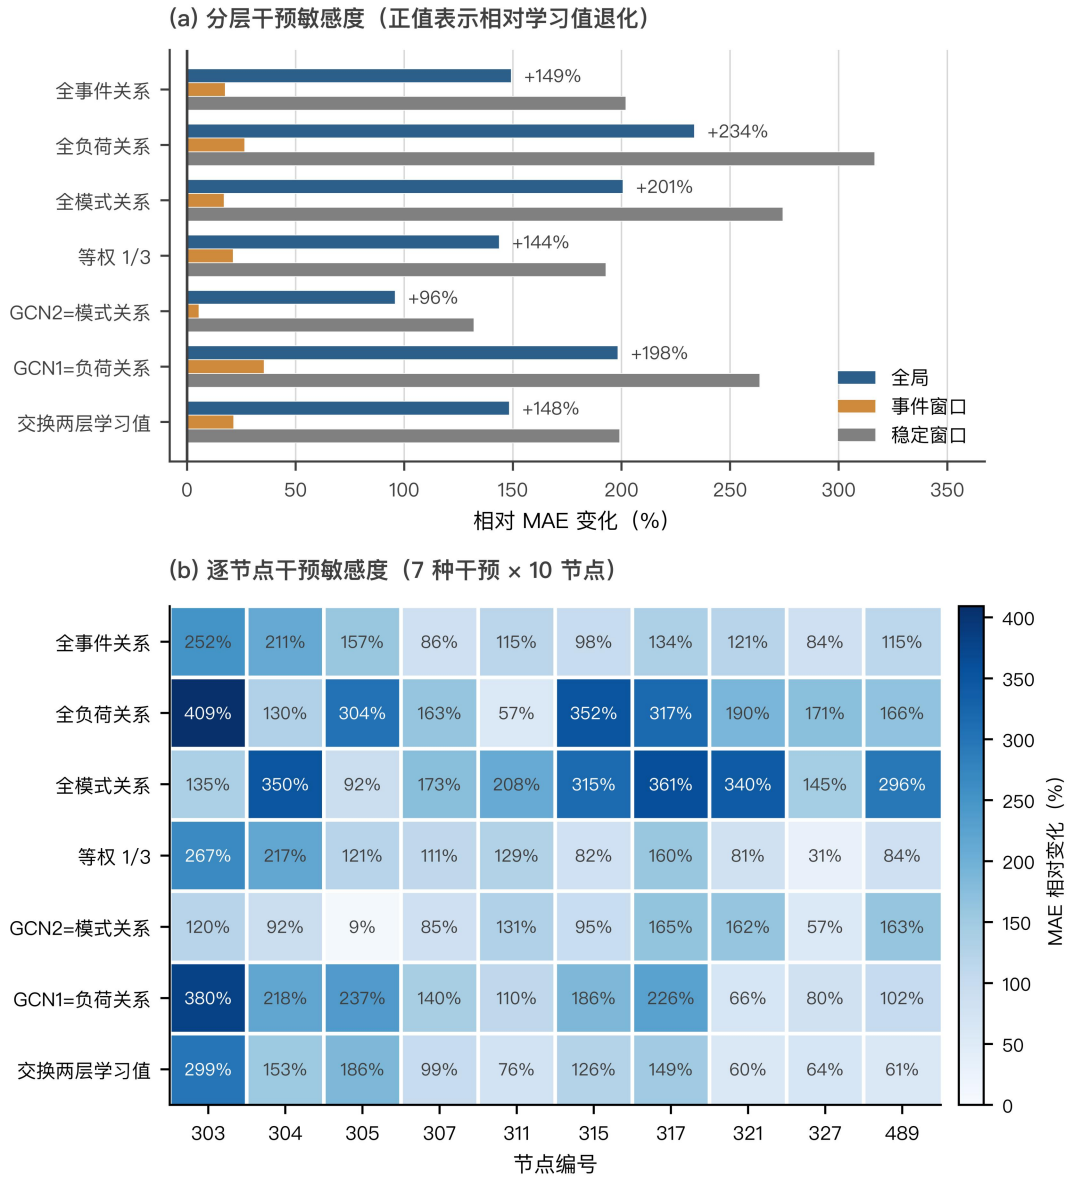


图 4-4 分层参数干预敏感度

注：左图比较全局、标签事件窗口和稳定窗口的相对 MAE 变化，右图展示 7 种干预在 10 个节点上的相对变化。正值表示相对学习值基线退化；三种子分层汇总结果未提供离散度，因此无误差棒。

4.2.6.3 解释边界

相对变化同时受基线大小、节点负荷尺度、事件比例和关系连接影响，故分层敏感度不能直接用来设定节点优先级或删除关系。新协议的等权β及关系子集重训练结果见 3.7.2 节，与本节冻结β替换分别回答参数化选择和既有配置依赖。

4.3 L2 蒸馏验证层（DV）：受检时序学生的替代性分析

4.3.1 协议操作

L2 采用知识蒸馏[87]检验图模型预测信号能否被纯时序学生吸收。教师为冻

结的 StaticGraph，学生为不含图输入的 TCN；教师参数在训练期间始终固定。目标值、教师预测和学生预测均处于训练集目标标准化空间，学生损失为$\mathcal{L}_{KD} = \mathcal{L}_1(\widehat{y}_s, y) + \alpha MSE\ (\widehat{y}_s, \widehat{y}_t)$，其中$\widehat{y}_s$和$\widehat{y}_t$分别为学生与教师预测。蒸馏权重取$\alpha \in \{0.1,0.5,1.0,2.0\}$，每一权重重复三种子，共 12 次训练；模型选择仍依据验证集目标值 MAE。该层检验的是“所检学生和目标能否逼近教师”，而不是图结构在任何模型中是否可替代。

4.3.2 诊断实验

四个蒸馏权重下，学生的全局 MAE 均接近无蒸馏 TCN 的 0.02952，且远高于教师的 0.01376；结果见表 4-4。数值最低的$\alpha = 2$仍约为教师 MAE 的 2.1 倍。

表 4-4 GCN→TCN 知识蒸馏结果

蒸馏权重α	seed-2024	seed-2025	seed-2026	均值±SD	相对教师倍数
0.1	0.02946	0.02938	0.02920	0.02934 ±0.00013	2.13×
0.5	0.02955	0.02921	0.02918	0.02931 ±0.00021	2.13×
1.0	0.02957	0.02932	0.02934	0.02941 ±0.00014	2.14×
2.0	0.02914	0.02925	0.02923	0.02921 ±0.00006	2.12×

注：教师 StaticGraph 的三种子全局 MAE 为 0.01376，纯 TCN 无蒸馏基线为 0.02952；均值与标准差按 3 个种子计算。结论限定于给定学生架构、蒸馏目标与α范围。

4.3.3 L2 判定结论

在本实验的 TCN 学生、预测值蒸馏目标和四个α取值下，蒸馏未弥合师生差距，但至少有三种尚未排除的解释。首先，学生缺少教师的邻居传播路径，软标签不能自动增加其输入信息；其次，教师与学生分别有 32,714 和 16,996 个可训练参数，当前实验没有容量匹配；再次，硬标签 L1 与软标签 MSE 对大残差的惩罚不同，有限权重范围和训练预算不保证找到更合适的折中。结果不能区分这些因素各自的贡献。

若进一步用 L2 检验图信息的可替代性，须控制学生容量、可用输入、蒸馏目标与训练选模预算；现有差距尚不能归因于图结构。

4.4 L3 四格溯源层（FET）：全局误差构成

4.4.1 协议操作

L3 将测试预测键按目标侧标签事件 target_event 与冻结规则触发 rule_trigger 交叉为四组：标签事件/规则触发、标签事件/规则未触发、非标签事件/规则触发和非标签事件/规则未触发。本文沿用“四格溯源”这一层名，但此处仅按预定义标签与回溯规则描述误差构成，不表示因果归因。目标侧事件是旧定义下的事后评价标签，冻结规则含代理负荷差分；二者并非分类器的预测与真值，因而不采用混淆矩阵或分类错误术语。

4.4.2 诊断实验

L3 使用原正式 StaticGraph 三个种子的逐键预测重建四格，各格样本量在三个种子间一致：标签事件/规则触发 235 个，标签事件/规则未触发 9,925 个，非标签事件/规则触发 2,825 个，非标签事件/规则未触发 699,375 个。表 4-5 报告 MAE 均值及描述种子波动的标准差。

表 4-5 原正式 MRG-GCN 三种子四格误差分解

分组	target_event	rule_trigger	样本量	占比	MAE（均值±SD）
标签事件/规则触发	1	1	235	0.0330%	0.21723 ±0.00598
标签事件/规则未触发	1	0	9,925	1.3933%	0.27747 ±0.00098
非标签事件/规则触发	0	1	2,825	0.3966%	0.07254 ±0.00591
非标签事件/规则未触发	0	0	699,375	98.1772%	0.00971 ±0.00019
合计	—	—	712,360	100.0000%	0.01376 ±0.00023

注：四格 MAE 为三种子均值±样本标准差；原四格 RMSE 和 WAPE 未在本次三种子锁定汇总中重建，故不填入未经核验的数值。

同一四格的样本组成、三种子 MAE 和误差贡献见图 4-5。图 4-6 的三模型残差密度、图 4-7 的事件分数分箱结果仍为 seed-2024 的描述性诊断：事件相关样本的残差分布更宽，强事件分数档的平均绝对误差最高。二者补充四格中的样本量—误差关系，但不替代三种子主四格证据。

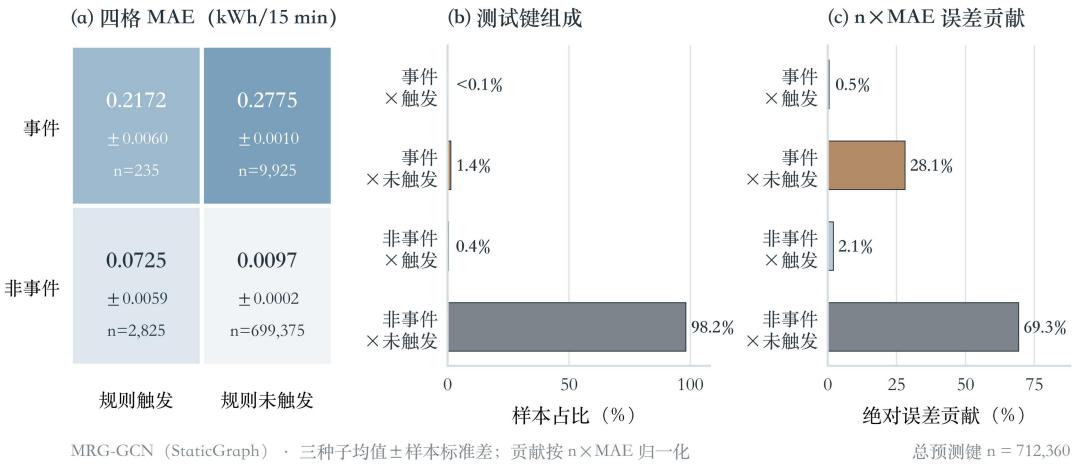


图 4-5　事件标签与规则触发的四格诊断

注：A 为原正式 MRG-GCN 三种子四格 MAE 热图及数值标注，B 展示各格样本占比，C 展示绝对误差贡献。贡献先逐种子按各格$n \times MAE$占总绝对误差的比例计算，再汇总均值及离散度；四格计数来自共同预测键，标签与规则均沿用旧协议定义。

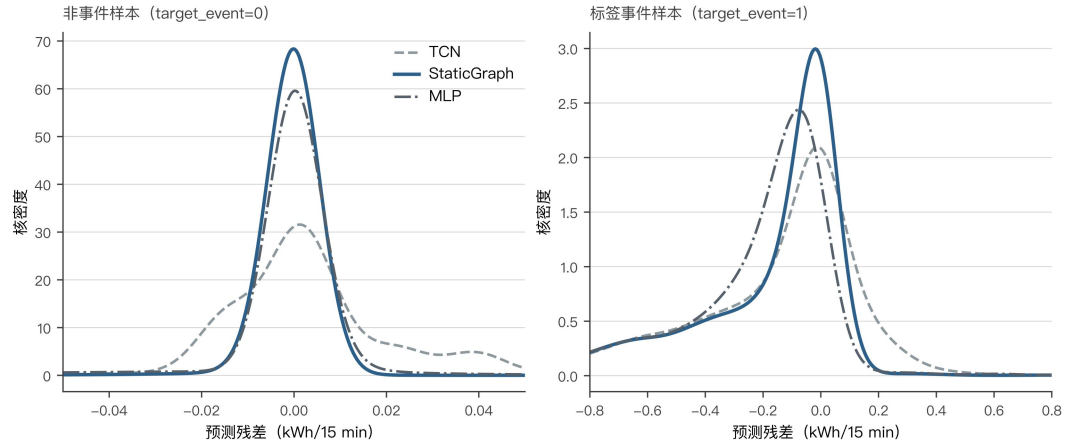


图 4-6　不同模型的残差分布

注：曲线为 seed-2024 中 TCN、StaticGraph 和 MLP 的预测残差密度；左、右面板分别为非事件与事件窗口。该图为描述性比较，不含误差棒。

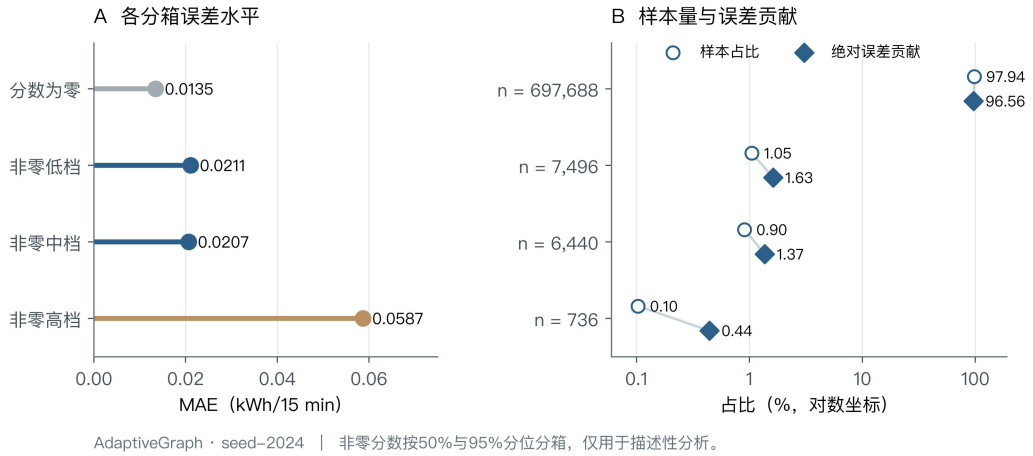


图 4-7 误差与回溯事件分数的关系

注：使用 AdaptiveGraph 的 seed-2024 测试预测键，按预测起点的旧代理事件分数分为零分数和三个非零组；非零分界为测试期非零分数的 50%和 95%分位数，仅用于描述，不用于规则拟合。A 展示组内 MAE；B 以对数坐标对照样本占比与绝对误差贡献，后者按各组$n \times MAE$占总绝对误差的比例计算，行标注为预测键数。两面板按相同分箱顺序排列，不含跨种子误差棒。零分数不等于目标侧非事件，最高分数组不等于冻结触发组；该图不证明实时可见性或因果作用。

4.4.3 还原校验

四格诊断以样本量加权恒等式作为有效性检查：

$$MAE_{global} = \frac{\sum_{a=0}^{l}\sum_{b=0}^{l} n_{ab} MAE_{ab}}{\sum_{a=0}^{l}\sum_{b=0}^{l} n_{ab}}. \tag{4-2}$$

式中，a和b分别表示 target_event 和 rule_trigger，n_{ab}为对应格样本量。原正式 MRG-GCN 三个种子的加权还原差均小于10^{-9}；逐键记录覆盖全部 712,360 个测试键。本次锁定汇总还检查了三种子四格计数、误差贡献与源文件哈希；没有对其他模型作相同的四格还原声明。

4.4.4 L3 判定结论

以每格绝对误差之和占总绝对误差的比例定义贡献C_g，三种子均在逐种子归一化后汇总。标签事件/规则未触发格仅占 1.3933%的预测键，却贡献 28.0995%±0.3654%的绝对误差，是稀有困难样本的集中来源；非标签事件/规则未触发格占 98.1772%，贡献 69.2907%±0.2234%，其单键误差较低，但因样本众多仍构成主要总量。其余两格分别贡献 0.5208%±0.0059%和 2.0891%±0.1362%。因此，评价时需分别报告稀有困难样本误差与常态格总误差贡献；仅凭误差占比不能推断改善稀有事件会降低实际运行风险。

四格恒等还原只验证键分组与算术闭合，不验证因果机制。规则与标签的错位提示回溯分层不能等价替代目标事件；第 5 章据此检查区间半宽路由与覆盖失

配的关系，不将规则触发率解释为在线识别性能。

4.5 MDP 诊断结果与适用边界

MDP 修正了三项判断：L1 将β敏感度解释为β与关系变换共同决定的联合配置变化；L2 将图结构不可替代收窄为当前受检学生未逼近教师；L3 要求并列报告困难格单键误差和常态格总误差贡献。表 4-6 据此列出论文报告与后续研究取舍。

表 4-6 MDP 证据引起的研究判断与后续决策

层次	原解释	诊断结果	修订后的研究判断与可支持的决策
L1	较大β代表关系更重要；冻结替换退化证明其独立增益	冻结替换显示联合配置敏感；函数保持重参数化说明β单独不具可识别的“重要性”；JPL 未重训等权配置	不按β删减关系，也不称其独立增益。关系取舍另依据 3.7.2 节自环替换：负荷与轮廓关系获条件增量证据，行为关系仍不确定；支持后续复核这三种关系，而非按权重排序
L2	蒸馏学生未逼近教师，说明图结构不可替代	当前 TCN 学生未弥合差距；参数量、输入路径及损失设置不匹配；JPL 未复做 L2	结论限于所检学生。当前主张不涉及图结构普遍必要性，故无需据此扩大训练矩阵；若要主张不可替代，须先匹配容量、输入、目标和预算
L3	全局 MAE 足以代表各类样本表现	四格中稀有事件键单键误差较高，常态未触发格贡献多数总误差	主结果并列报告全局与事件/非零分层，后续模型筛选同时检查两类指标；误差份额仅用于确定研究评价重点，不转换为风险或报警阈值

这些判断支持安排关系对照、学生配置核验和分层评价；它们对改模决策及预测性能的实际收益仍需受控实验检验。

4.6 JPL 的 L1/L3 复核与适用范围

4.6.1 复核材料与计算口径

为检验诊断判断是否只出现在 Caltech，本节使用 SG-EXP-028 既有三个正

式 MRG-GCN 检查点和冻结测试数据，追加 L1 关系参数替换及 L3 四格复核。分析在 JPL 测试结果已查看后开展，属于事后诊断；不重新训练、不改变输入、关系图、标签、阈值或选模。基线先按原冻结源码在 CPU 前向重放，每种子 632,640 个预测键的原点、节点、真值、目标时间及掩码均与原导出一致；最大逐键预测差为 2.08×10^{-6} ，低于 5×10^{-6} 的既定容差。独立算术复核覆盖三个种子的 24 组基线/替换输出及 3 组重参数化对照，四格加权还原最大差为 1.39×10^{-17} kWh/15 min。

L1 沿用 4.2.2 节七种操作。“近单一关系”使用相应关系 logit 为 10、其余为 0，Softmax 主权重为 99.9909%，因此不是严格只保留一种关系的结构消融。L3 直接读取原冻结目标侧标签和发布原点规则触发；原点触发广播至四个目标片，阈值仍由原训练/调参流程确定，未依据此次测试分析重新拟合。

4.6.2 L1：整体配置敏感度及样本层面差异

表 4-7 JPL 冻结关系参数替换的分层结果

配置	整体 MAE	标签事件 MAE	稳定 MAE	整体变化/%
学习值	0.081067 ±0.000304	0.422111 ±0.003682	0.073820 ±0.000324	—
第一层近负荷；第二层学习值	0.103703 ±0.008997	0.453735 ±0.048255	0.096266 ±0.008235	27.92
第一层学习值；第二层近轮廓	0.097843 ±0.001102	0.417682 ±0.003894	0.091047 ±0.001052	20.69
两层近负荷	0.123434 ±0.022627	0.501144 ±0.041952	0.115408 ±0.022271	52.26
两层近行为	0.104072 ±0.024635	0.427197 ±0.025078	0.097206 ±0.025649	28.38
两层近轮廓	0.106241 ±0.003802	0.476894 ±0.007734	0.098365 ±0.003718	31.05
两层等权	0.088149 ±0.002406	0.419897 ±0.004949	0.081100 ±0.002471	8.74
交换两层学习值	0.092807 ±0.007848	0.419053 ±0.001792	0.085875 ±0.007996	14.48

注：单位为 kWh/15 min，均值±样本标准差来自 2024、2025、2026 三个种子；整体变化以学习值基线三种子均值为分母。表中替换仅改变冻结模型的两层关系 logit，其他参数保持；近单一权重的定义见 4.6.1 节。不同种子共享同一测试期，标准差不表示跨场站不确定性；本节不作确认性显著性判断。

七种替换的整体 MAE 在三个种子下均高于各自学习值基线；三种子均值的整体增幅为 8.74%～52.26%。但“第二层近轮廓”、两层等权及交换学习值的标签事件 MAE 均值分别为 0.417682、0.419897 和 0.419053，略低于基线 0.422111。这与旧 Caltech 的分层响应不同，说明联合配置的整体敏感度可以在 JPL 观察到，样本层面的响应方向与幅度仍受协议及场站条件影响。

进一步令两层 $\beta_r^{'} = 1/3$，同时将相应无偏置关系变换改为 $W_r^{'} = 3\beta_r W_r$，冻结

其余参数，仅执行前向。三个种子的重参数化预测与各自学习值预测最大逐键差分别为 1.55×10^{-6} 、1.55×10^{-6} 和 1.20×10^{-6} ，均在同一容差内。该检查在 JPL 已有权重上落实了 4.2.5 节的函数保持关系：只替换β引起退化，仍不能单独证明β有独立正增益；此处也没有进行 JPL 等权重训练。

4.6.3 L3：困难样本与总误差组成

表 4-8 JPL 原正式 MRG-GCN 三种子四格误差分解

样本格	预测键数	样本占比/%	MAE（均值±样本标准差）	绝对误差份额/%
标签事件 / 规则触发	831	0.1314	0.464647 ±0.010446	0.7529
标签事件 / 规则未触发	12,332	1.9493	0.419245 ±0.003322	10.0810
非标签事件 / 规则触发	26,185	4.1390	0.167867 ±0.000881	8.5708
非标签事件 / 规则未触发	593,292	93.7803	0.069670 ±0.000331	80.5953

注：单位为 kWh/15 min；预测键数和掩码在三个种子间完全一致，误差份额为各种子“格内绝对误差和 / 全体绝对误差和”的均值。四格加权 MAE 还原原正式三种子整体均值 0.081067。目标侧事件仅用于事后评价，规则触发是发布原点的既有分组信号，二者不组成同一时刻的事件检测混淆矩阵。

标签事件 / 规则未触发格占 1.9493%的预测键，贡献 10.0810%的绝对误差，格内 MAE 为 0.419245；非标签事件 / 规则未触发格占 93.7803%，格内 MAE 为 0.069670，却贡献 80.5953%的绝对误差。JPL 同样要求兼顾稀有困难格的单键误差和常态格的累计误差，不能用一个总体指标替代两者。Caltech 旧协议相应稀有格的误差份额为 28.0995%，与 JPL 不同；两协议的输入、标签和规则不同，不对格内绝对误差作直接跨协议效应比较，也不把误差份额解释为运行风险。

4.6.4 复核结论与剩余验证范围

JPL 复核表明，L1 整体配置敏感度与 L3 四格误差结构可在另一 ACN 场站的既有检查点上复算，样本格响应与 Caltech 不同；该复核未覆盖 L2，也未检验诊断指导改模的预测收益。SG-EXP-031 为邻接替换后重训，本节则冻结门控权重作前向干预，两者回答不同问题，不能合并解释。

第 5 章　模型结构与可靠性边界分析

5.1 引言

第 4 章揭示了整体指标与困难样本表现的差异。本章进一步按“结构候选—区间可靠性—运行条件”检验证据：训练段 TE 候选经家族校正后无一保留；Caltech 与 JPL 冻结预测的整体覆盖不能代表事件覆盖；固定代理轨迹与合成线性规划仅用于核验接口及其条件。

5.2 方向性统计候选与结构对照

本节用同一训练段序列开展传递熵（TE）筛查与 PCMCI+条件独立检验，并按有向节点对比较历史名义结果，流程见图 5-1。

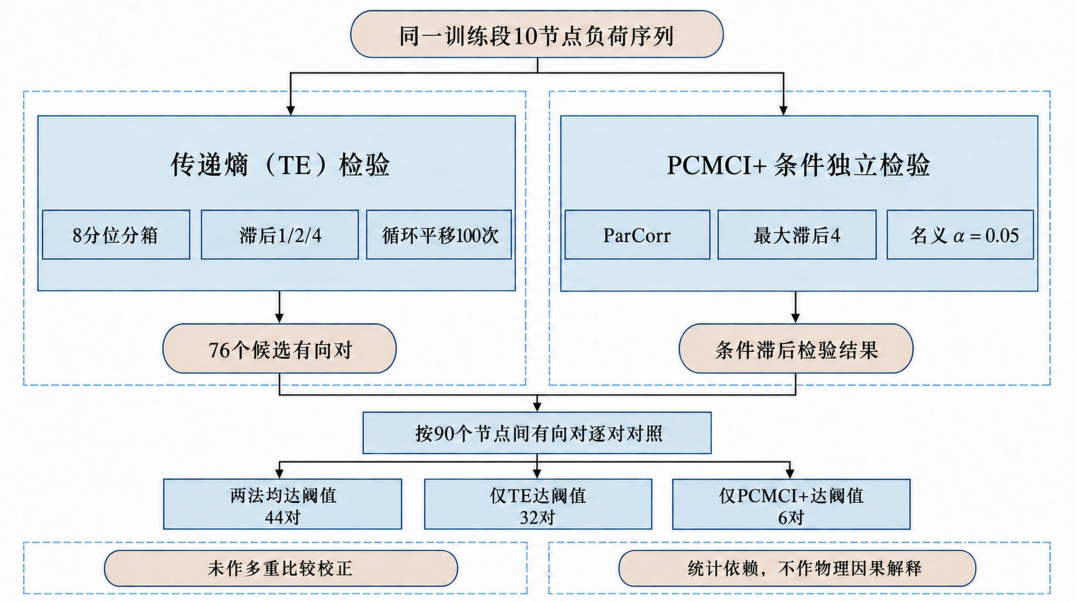


图 5-1 TE 候选生成与 PCMCI+条件独立检验流程

注：两法均使用训练期 10 节点序列；44/32/6 分别为两法均、仅 TE、仅 PCMCI+达到名义阈值的有向对数（未经多重校正）。该对照基于同一序列，不构成独立复现；TE 候选经家族校正后无一保留。

5.2.1 问题与动机

第 3 章的 LRE 三关系图均为无向对称统计量，可描述节点间耦合强度，却不含先后方向与候选时滞；若一个节点的历史变化能为另一节点的后续负荷提供附加信息，这种不对称性便会被无向图压缩。本节据此提出待验证假设：站内节点间可能存在方向性、滞后的统计依赖，其中方向仅表示信息先后。

5.2.2 传递熵方向性检验

采用传递熵（transfer entropy，TE）[88]衡量给定目标历史后，源节点滞后取值对目标当前值提供的条件信息：

$$TE_{X\to Y}(\ell) = H(Y_t|Y_{t-\ell}) - H(Y_t|Y_{t-\ell}, X_{t-\ell}) = I(X_{t-\ell}; Y_t|Y_{t-\ell}). \quad (5\text{-}1)$$

对 10 个节点的 90 条有向对，在滞后$\ell \in \{1,2,4\}$下进行 8 分位分箱估计，并以每个“有向对×滞后”100 次循环平移置换构造零分布。循环平移尽量保留单序列自相关，但不消除共同驱动或滞后选择的不确定性。归档程序先在三个滞后中按最小置换p值选择滞后，再以$p < 0.05$标记候选；此选择使完整检验族包含 90×3=270 项。每个检验的最小可达p值为 1/101≈0.00990，故未经校正的候选只作探索性筛查。

5.2.3 传递熵名义候选与双向读数不对称

在 90 条有向节点对中，76 条通过未经校正的名义阈值（84.4%）；按 45 个无向节点对汇总，其中 31 对双向通过、14 对单向通过。对双向选定滞后下的 TE 读数，定义描述性不对称度

$$ASYM_{ij} = \frac{|TE_{i\to j} - TE_{j\to i}|}{TE_{i\to j} + TE_{j\to i} + \epsilon}, \quad (5\text{-}2)$$

其中ϵ仅避免分母为零。以$ASYM > 0.3$作描述性标记，得到 20 对 (44.4%)；两个方向各自按其滞后p值选择 TE，因此该指标不是共享滞后下的效应差，也未检验不对称性的统计显著性。对完整 270 项检验族作 Bonferroni 校正后，76 条候选均未达到 0.05；最小校正p值为 1.00。故图 5-2 和图 5-3 呈现的是未校正候选及读数差异，不支持“存在显著方向效应”的结论。

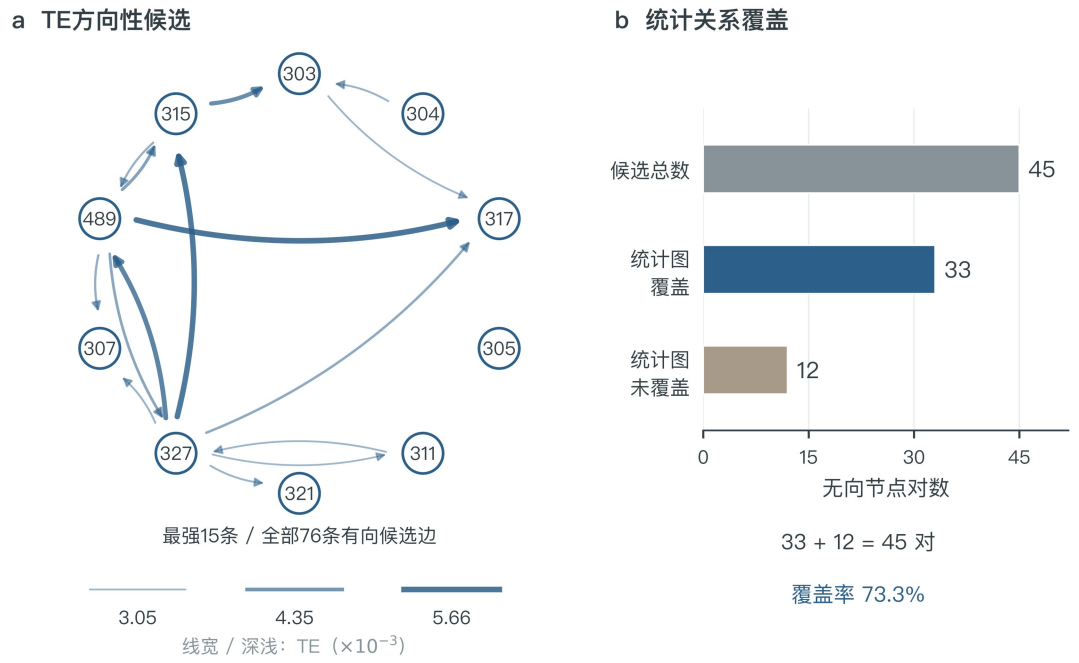
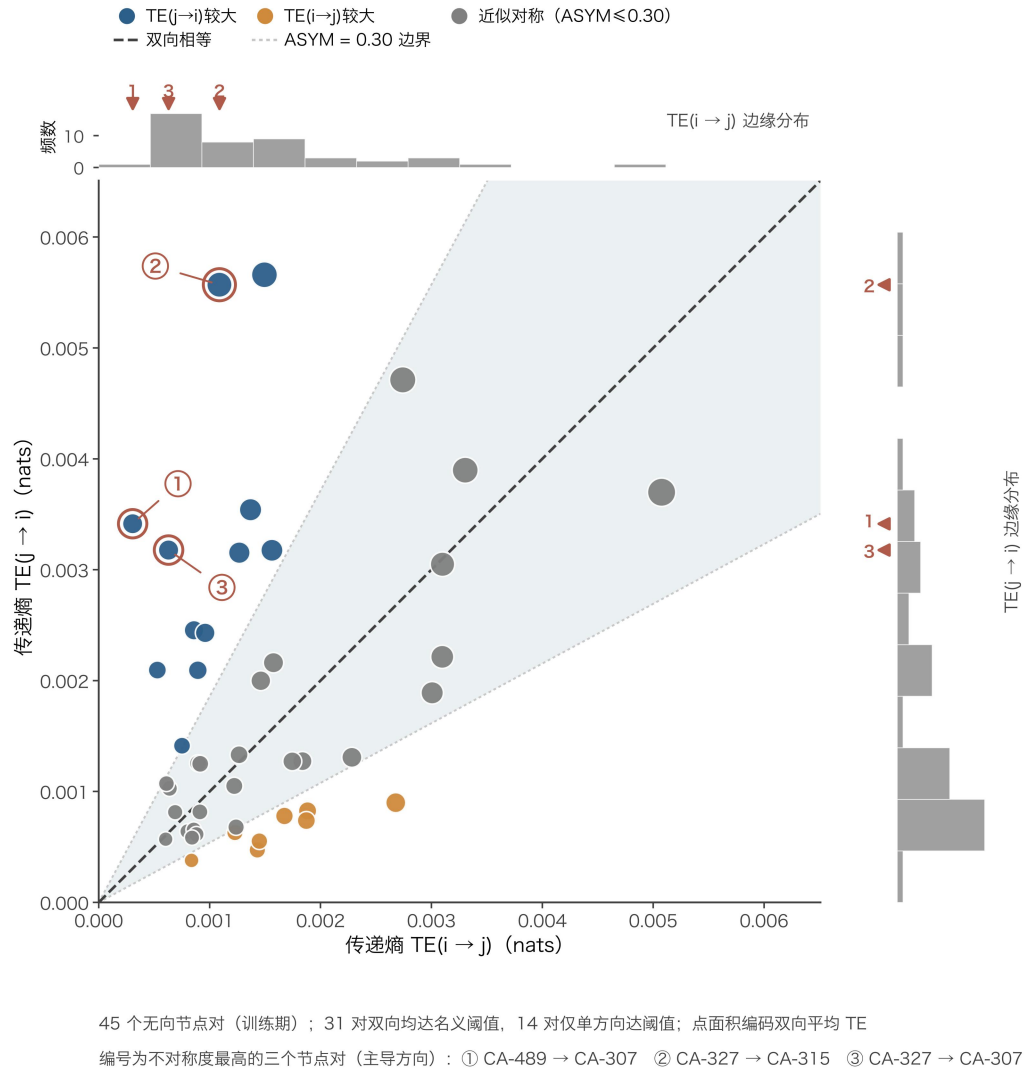


图 5-2 传递熵方向性候选结构

注：基于 seed-2024 训练期数据，左图展示 TE 值较高的 15 条候选边，右图汇总候选边被三类统计关系覆盖的情况。箭头表示方向性候选，线宽表示 TE 强度；100 次循环平移置换未做多重比较校正，无误差棒。

5.2.4 有向候选边与统计关系图的互补性

76 条 TE 候选对应 45 个无向节点对，其中 33 对被至少一类 LRE 图覆盖，12 对未覆盖。覆盖统计统一采用 top-k=3，但不保证对称化后的实际边数相同；这一探索性设置与旧回溯主模型一致，事件时刻协议另用 top-k=5。TE 候选与负荷耦合、行为共现和轮廓相似图的 Jaccard 系数分别为 0.444、0.489 和 0.378，TE 强度与三类关系权重的 Spearman 系数分别为 0.27、−0.15 和 0.26。两者部分重叠，未覆盖候选也仍需校正与验证。覆盖统计见表 5-1，逐边对应见图 5-4。



45 个无向节点对（训练期）；31 对双向均达名义阈值，14 对仅单方向达阈值；点面积编码双向平均 TE

编号为不对称度最高的三个节点对（主导方向）：① CA-489 → CA-307　② CA-327 → CA-315　③ CA-327 → CA-307

图 5-3　双向传递熵与描述性不对称度

注：每个点对应一个无向节点对，坐标为两个方向各自选定滞后的 TE 读数，虚线表示双向读数相等。灰带对应$|F - B|/(F + B) \leq 0.3$；蓝、橙点分别表示较大的读数来自横轴或纵轴方向。45 对中 20 对（44.4%）超过该描述性界值；此比例不检验方向差异的统计显著性。图中 TE 名义候选未经多重比较校正，完整 270 项检验族校正后无候选保留。

表 5-1 TE 候选与 LRE 统计关系的覆盖情况

项目	数值	说明
通过名义阈值的有向 TE 候选	76/90	未做多重比较校正
Bonferroni 校正后保留的 TE 候选	0/90	对 90 条有向对×3 个滞后的 270 项检验族校正；最小校正p值为 1.00
对应无向节点对	45	31 对双向候选，14 对单向候选
至少被一类统计图覆盖的节点对	33/45	探索性比较统一采用 top-k=3
未被统计图覆盖的节点对	12/45	仅指当前统计图未覆盖
与负荷耦合图的 Jaccard 系数	0.444	探索性比较
与行为共现图的 Jaccard 系数	0.489	探索性比较
与轮廓相似图的 Jaccard 系数	0.378	探索性比较

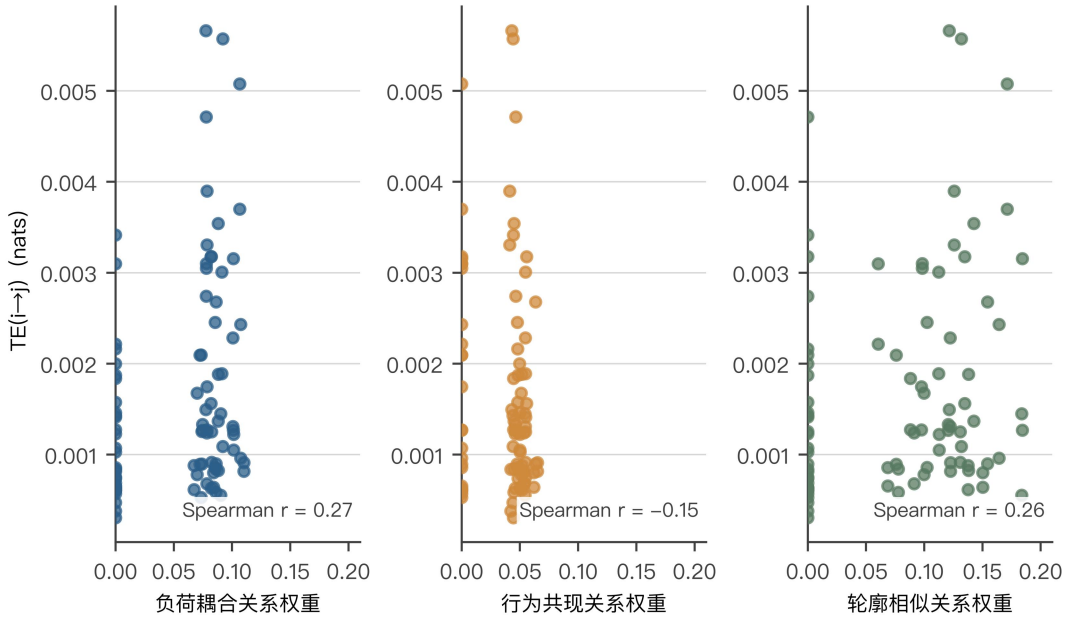


图 5-4 TE 与统计关系权重的对应

注：90 条有向节点对分别与三类固定统计关系权重比较，Spearman 系数标注于图内。灰色叉号表示 TE 为零的边；该图为单种子、未校正的探索性比较。

5.2.5 PCMCI+条件独立检验与版本敏感性

为检查 TE 候选与条件独立检验是否给出相近的方向对，进一步采用 PCMCI+[89-90]。历史归档输入为训练段 10 个节点的 83,198 个原始时间观测，而非窗口化后的 83,103 个预测起点；采用 ParCorr、最大滞后 4 片和$\alpha = 0.05$。归档记录 80 个达到名义阈值的滞后单元；按有向节点对汇总，76 条 TE 候选中 44 条同时出现在 PCMCI+名义结果中（57.9%），32 条未出现。PCMCI+另记录 16 个 TE 汇总中未出现的有向对，包括 6 个节点间对和 10 个自回归对；这些都是未校正历史计数，同一节点对可对应多个滞后，不能将对数与滞后单元数等同。图 5-5 仍按历史归档结果绘制。

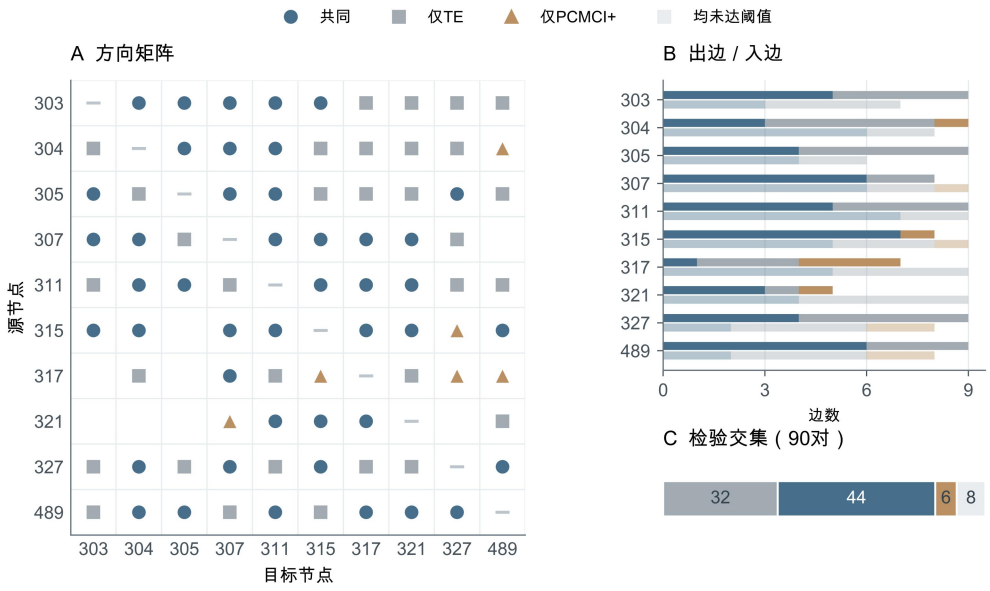


图 5-5 PCMCI+条件独立检验与 TE 名义候选对照

注：A 以行为源节点、列为目标节点，区分历史归档中两法均达名义阈值的 44 对、仅 TE 达到阈值的 32 对和仅 PCMCI+达到阈值的 6 对，空白格表示两者均未达到阈值。B 按相同节点顺序汇总 82 个至少被一种检验列为名义候选的节点间有向对的出边与入边构成，各行上条为出边、下条为入边。C 汇总全部 90 个节点间有向对，其中 8 对在两种检验中均未达到名义阈值。10 个自回归对均排除，对角线短横线表示不纳入本图比较。输入为训练段 83,198 个原始时间观测，采用 ParCorr、最大滞后 4 个时间片和$\alpha = 0.05$，历史结果未进行多重比较校正。

历史 PCMCI+汇总缺少完整p值矩阵及 Tigramite 版本，无法对其 80 个入选滞后单元追溯多重校正。为评估环境版本敏感性，使用当前锁定张量和 Tigramite 5.2.10.1 对全部 360 个非对角有向对×滞后单元（90×4）重算：65 个达到名义阈值，Holm 校正后 22 个滞后单元、对应 21 个有向节点对仍低于 0.05。该复算与历史 80 个名义单元不一致，故仅作为当前环境下的敏感性结果，未替换图 5-5 或历史交叉计数；它也不消除 PCMCI+数据驱动筛选与共同驱动问题，不应解释为物理因果边。TE 没有任何候选通过 270 项家族校正。

5.2.6 方向性证据的解释边界与复核路径

本文将 TE 与 PCMCI+结果保留为训练段候选筛查，未回灌 MRG-GCN，也不解释为因果边。后续若纳入有向关系，须预先固定构图规则，并在统一数据划分、预测键、模型容量、种子及训练与选模预算下检验增量；若仍使用本研究已查看的时期，结果只能称为探索性。独立时期确认须待取得兼容的新时期数据后开展，本文目前尚无此类数据。

5.3 事件感知的区间预测：分层共形预测

5.3.1 问题与动机

整体点预测误差不足以判断区间可靠性。本节依次报告独立校准、成熟标签滚动更新和回溯规则设置下 Caltech 与 JPL 的区间表现，并用标签事件参照检查覆盖失配[91-93]。

5.3.2 分层共形方法

对冻结模型的校准绝对残差$r = |y - \widehat{y}|$，以$\alpha = 0.1$构造目标覆盖率 90%的区间。独立校准采用第$\lceil (n+1)(1-\alpha) \rceil$个顺序统计量；回溯历史实现保留原经验分位数，二者按协议区分。标准共形对每个节点估计全局半宽q_n；规则路由分层共形则将预测键按冻结规则分为触发层和未触发层：触发层样本稀少，使用跨节点统一半宽q_{trig}；未触发层样本较多，使用逐节点半宽$q_{stable,n}$。测试区间为

$$[\widehat{y} - q, \widehat{y} + q], q = \begin{cases} q_{trig}, & rule_trigger = 1, \\ q_{stable,n}, & rule_trigger = 0 \end{cases} \tag{5-3}$$

目标侧事件标签仅用于分组评价；按其选择半宽的 oracle 为事后参照。各路径均以冻结点预测和校准期绝对残差确定半宽，校准段及更新方式按协议区分。图 5-6 仅展示旧回溯协议的规则路由：旧规则含事后代理负荷差分，验证段参与模型选择，且采用未修正经验分位数，均属于历史实现限制。当前事件时刻协议下的行为输入独立校准、成熟标签滚动校准及 JPL 校准见 5.3.3—5.3.5 节；重叠窗口与分布变化仍需经验评价。

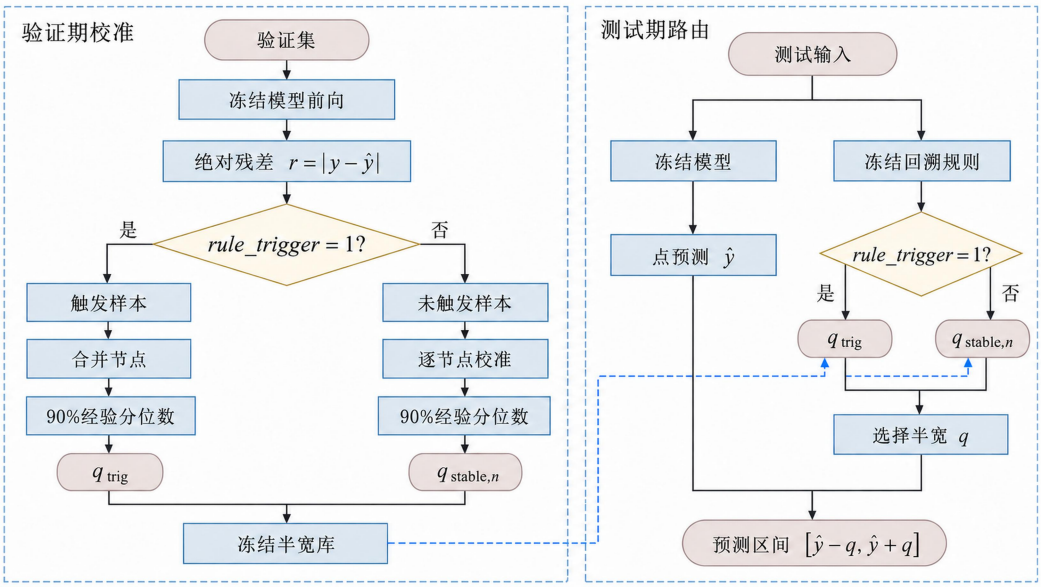


图 5-6　冻结规则路由的分层共形方法

注：左侧为验证期校准：冻结主模型生成绝对残差，触发层合并节点估计 90%经验分位数，未触发层逐节点校准。右侧为测试期回溯路由：冻结旧规则选择半宽q，与点预测$\widehat{y}$共同形成区间。目标侧标签事件不参与规则路由；旧规则含事后代理负荷差分，不表述为在线可见，90%经验分位数不等同于测试覆盖保证。

5.3.3　事件时刻输入协议下的独立校准补充

本分析复用三种子冻结预测；模型由调参段选定，校准和测试完整窗口、目标时间片互不重叠。标准路径逐节点校准，行为分层路径将触发组跨节点汇聚、未触发组逐节点校准，目标事件标签仅用于评价。半宽取秩$k_g=\lceil(n_g+1)(1-\alpha)\rceil$的残差，$\alpha=0.1$；各节点标准组含 35,220 个校准键，触发组含 2,964 个[92]。重叠窗口依赖与分布变化仍可能影响测试覆盖，独立校准段本身不保证 90%覆盖[93]。

表 5-2　新协议独立校准的覆盖与区间质量

路径	整体覆盖率 /%	事件覆盖率 /%	稳定覆盖率 /%	平均宽度	区间分数
标准逐节点	79.55 ±0.23	3.87 ±0.09	80.66 ±0.23	0.02757 ±0.00040	0.74551 ±0.00563
行为规则分层	80.04 ±0.26	5.92 ±0.15	81.13 ±0.26	0.03951 ±0.00037	0.73214 ±0.00548

注：三种子均值±样本标准差；测试共 708,560 键，其中标签事件 10,204 键。宽度与区间分数单位为 kWh/15 min。区间分数为区间宽度加 $2/\alpha$倍越出区间的距离，越小越好；保留原预测及未截零的对称区间端点。本文未按测试覆盖调整半宽。该表属于新协议，不能与表 5-4 相减来估计独立校准的因果收益。

两条路径整体覆盖均低于 90%。行为分层较标准路径将整体覆盖提高 0.49 个百分点、事件覆盖提高 2.05 个百分点，但区间宽度增加 43.3%，事件覆盖仍不足。校准与测试的标签分布发生变化，测试事件中多数未触发行为规则并使用较

窄半宽；结果提示分布失配和路由错位需要并列检查，尚未验证实际上报时延。

5.3.4 成熟标签约束下的滚动校准回放

为缓解独立校准的覆盖失配，保持点预测、行为规则和$\alpha = 0.1$不变，改用随时间更新的历史残差。事先固定 14 天为主要回看窗口、28 天为窗口敏感性，每个洛杉矶当地零点更新一次；回看长度按经过的 14 或 28 个 24 h 计算。残差纳入须满足：预测已发布、目标片已结束、关联会话断开后节点标签已成熟，且目标片起点位于回看窗口内。若无合格样本，回退至原独立校准半宽；有限样本秩超过样本数时取无穷大，本次回放未出现无穷区间。

每种窗口均报告逐节点标准路径和行为分层路径，规则触发仅用于后者的分组与路由，目标事件标签仅用于事后评价。结果见表 5-3。更新只利用发布时刻前已经成熟的标签，这是遵守时间先后的历史回放；由于测试时期已查看，且序列与重叠目标具有依赖性，不将其称为未见时期验证或具有交换性保证的独立样本实验[92-93]。

表 5-3 新协议成熟标签滚动校准回放结果

校准方式	整体覆盖/%	事件覆盖/%	平均宽度	区间分数
冻结逐节点	79.55	3.87	0.02757	0.74551
冻结行为分层	80.04	5.92	0.03951	0.73214
14 天逐节点	89.03	26.44	0.17223	0.67844
14 天行为分层	89.01	26.71	0.17649	0.66952
28 天逐节点	88.83	24.99	0.15437	0.68014
28 天行为分层	88.88	25.18	0.15916	0.66979

注：三种子均值，同一 708,560 个测试键；宽度与区间分数单位为 kWh/15 min，分数越小越好。14 天行为分层整体覆盖为 89.01%±0.05%，事件覆盖为 26.71%±0.12%，标准差只描述种子波动。窗口固定后报告全部方案，不按测试覆盖挑选最优配置。

14 天滚动更新较冻结行为分层提高整体覆盖 8.97 个百分点、事件覆盖 20.79 个百分点，区间分数下降约 8.6%；平均宽度扩大至 4.47 倍。逐节点路径整体覆盖相近（89.03%），尚无行为分层独有增益证据。事件覆盖仍仅 26.71%，且测试期已查看，故该回放只支持其缓解所检时期失配的可能性，不支持可靠事件防护；成熟标签等待、事件稀疏和规则漏触发的作用尚未分开。

5.3.5 JPL 既有预测的独立校准补充

JPL 预留校准段可用于检查另一场站的经验覆盖。本文复用 SG-EXP-028 的三种子冻结预测，保持 5.3.3 节的两条路径和$\alpha = 0.1$：标准路径逐节点汇聚四个目标片的残差，行为分层路径将触发键跨节点汇聚，未触发键逐节点计算。半宽仅由 313,120 个校准键的有限样本顺序统计量确定，632,640 个测试键只用于评

价；两段原点及目标时刻集合无交集。该分析在测试期已查看后开展，未调节规则、模型或半宽以迎合测试覆盖。

标准逐节点与行为分层路径的整体覆盖分别为 90.08%和 90.11%，事件覆盖分别为 46.43%和 45.88%，非零目标覆盖为 65.82%和 66.01%。行为分层未提高事件覆盖。该结果只描述已查看的固定测试期；现有区间不足以支持事件预警或保护动作，业务可接受的区间宽度也尚未确定。

5.3.6 回溯补充：覆盖与路由错位

表 5-4 显示，标准与规则路由的事件覆盖仅 1.9%和 3.9%，远低于 90%目标；事后按标签事件路由可达 86.1%，但该标签预测时不可见，不能代表部署表现。

表 5-4 不同共形口径的经验覆盖率

校准与路由方式	整体覆盖率	标签事件窗口覆盖率	稳定窗口覆盖率	解释
标准共形	69.6%±1.7%	1.9%±0.5%	70.5%±1.8%	全局逐节点校准
规则路由分层共形	69.8%±1.8%	3.9%±0.5%	70.7%±1.8%	旧冻结规则回溯路由，覆盖未达标
标签事件事后参照（oracle）	70.1%±1.8%	86.1%±0.0%	69.9%±1.9%	标签路由，预测时不可用

注：均值和标准差来自 2024、2025、2026 三种子；覆盖率为测试集经验值，未作有限样本秩修正。

测试键中规则触发占 0.43%，标签事件占 1.43%；3,060 个触发键中仅 235 个属于标签事件，多数事件因此进入较窄的未触发层。该错位可解释部分覆盖不足，但不能排除残差分布变化和有限样本影响。

三类覆盖口径见图 5-7，触发层半宽相对全局半宽的膨胀见图 5-8。规则触发层的统一半宽为 0.651±0.005 kWh/15 min，远大于逐节点全局残差半宽，反映触发层残差分布更宽。

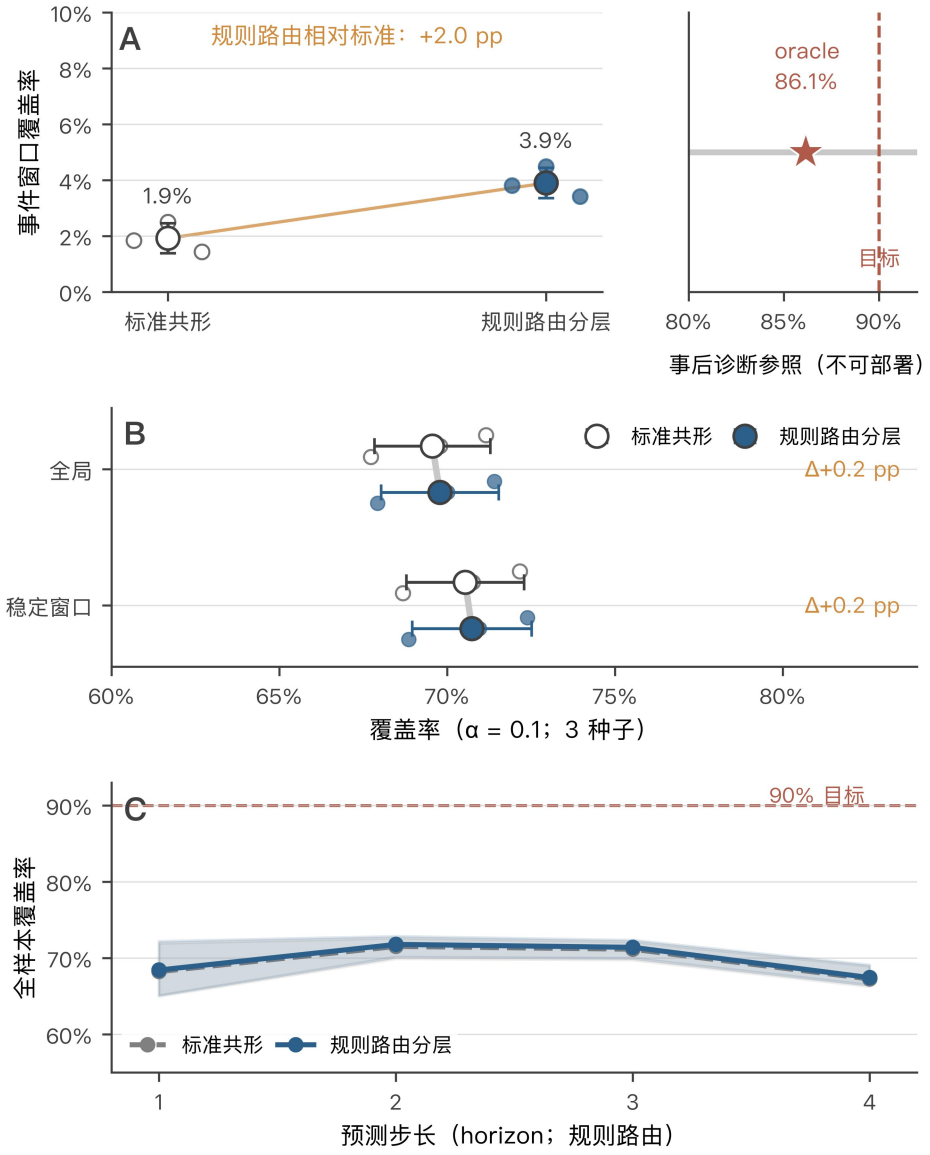


图 5-7 共形覆盖率比较

注：A 比较标签事件窗口中的标准、规则路由和 oracle 结果；B 比较整体与稳定窗口；C 为规则路由下第 1—4 个目标片的整体覆盖率。散点为单种子读数，误差棒为跨种子标准差，阴影为 min–max 范围。

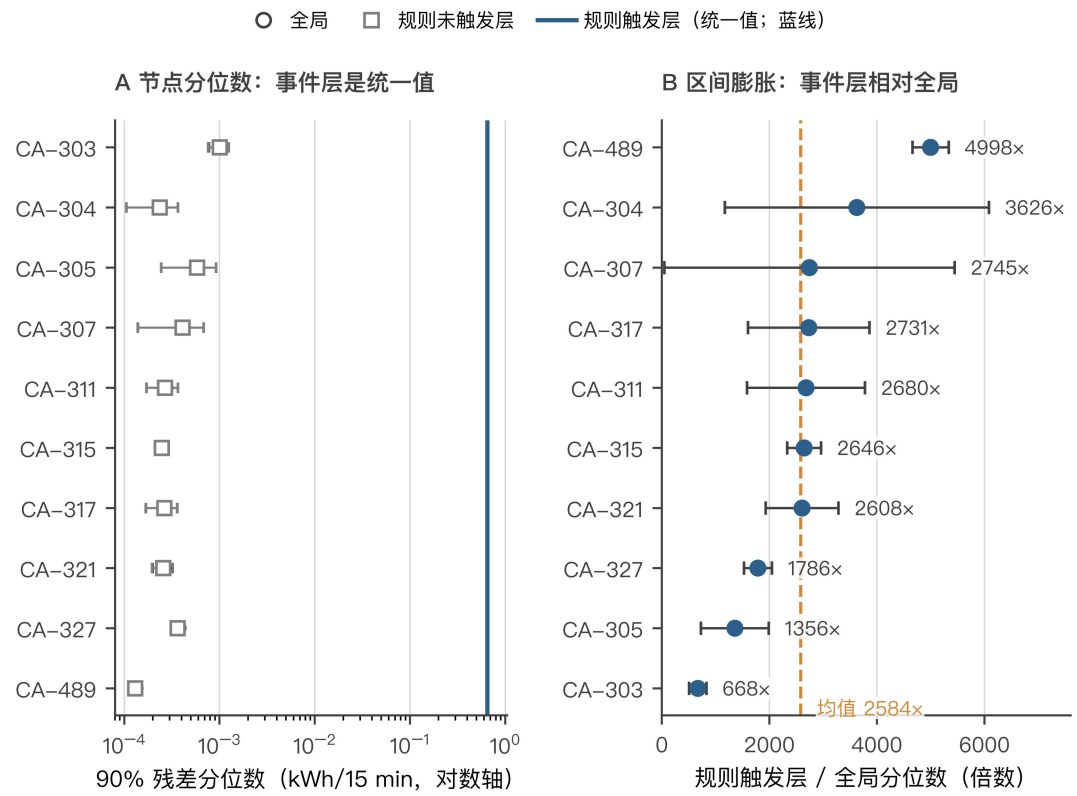


图 5-8　分层残差分位数与区间膨胀

注：A 比较全局、规则未触发层和规则触发层的 90%残差分位数；B 给出触发层相对全局分位数的倍数。点和误差棒为三种子均值±标准差；规则触发层使用统一分位数。

规则路由下各节点的平均区间宽度列于表 5-5。

表 5-5　规则路由分层共形的节点级区间宽度

节点	区间宽度/(kWh/15 min)
CA-303	0.0105±0.0005
CA-311	0.0091±0.0001
CA-327	0.0091±0.0001
CA-489	0.0071±0.0001
CA-321	0.0069±0.0002
CA-305	0.0064±0.0006
CA-315	0.0051±0.0001
CA-304	0.0040±0.0002
CA-307	0.0028±0.0006
CA-317	0.0025±0.0002

注：数值为三种子均值±样本标准差。区间宽度受节点残差与规则触发层分位数共同影响，不将其解释为节点风险的唯一度量。

5.3.7　回溯补充：残差失配诊断

为区分路由错位与校准失配，保持原模型、冻结规则和验证期分位数不变，重新前向验证集并核对归档测试预测。三种子的原校准半宽均在浮点容差内复现，各覆盖指标与旧汇总的最大差异为 0.0064 个百分点，不改变表 5-4 的显示值。新增统计只作事后失效诊断，不利用测试分位数重新校准或选择阈值。

表 5-6 冻结区间的覆盖失效诊断

诊断量	验证期或标准路径	测试期或规则路径	解释
全体绝对残差 p50	0.000178	0.000220	测试/验证为 1.24 倍
全体绝对残差 p90	0.000716	0.002507	测试/验证为 3.50 倍
全体绝对残差 p95	0.000912	0.008759	测试/验证为 9.60 倍
标签事件/触发（235 键）覆盖率	0.85%	86.52%	触发半宽增宽，但该组很少
标签事件/未触发 (9,925 键）覆盖率	1.95%	1.95%	大多数标签事件仍接受窄区间
非标签事件/触发 (2,825 键）覆盖率	5.83%	96.07%	增宽也覆盖非标签事件键
非标签事件/未触发 (699,375 键）覆盖率	70.80%	70.63%	大样本稳定组同样未达目标

注：前三行为每种子先跨预测键计算分位数，再取三种子均值，单位 kWh/15 min；不是逐节点校准半宽的均值。后四行为相同四格内标准与规则路径的测试经验覆盖率，先逐种子计算再取均值。预测窗口重叠，不作独立样本显著性推断。

覆盖不足首先表现为路由错位。235 个标签事件/触发键的规则覆盖为 86.52%，9,925 个标签事件/未触发键仅为 1.95%；区间增宽没有惠及多数标签事件。同时，2,825 个非标签事件/触发键的覆盖为 96.07%，说明半宽路由与目标标签分层并不一致。两者属于不同定义的分组，不等同于分类漏报和误报。

第二条证据链是校准失配。测试残差 p90 和 p95 分别为验证期的 3.50 倍和 9.60 倍；按 3 种子、10 节点和 4 个目标片分别计算的 120 组 p90，测试期均高于验证期。规则整体覆盖率的月度三种子均值从 2021 年 3 月 79.34%降至 9 月 59.13%，目标标签事件占比从 0.83%升至 2.28%；首末月仅覆盖部分日期，不据此推断单调趋势。

该事后诊断表明残差尾部变化与冻结半宽失配并存，但未识别成因，也不是预登记漂移检验；分层样本稀疏及节点、目标片汇聚仍可能影响读数。旧协议未设独立校准段，且测试时期已查看；新协议独立校准结果见 5.3.3 节。

5.4 节点负荷预测的决策接口与验证条件

5.4.1 预测量与运行量的对应

本节将节点预测汇总为集合代理需求，定义容量核查与充电协调的输入接口。设t为发布时刻，预测对象为$[t, t+60min)$内的 4 个连续 15 min 目标片；以目标片左端时刻τ标记时间片，$h = 1, \ldots, 4$依次对应左端t、$t+15$、$t+30$和$t+45$ min；$\mathcal{N}$为 10 个研究节点。首片虽以发布时刻为左端，预测量仍是该片完整区间的能量。集合代理需求及预测值为

$$D_\tau = \sum_{n\in\mathcal{N}} y_{\tau,n},\ \widehat{D}_{t,h}^{(m,s)} = \sum_{n\in\mathcal{N}} \widehat{y}_{t,h,n}^{(m,s)}. \tag{5-4}$$

其中，m和s分别表示模型配置与随机种子。D_τ和$\widehat{D}_{t,h}$的单位为 kWh/15 min，表示会话最终交付电量按接入至断开期间均匀分配后得到的区间能量代理；后文省略模型和种子上标。对$\Delta t = 0.25$ h 的时间片，除以时间长度可得到区间平均代理功率：

$$\widehat{P}_{t,h}^{proxy} = \frac{\widehat{D}_{t,h}}{\Delta t} = 4\widehat{D}_{t,h}. \tag{5-5}$$

该换算仍是代理平均功率，不能恢复片内波动。预测仅覆盖 10 个研究节点；与全站限额比较前，还需校准同步电表并补入其他节点和非充电负荷。

5.4.2 从预测曲线到运行核查

预测进入运行核查前，需先核对时间戳、节点映射、输入可见性和目标片；校准后可作为影子运行中的需求提示，与其他负荷、限额和备用裕度合并计算余量：

$$M_{t,h} = P_{\lim} - P_{other,t,h} - \widehat{P}_{EV,t,h}^{cal} - R_{t,h}. \tag{5-6}$$

各项单位为 kW，依次表示有功限额、非充电负荷、校准后的全站充电预测及规程裕度。15 min 平均量不能检验瞬时尖峰、三相不平衡或热约束，正余量也不代表安全认证。当前缺少完整运行输入，式（5-6）仅定义核查接口；若开展影子运行，还需同步记录数据更新时间、复核结果和电表读数，输入缺失或校准失效时停止使用预测。

5.4.3 固定发布时刻的四目标片算例

为展示预测曲线，选取测试记录中按时间顺序出现的首个合格代理需求过程，不依据模型误差选例。发布时刻为 2021 年 3 月 16 日 13:00，过程起点为 13:45，故提前量为 45 min；60 min 是第四片终点。表 5-7 列出 MRG-GCN 三个种子的该原点预测及离散度，不代表集成预测或区间预测。

表 5-7 固定发布时刻下的节点集合四目标片预测示例

目标片起点	目标片起点相对发布时刻/min	预测代理需求/实际代理需求（kWh/15 min）	预测/实际区间平均代理功率（kW）
13:00	0	0.7624±0.1041 / 0.8080	3.05 / 3.23
13:15	15	0.7262±0.0894 / 0.8080	2.90 / 3.23
13:30	30	0.6879±0.0767 / 0.8080	2.75 / 3.23
13:45	45	0.6548±0.0728 / 1.1505	2.62 / 4.60

注：预测均值与样本标准差基于 3 个独立种子；功率为代理能量除以 0.25 h 所得的区间平均等效值，不是实测功率。目标时间片以左端时刻标记。

预测呈回落趋势，未捕捉 13:45 的代理需求跃升，末片低估 0.4957 kWh/15 min（43.1%）。该固定案例提示需单独评价局部低估；它不代表实测越限或安全验证。

5.4.4 有限时域充电分配与合成决策算例

为说明预测如何进入有限时域充电分配，构造如下线性规划。令$p_{j,h}$为车辆j在时间片h的计划功率，π_h为单位电量记账价格，目标是在满足车辆请求的前提下降低计划成本：

$$\min_{\{p_{j,h}\}} \sum_{h=1}^{K} \pi_h \Delta t \sum_j p_{j,h}. \tag{5-7}$$

每辆车具有服务窗、剩余电量需求和功率上限，并满足能量请求及站点容量约束。容量式中的不可调充电基线须经计量校准；若全站预测已含可调车辆，再将同一车辆请求加入会重复计量。当前模块只输出供复核的计划；采用无损、连续功率假设，未建模 V2G、三相约束、离散电流、效率和执行偏差。超出四片时域的请求还需扩展时域或验证终端可行性。

合成算例设置一辆车在四片内请求 1 kWh、功率上限 3 kW；不可调充电与其他负荷各 1 kW，站点限额 6 kW、备用 1 kW，价格为 4、3、2、1。参数均为人工设定。求解结果见表 5-8。

表 5-8 合成四片充电分配的影子计划

项目	第 1 片	第 2 片	第 3 片	第 4 片
单位电量记账价格	4	3	2	1
不可调充电/kW	1	1	1	1
非充电负荷/kW	1	1	1	1
可调车辆功率/kW	0	0	1	3
合计计划功率/kW	2	2	3	5

计划满足 1 kWh 请求，合计功率加备用不超过 6 kW，成本为 1.25 个记账单位；整数网格枚举得到相同最优值。该核验仅说明求解器在合成输入下满足约束，不证明预测带来节约。

5.4.5 证据边界与应用验证要求

EPFL 数据提供 172.5 kW 站级限额、两车共享规则及功率控制字段，2.1.2 节据此完成有限形态核查；其节点与计量口径尚不能对齐 ACN。运行验证仍需同步节点及全站电表、输入到达时间、设备限额、预测时已知车辆请求和电价。取得这些材料后，再固定事件定义、告警阈值与调度基线开展影子回放，评价覆盖、漏报、越限、需求满足与成本。现有证据支持运行接口定义与合成约束可行性核验。

5.5 本章小结

表 5-9 汇总本章三类分析：方向性候选、区间可靠性和运行接口。

表 5-9 第 5 章探索结果汇总

问题	操作	主要观察	结论边界
分离模型选择与校准后能否达标?	新协议冻结三种子、独立校准段与有限样本秩修正	行为分层整体覆盖 80.04%，事件 5.92%；平均宽度较标准增加 43.3%	测试时期已查看；存在时间依赖与失配，不能报告 90%保证或与旧覆盖直接计算收益
滚动残差更新能否缓解失配?	14/28 天成熟标签历史回放	14 天行为分层整体覆盖 89.01%，事件 26.71%；宽度为冻结分层的 4.47 倍	已查看时期的条件回放，未达 90%，不证明分层独有优势
JPL 独立校准能否覆盖困难样本?	复用冻结三种子预测，按原两条路径校准	标准/行为分层整体覆盖 90.08%/90.11%，事件 46.43%/45.88%	固定已查看测试期；总体接近目标不等于事件可靠性
点预测能否给出可靠区间?	旧标准共形、回溯规则路由与 oracle 对比	标签事件覆盖率 1.9%→3.9%；oracle 为 86.1%	旧规则不具备已验证实时可见性, 覆盖未达标; oracle 仅为事后参照
统计关系能否呈现方向信息?	TE 候选筛查与 PCMCI+条件独立分析	TE 有 76/90 个未经校正的名义候选，270 项 Bonferroni 后为 0；当前环境 PCMCI+为 22/360 个 Holm 校正滞后单元	历史 PCMCI+的 80 个名义单元缺版本和完整 p 矩阵；方向统计不是物理因果边
节点预测如何进入运行决策?	代理需求回放及合成充电分配线性规划	实例末步低估 43.1%；合成计划满足 1 kWh 请求与容量限制	真实预测与合成约束来源不同，尚无计量映射或实际调度收益

结　论

研究工作总结

本文围绕站内节点代理负荷，完成关系建模、受控预测比较和 MDP 诊断。新增证据支持所检 JPL 设置下负荷耦合与轮廓相似关系相对自环的条件性整体 MAE 增量，并说明组件价值、完整模型表现和参数敏感度须分别判断。

主要研究结论

（1）整体误差优势未延伸至困难样本。Caltech 事件时刻协议下，MRG-GCN 整体 MAE 为 0.03890 kWh/15 min，较容量近似 TCN 低 16.1%，但完整 AGCRN 更低，且 MRG-GCN 非零目标与标签事件误差均未优于 TCN。JPL 重新拟合后，其整体 MAE 为 0.081067 kWh/15 min，较三项预登记对照低 2.64%—3.36%，校正时间块区间为正；TCN 的 RMSE 及困难样本误差更低。因此，模型选择应并列考察整体与分层指标。

（2）组件增量具有明确边界。节点级门控相对同参数共享门控在 Caltech、JPL 的整体 MAE 分别低 2.69%和 2.71%；每站一个共享门控种子触及 60 轮上限，结果限于该训练预算。JPL 同参数自环替换显示，负荷耦合和轮廓相似关系的整体 MAE 增量分别为 1.82%和 1.52%，Bonferroni 校正区间下限均为正；行为共现关系的区间跨零。事后分层中，负荷邻接换为自环后非零组 MAE 较完整模型高 0.004893 kWh/15 min，三种子同向，但该结果未经多重校正。它是组件内差异，不是模型间排名：完整 MRG-GCN 在 Caltech、JPL 及完成时刻截断目标下的非零组均未胜过容量近似 TCN。

（3）目标敏感性与 MDP 改变了证据解释。完成时刻截断下，MRG-GCN 相对容量近似 TCN 的整体 MAE 排序保持（0.043401 对 0.051703 kWh/15 min），但新目标零值占比为 94.27%，MRG-GCN 非零组 MAE 高 0.013938 kWh/15 min，整体优势仍由零目标组驱动；该实验固定关系图并复用已查看测试期。MDP 区分联合参数敏感度、受检学生替代表现和误差组成：β未显示独立增益，当前学生未弥合差距，四格结果要求并列报告稀有困难格误差与常态格总误差。它支持修订研究判断和评价重点，尚未证明诊断指导改模可提升预测。

（4）可靠性与应用证据仍有限。Caltech 14 天成熟标签滚动分层覆盖为 89.01%，事件覆盖为 26.71%，区间宽度达到冻结方案的 4.47 倍；JPL 标准独立校准整体覆盖为 90.08%，事件覆盖仅 46.43%。TE 候选经 270 项家族校正后均未保留。固定轨迹和合成线性规划只核验了代理接口与约束求解；缺少计量映射

及实际运行资料，尚不能评价现场风险或经济收益。

研究判断与使用条件

在会话重构的站内节点代理负荷任务中，可优先复核负荷耦合和轮廓相似关系，将行为共现关系保留为待确认候选；若关注活跃片段，应按非零组和事件组表现选模，不以整体 MAE 或β排序单独决定关系取舍。现有证据可用于安排模型复核与数据采集，不能支持现场设备选型、容量控制或收益估算。

研究局限与后续工作

后续工作优先核验代理目标与实际充电过程的对应关系：采集同步电表和输入到达时间戳，校准计量映射与信息可见性，并取得兼容数据开展独立验证。ACN 时间范围核验未发现晚于既有时期的记录，Office 1 仍待节点、字段及既有使用史核查。方法补验分别针对三项问题：在替代目标下重建关系图以检验全流程稳健性；以共同延长的预算比较节点级与共享门控，排查预算解释；匹配学生容量、输入、目标和训练预算，评价图信息的可替代性。运行评价需设备与车辆约束、成熟标签和实时可见信号，先开展影子回放，再评价事件覆盖、漏报、执行效果与成本。

参考文献

[1] 中国电动汽车充电基础设施促进联盟. 2024 年全国电动汽车充换电基础设施运行情况[EB/OL]. (2025-01-23)[2026-10-22]. https://www.evcipa.org.cn/newsinfo/8137834.html.

[2] 陈丽丹, 张尧, FIGUEIREDO A. 电动汽车充放电负荷预测研究综述[J]. 电力系统自动化, 2019, 43(10): 177-197.

[3] 张夏韦, 梁军, 王要强, 等. 电动汽车充电负荷时空分布预测研究综述[J]. 电力建设, 2023, 44(12): 161-173.

[4] 崔一诺, 罗配明, 李攀硕, 等. 电动汽车充放电负荷时-空分布预测研究综述[J]. 电气工程学报, 2026, 21(2): 371-385.

[5] 韩林阳, 叶承晋, 朱超, 等. 高温天气下计及用户意愿的城市充电负荷空间引导策略[J]. 电力系统自动化, 2024, 48(10): 139-150.

[6] 田礼彬. 电动汽车负荷时空预测及有序充放电优化调度[D]. 吉林: 东北电力大学, 2025.

[7] 王哲, 万宝, 凌天晗, 等. 基于谱聚类和 LSTM 神经网络的电动公交车充电负荷预测方法[J]. 电力建设, 2021, 42(6): 58-66.

[8] 陈闯. 基于图卷积网络及排队论的电动汽车充电负荷预测研究[D]. 深圳: 哈尔滨工业大学(深圳), 2022.

[9] 奚圣宽. 基于深度学习的电动汽车充电桩负荷预测方法研究[D]. 北京: 华北电力大学, 2023.

[10] 黄南天, 孙赫宏, 王圣元, 等. 计及多公共充电站差异化耦合关联的电动汽车充电负荷时-空短期预测[J]. 中国电机工程学报, 2025, 45(4): 1424-1436. DOI: 10.13334/j.0258-8013.pcsee.231589.

[11] 张美霞, 孙铨杰, 杨秀. 考虑多源信息实时交互和用户后悔心理的电动汽车充电负荷预测[J]. 电网技术, 2022, 46(2): 632-641.

[12] 张延宇, 张智铭, 刘春阳, 张西锄, 周毅. 基于动态自适应图神经网络的电动汽车充电负荷预测[J]. 电力系统自动化, 2024, 48(7): 86-93. DOI: 10.7500/AEPS20230611001.

[13] 黄健, 陈建红, 何剑杰, 等. 基于 GCN-LSTM 的电动汽车负荷预测方法[J]. 浙江电力, 2024, 43(12): 59-67. DOI: 10.19585/j.zjdl.202412006.

[14] 陈培垠, 方彦军. 基于卡尔曼滤波预测节假日逐点增长率的电力系统短期负荷预测[J]. 武汉大学学报(工学版), 2020, 53(2): 139-144.

[15] 潘良军, 王楷, 赵宏炎, 等. 基于春节影响时期分析的中期负荷智能预测[J]. 智慧电力, 2020, 48(9): 75-80,117.

[16] 陈梓行, 金涛, 郑熙东, 等. 基于新型日期映射法和 ISGU 混合模型的短期电力负荷预测[J]. 电力系统保护与控制, 2022, 50(15): 72-80.

[17] 巫朝越. 考虑特殊事件影响的单体用户短期负荷预测组合模型[D]. 南京: 东南大学, 2024.

[18] 韩富佳, 王晓辉, 乔骥, 等. 基于人工智能技术的新型电力系统负荷预测研究综述[J]. 中国电机工程学报, 2023, 43(22): 8569-8591.

[19] 黄运有, 詹剑锋. 基于深度学习的短期负荷预测综述[J]. 高技术通讯, 2021, 31(3): 240-248.

[20] KE G, MENG Q, FINLEY T, et al. LightGBM: a highly efficient gradient boosting decision tree[C]//Advances in Neural Information Processing Systems (NeurIPS). 2017: 3146-3154.

[21] CHEN T, GUESTRIN C. XGBoost: a scalable tree boosting system[C]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2016: 785-794.

[22] HOCHREITER S, SCHMIDHUBER J. Long short-term memory[J]. Neural Computation, 1997, 9(8): 1735-1780.

[23] CHO K, VAN MERRIËNBOER B, GULCEHRE C, et al. Learning phrase representations using RNN encoder-decoder for statistical machine translation[C]//Proceedings of EMNLP. 2014: 1724-1734.

[24] BAI S, KOLTER J Z, KOLTUN V. An empirical evaluation of generic convolutional and recurrent networks for sequence modeling[J/OL]. arXiv, 2018[2026-10-22]. https://arxiv.org/abs/1803.01271. DOI: 10.48550/arXiv.1803.01271.

[25] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems (NeurIPS). 2017: 5998-6008.

[26] 王华彪, 李小勇. 基于融合注意力机制改进双向长短时记忆网络在电动汽车充电负荷中的预测研究[J]. 电网与清洁能源, 2022, 38(6): 104-112.

[27] 王琨, 高敬更, 张勇红, 等. 基于 LSTM 神经网络的复合变量电动汽车充电负荷预测方法技术研究[J]. 工业仪表与自动化装置, 2019(1): 27-31.

[28] 张昌鸿, 曾祥智. 基于拉丁超立方及 CNN-LSTM-ATTENTION 的电动汽车负荷预测[J]. 电工技术, 2025(10): 125-129.

[29] 顾玮, 段敬, 张栋, 等. 分时电价下的充电站负荷预测[J]. 计算机应用, 2024, 44(S1): 337-342.

[30] 袁溪, 张邵欣, 张超, 等. 基于 Transformer 的电动汽车充电站能耗预测研究[J]. 计算机技术与发展, 2025, 35(2): 213-220.

[31] 王强, 毕宇豪, 高超, 等. 融合多方信息的电动汽车充电负荷时空分布预测[J]. 电力建设, 2025, 46(6): 24-37. DOI: 10.12204/j.issn.1000-7229.2025.06.003.

[32] 赵子鋆, 彭清文, 邓铭, 等. 考虑多因素影响与误差修正的充电站负荷预测[J]. 浙江电力, 2024, 43(4): 21-28.

[33] 温子健, 李伟风, 刘泽晖, 等. 基于时间特征分类与误差修正的电动汽车充电负荷预测[J]. 浙江电力, 2026, 45(5): 69-78. DOI: 10.19585/j.zjdl.202605007.

[34] 蒋建东, 韩文轩, 赵云飞, 等. 基于优化VMD二次分解的短期电力负荷预测[J]. 郑州大学学报(工学版), 2026, 47(1): 124-130.

[35] 张翾, 李红月. 基于优化 VMD 与 TCN-ISE-Pyraformer 的短期电力负荷预测[J]. 安徽工业大学学报(自然科学版), 2025, 42(3): 263-275. DOI: 10.12415/j.issn.1671-7872.25006.

[36] 韩宇昊, 刘鸿鹏. 基于 FMD-LSTM-Bootstrap 的电动汽车充电负荷区间预测[J]. 东北电力大学学报, 2025, 45(6): 51-59.

[37] 朱俊丞. 基于深度学习的多时间尺度电动汽车充电负荷预测模型设计[D]. 郑州: 郑州大学, 2020.

[38] 陈勇, 江颖达, 徐刚, 等. 规模化电动汽车充电负荷预测[J]. 电力需求侧管理, 2022, 24(5): 71-77. DOI: 10.3969/j.issn.1009-1831.2022.05.012.

[39] 闫威, 李南, 沈月秀, 等. 基于 CNN-GAN 与半监督回归的电动汽车充电负荷预测[J]. 浙江电力, 2023, 42(2): 83-89. DOI: 10.19585/j.zjdl.202302011.

[40] 赵伟博, 范旭东, 孙胜博, 等. 电动汽车充电负荷场景化分析与超短期预测方法[J]. 电

力信息与通信技术, 2025, 23(2): 28-37. DOI: 10.16543/j.2095-641x.electric.power.ict.2025.02.04.
[41] 毛建斌, 杨少兵, 杨湘彦, 等. 基于有限混合模型的规模化电动汽车充电负荷在线预测方法[J]. 电网技术, 2025, 49(5): 1931-1940. DOI: 10.13335/j.1000-3673.pst.2024.0241.
[42] 吴钉捷, 李晓露. 基于实时出行需求和交通路况的电动汽车充电负荷预测[J]. 电力建设, 2020, 41(8): 57-67. DOI: 10.12204/j.issn.1000-7229.2020.08.008.
[43] 丁乐言, 柯松, 张帆, 等. 考虑出行需求和引导策略的电动汽车充电负荷预测[J]. 电力建设, 2024, 45(6): 10-26. DOI: 10.12204/j.issn.1000-7229.2024.06.002.
[44] 张琳娟, 李文峰, 许长清, 等. 计及充电排队与实时 SOC 的电动汽车充电负荷时空分布预测[J]. 电力建设, 2025, 46(8): 54-66. DOI: 10.12204/j.issn.1000-7229.2025.08.006.
[45] 李宏伟, 宋玉峰, 李帅兵, 等. 基于 ArcGIS 路网结构与交通拥挤度分析的电动汽车充电负荷预测方法[J]. 电网技术, 2025, 49(5): 1920-1930. DOI: 10.13335/j.1000-3673.pst.2023.1420.
[46] 葛乐, 陆颖, 王明深, 等. 考虑用户决策更新的电动汽车充换电负荷预测[J]. 浙江电力, 2025, 44(10): 152-164. DOI: 10.19585/j.zjdl.202510013.
[47] KIPF T N, WELLING M. Semi-supervised classification with graph convolutional networks[C]//Proceedings of the 5th International Conference on Learning Representations (ICLR). Toulon, 2017.
[48] VELIČKOVIĆ P, CUCURULL G, CASANOVA A, et al. Graph attention networks[C]//Proceedings of the 6th International Conference on Learning Representations (ICLR). 2018.
[49] SCHLICHTKRULL M, KIPF T N, BLOEM P, et al. Modeling relational data with graph convolutional networks[C]//European Semantic Web Conference (ESWC). 2018: 593-607.
[50] YU B, YIN H, ZHU Z. Spatio-temporal graph convolutional networks: a deep learning framework for traffic forecasting[C]//Proceedings of the 27th International Joint Conference on Artificial Intelligence (IJCAI). 2018: 3634-3640.
[51] WU Z, PAN S, LONG G, et al. Graph WaveNet: deep spatial-temporal graph modeling[C]//Proceedings of the 28th International Joint Conference on Artificial Intelligence (IJCAI). 2019: 1907-1913.
[52] BAI L, YAO L, LI C, et al. Adaptive graph convolutional recurrent network for traffic forecasting[C]//Advances in Neural Information Processing Systems (NeurIPS). 2020: 17804-17815.
[53] 叶宝林, 戴本岙, 张鸣剑, 等. 基于图卷积网络的交通流预测方法综述[J]. 南京信息工程大学学报(自然科学版), 2024, 16(3): 291-310.
[54] 闫佳和, 李红辉, 孙婧, 等. 面向交通流预测的时空图神经网络发展综述[J]. 计算机工程与应用, 2025, 61(22): 1-19.
[55] 李志帅, 吕宜生, 熊刚. 基于图卷积神经网络和注意力机制的短时交通流量预测[J]. 交通工程, 2019, 19(4): 15-19, 28.
[56] 董雷, 陈振平, 韩富佳, 等. 基于图卷积神经网络与 K-means 聚类的居民用户集群短期负荷预测[J]. 电网技术, 2023, 47(10): 4291-4301.
[57] 张鹏飞, 胡博, 何金松, 等. 基于时空图卷积网络的短期空间负荷预测方法[J]. 电力系统自动化, 2023, 47(13): 78-85.
[58] 吴兴扬, 戴剑丰. 基于多尺度自适应时空图卷积网络与 BERT 模型的多节点短期负荷预

测[J]. 电网技术, 2025, 49(9): 3756-3766. DOI: 10.13335/j.1000-3673.pst.2024.1895.
[59] 张艺涵, 杨萌, 刘军会, 等. 基于时间图卷积网络的短期电力负荷时空预测方法[J]. 电网与清洁能源, 2024, 40(12): 27-35.
[60] 高昆仑, 姚铁锤, 刘思言, 等. 面向电网分析计算的图神经网络技术综述[J]. 电网技术, 2026, 50(3): 909-921.
[61] 赵紫昱, 陈渊睿, 陈霆威, 等. 基于时空图注意力网络的超短期区域负荷预测[J]. 电力系统自动化, 2024, 48(12): 147-155.
[62] 原野, 王海燕, 袁新平, 等. 基于可解释动态图注意力网络的短期电力负荷预测[J]. 计算机应用, 2025, 45(S1): 329-333.
[63] 孟衡, 张涛, 王金, 等. 基于多尺度时空图卷积网络与 Transformer 融合的多节点短期电力负荷预测方法[J]. 电网技术, 2024, 48(10): 4297-4305. DOI: 10.13335/j.1000-3673.pst.2024.0168.
[64] 贠昕尧. 基于多图融合的电动汽车充电站群负荷时空预测方法研究[D]. 西安: 西安理工大学, 2024.
[65] 王进世. 基于图注意力网络的电动汽车充电站负荷预测方法研究[D]. 兰州: 西北师范大学, 2025.
[66] 王圣元. 基于图神经网络的短期负荷时空预测[D]. 吉林: 东北电力大学, 2023.
[67] HUANG Y, WU S, WANG Z, et al. Causality-aware multi-graph convolutional networks with critical node dynamics for electric vehicle charging station load forecasting[J]. IEEE Transactions on Smart Grid, 2025, 16(4): 3210-3225. DOI: 10.1109/TSG.2025.3570955.
[68] ZHANG L, JIAO Z, ZHAO C. Load probabilistic forecasting for electric vehicle charging station cluster: adaptive multivariate spatiotemporal graph fusion technology[J]. International Journal of Electrical Power & Energy Systems, 2025, 173: 111387. DOI: 10.1016/j.ijepes.2025.111387.
[69] HE J, LIU Q Y, HU Y L, et al. Short-term regional EV charging load forecasting based on GAT and GRU with trip distribution estimation[J]. Applied Energy, 2026, 406: 127262. DOI: 10.1016/j.apenergy.2025.127262.
[70] XIE T, YUN X, ZHANG G, et al. Charging station cluster load prediction: spatiotemporal multi-graph fusion technology[J]. Renewable and Sustainable Energy Reviews, 2024, 206: 114855. DOI: 10.1016/j.rser.2024.114855.
[71] FENG D, LI D, ZHOU Y, ZHAO J, ZHANG K. STGNet: short-term residential load forecasting with spatial-temporal gated fusion network[J]. Energy Science & Engineering, 2024, 12(3): 541-560. DOI: 10.1002/ese3.1633.
[72] WANG Y, RUI L, MA J, et al. A short-term residential load forecasting scheme based on the multiple correlation-temporal graph neural networks[J]. Applied Soft Computing, 2023, 146: 110629. DOI: 10.1016/j.asoc.2023.110629.
[73] ZHANG T, JIAO W, YU J, et al. Short-term residential load forecasting framework based on spatial-temporal fusion adaptive gated graph convolution networks[J]. IEEE Transactions on Neural Networks and Learning Systems, 2025, 36(9): 17004-17018. DOI: 10.1109/TNNLS.2025.3551778.
[74] 高洪超, 陈启鑫, 雷振, 等. 考虑事件数据的产消者负荷预测方法及极端误差抑制策略[J]. 电力系统自动化, 2023, 47(13): 47-55.
[75] HWANG J, SUH D. PAR-LLM: peak-aware residual LLM over anchor for EV charging station demand[J]. IEEE Access, 2026, 14: 52360-52370. DOI:

10.1109/ACCESS.2026.3679962.
[76] LIANG Y. Forecast-time-safe load forecasting for connected and automated EV charging operation: periodicity-aware residual correction on a processed distribution load proxy with public EV charging validation[J]. World Electric Vehicle Journal, 2026, 17(7): 336. DOI: 10.3390/wevj17070336.
[77] LUNDBERG S M, LEE S I. A unified approach to interpreting model predictions[C]//Advances in Neural Information Processing Systems (NeurIPS). 2017: 4765-4774.
[78] 孙飞虎. 基于注意力机制的配电网电力负荷预测方法研究[D]. 桂林: 桂林电子科技大学, 2025.
[79] JAIN S, WALLACE B C. Attention is not explanation[C]//Proceedings of NAACL-HLT. 2019: 3543-3556.
[80] ARABZADEH V, FRANK R. A four-dimensional analysis of explainable AI in energy forecasting: a domain-specific systematic review[J]. Machine Learning and Knowledge Extraction, 2025, 7(4): 153.
[81] GUASTAVINO S, PIANA M, BENVENUTO F. Bad and good errors: value-weighted skill scores in deep ensemble learning[J]. IEEE Transactions on Neural Networks and Learning Systems, 2024, 35(2): 1993-2002. DOI: 10.1109/TNNLS.2022.3186068.
[82] LEE Z J, LI T, LOW S H. ACN-Data: Analysis and applications of an open EV charging dataset[C]//Proceedings of the Tenth ACM International Conference on Future Energy Systems. New York: ACM, 2019: 139-149. DOI: 10.1145/3307772.3328313.
[83] LI T. ACN-Data Static[EB/OL]. [2026-10-22]. https://github.com/tongxin-li/ACN-Data-Static.
[84] DESL-EPFL. Level 3 electric vehicle charging dataset[DB/OL]. [2026-10-22]. https://github.com/DESL-EPFL/Level-3-EV-charging-dataset.
[85] BOX G E P, JENKINS G M. Time series analysis: forecasting and control[M]. San Francisco: Holden-Day, 1970.
[86] NAM A, CONKLIN H, YANG Y, et al. Causal head gating: a framework for interpreting roles of attention heads in transformers[C]//Advances in Neural Information Processing Systems. 2025, 38.
[87] HINTON G, VINYALS O, DEAN J. Distilling the knowledge in a neural network[C]//NeurIPS 2014 Deep Learning Workshop. 2015.
[88] SCHREIBER T. Measuring information transfer[J]. Physical Review Letters, 2000, 85(2): 461-464.
[89] RUNGE J, NOWACK P, KRETSCHMER M, et al. Detecting and quantifying causal associations in large nonlinear time series datasets[J]. Science Advances, 2019, 5(11): eaau4996.
[90] RUNGE J. Discovering contemporaneous and lagged causal relations in autocorrelated nonlinear time series datasets[C]//Proceedings of the 36th Conference on Uncertainty in Artificial Intelligence (UAI). PMLR, 2020, 124: 1388-1397.
[91] VOVK V, GAMMERMAN A, SHAFER G. Algorithmic learning in a random world[M]. New York: Springer, 2005.
[92] LEI J, G'SELL M, RINALDO A, et al. Distribution-free predictive inference for regression[J]. Journal of the American Statistical Association, 2018, 113(523): 1094-1111.
[93] GIBBS I, CANDÈS E. Adaptive conformal inference under distribution shift[C]//Advances in Neural Information Processing Systems. 2021, 34: 1660-1672.

附录 A　Caltech 事件时刻协议完整组件结果

附表 A-1 保存 SG-EXP-019 全部 12 种配置的原结果，供 3.7 节组件分析追溯。主结果见表 3-2；两表使用同一组预测键。

表 A-1 Caltech 事件时刻协议完整配置与组件结果

配置	全局 MAE	事件段 MAE	平稳段 MAE	参数量	最优轮次/实际停止轮次
agcrn_full	0.03743 ±0.00022	0.3774 ±0.0008	0.0325 ±0.0002	199,912	1/1/1；9/9/9
mrg_equal_beta	0.03862 ±0.00028	0.3812 ±0.0014	0.0336 ±0.0003	32,708	17/16/13；25/24/21
mrg_full	0.03890 ±0.00010	0.3810 ±0.0009	0.0339 ±0.0001	32,714	27/19/19；35/27/27
mrg_no_skip	0.03900 ±0.00051	0.3829 ±0.0019	0.0340 ±0.0005	30,666	60/21/39；60/29/47
mrg_no_refine	0.03931 ±0.00031	0.3805 ±0.0015	0.0343 ±0.0003	30,602	22/28/60；30/36/60
mrg_pattern	0.03948 ±0.00031	0.3816 ±0.0025	0.0345 ±0.0003	28,612	48/54/51；56/60/59
mrg_fixed_gate	0.04111 ±0.00147	0.3825 ±0.0008	0.0361 ±0.0015	28,554	60/58/60；60/60/60
mrg_load	0.04315 ±0.00073	0.3805 ±0.0024	0.0382 ±0.0008	28,612	48/21/51；56/29/59
mrg_event	0.04559 ±0.00027	0.3780 ±0.0004	0.0407 ±0.0003	28,612	5/21/5；13/29/13
mrg_self_loop	0.04610 ±0.00057	0.3739 ±0.0010	0.0413 ±0.0006	32,714	2/1/6；10/9/14
tcn	0.04629 ±0.00019	0.3751 ±0.0007	0.0415 ±0.0002	16,996	6/1/8；14/9/16
tcn_wide	0.04634 ±0.00029	0.3746 ±0.0019	0.0415 ±0.0003	32,674	11/4/3；19/12/11

注：数值单位为 kWh/15 min；均值和标准差来自 2024、2025、2026 三种子，标准差为样本标准差。最优轮次为验证集原单位 MAE 最低的轮次，实际停止轮次为训练日志最后一轮；两者均按 seed-2024/2025/2026 顺序列出。该表使用 Caltech 事件时刻协议的 708,560 个测试预测键，与 Caltech 回溯协议的 712,360 个预测键不具有直接数值可比性。